4th International Conference on Recent Academic Studies

March 04-05, 2025: Konya, Turkey

© 2025 Published by All Sciences Academy

https://as-proceeding.com/index.php/icras/home

CNN ve ViT Modellerinde Farklı Aktivasyon Fonksiyonlarının CIFAR-10 Sınıflandırma Performansına Etkisi

Ahmet AKKAYA[1*] ve Cemil KÖZKURT [2]

[1] *Bilgisayar Teknolojileri / Gönen Meslek Yüksekokulu, Bandırma Onyedi Eylül Üniversitesi, Türkiye*
[2] *Bilgisayar Mühendisliği /Mühendislik ve Doğa Bilimleri Fakültesi, Bandırma Onyedi Eylül Üniversitesi, Türkiye*

[*]*(aakkaya@bandirma.edu.tr) Sorumlu yazarın mail adresi*

Özet – Bu çalışmada, Evrişimsel Sinir Ağları (Convolutional Neural Network – CNN) ve Görüntü Dönüştürücü (Vision Transformer – ViT) modellerinin ReLU, LReLU, ELU, GELU ve Mish gibi popüler aktivasyon fonksiyonlarıyla CIFAR-10 veri seti üzerinde gösterdiği performans karşılaştırılmaktadır. Araştırmanın temel amacı, CNN ve ViT modellerinin farklı aktivasyon fonksiyonları kullanılarak sinir ağı eğitim ve doğrulama aşamalarındaki etkilerini inceleyerek kullanılan aktivasyon fonksiyonlarının modeller üzerindeki performanslarını çeşitli metriklerle değerlendirmektir. Yapılan deneysel çalışmalarda her aktivasyon fonksiyonu için CNN ve ViT modelleri, 30 epok ve 5 ayrı çalıştırma ile eğitilmiş ve test edilmiştir. Eğitim sürecinde elde edilen eğitim doğruluğu (train accuracy), eğitim kaybı (train loss), doğrulama doğruluğu (validation accuracy) ve doğrulama kaybı (validation loss) metriklerinin ortalama değerleri analiz edilerek aktivasyon fonksiyonları ve kullanılan model arasında performans karşılaştırması yapılmıştır. Elde edilen sonuçlar, CNN modelinde LReLU aktivasyon fonksiyonunun en yüksek eğitim doğruluğunu (%86.36) sağladığını, ancak doğrulama doğruluğunun (%69.31) diğer fonksiyonlara göre daha dengesiz olduğunu göstermektedir. Diğer yandan, ELU aktivasyon fonksiyonu, CNN modeli için doğrulama kaybını minimize ederek daha kararlı bir performans sunmuştur. ViT modelinde ise ELU aktivasyon fonksiyonunun en yüksek doğrulama doğruluğunu (%63.45) sağladığı gözlemlenmiştir. Eğitim ve doğrulama kayıpları açısından, CNN modelinde LReLU'nun düşük eğitim kaybı sağladığı ancak doğrulama kaybının yüksek olduğu görülmüştür. ViT modelinde ise GELU ve Mish aktivasyon fonksiyonlarının eğitim ve doğrulama kaybını belirgin şekilde azalttığı tespit edilmiştir. Genel olarak, CNN ve ViT modellerinin farklı aktivasyon fonksiyonlarına karşı duyarlılığı değişkenlik göstermekte olup, uygulama alanına göre en uygun fonksiyonun seçilmesi performansı önemli ölçüde etkilediği sonucuna ulaşılmıştır.

Anahtar Kelimeler – CNN,Vit, CIFAR-10, Karşılaştırma, ReLU, LReLU, ELU, GELU, Mish

I. GİRİŞ

Günümüzde bilgisayarla görme, doğal dil işleme ve ses tanıma gibi birçok alanda derin öğrenmenin ilerlemeler kaydettiği görülmektedir. Özellikle, Evrişimsel Sinir Ağları'nın (Convolutional Neural Network – CNN) görüntü işleme alanında popüler olarak kullanılan bir yöntem olduğu görünmektedir. CNN'ler, yerel özellikleri öğrenme [1] ve uzamsal bağıntıları koruma yetenekleri [2] sayesinde çeşitli görüntü sınıflandırma [3] ve nesne tespiti [4] görevlerinde oldukça başarılı sonuçlar elde etmektedir. Bu başarılı sonuçlara rağmen CNN'lerin sınırlı alansal farkındalığı ve büyük veri kümelerinde genel performansının artışı için daha derin ve karmaşık yapılara ihtiyaç duyması, araştırmacıları alternatif yaklaşımlar kullanmaya yöneltmektedir. Bu nedenle son yıllarda Transformer tabanlı modellerin yüksek başarımdan dolayı kullanımının arttığı görünmektedir. Özellikle Doğal Dil İşleme (Natural Language

Processing – NLP) alanında Transformer modelleri büyük ilgi görmektedir [5]. Bu duruma paralel olarak görüntü işleme alanında da Transformer yapılarının kullanımı giderek artmaktadır [6]. Transformer tabanlı bir model olan Görüntü Dönüştürücü (Vision Transformer – ViT), görüntüleri küçük parçalara bölerek bunları sıralı bir giriş olarak ele almaktadır. ViT modelleri, kendine dikkat (self-attention) olarak isimlendirilen mekanizması sayesinde küresel ilişkileri öğrenebilmektedir. ViT modelleri, yeterli veri ve hesaplama gücü sağlandığında CNN'lere alternatif olarak yüksek doğrulukta sonuçlar verebilmektedir [7].

Literatür incelendiğinde CNN ve ViT modelleri kullanılarak çeşitli çalışmalar yapıldığı görünmektedir. CNN'lerin temelini atan ilk derin öğrenme modeli LeNet olarak karşımıza çıkmaktadır. Bu model MNIST veri seti üzerinde oldukça başarılı sonuçlar elde etmektedir. Özellikle el yazısı tanıma için geliştirilen modelde konvolüsyonel katmanlar, subsampling (max pooling) katmanları ve fully connected katmanları bulunmaktadır. Bu yapı, görsel özellikleri öğrenme ve sınıflandırma için etkili bir yöntem olarak kabul edilmektedir [8]. Diğer önemli model ise, görsel tanıma alanında devrim yaratan AlexNet modelidir. ImageNet yarışmasında birincilik kazanan bu model, derin CNN'lerin büyük veri setlerinde üstün performans gösterebileceğini ortaya koymuştur. 8 katmanlı yapısıyla, büyük veri setleri üzerinde eğitim yapabilen ve GPU'lar kullanarak hızlı işlem yapabilme gibi özellikleri bulunmaktadır [9]. Bir başka model ise, derin ağların öğrenme yeteneğini artırmak için residual (kalan) bağlantıları kullanarak derin ağların eğitiminde karşılaşılan zorlukları aşmak için tasarlanmış olan ResNet modelidir. ResNet modelinde, kalan bağlantılar ağın daha derin katmanlarla eğitilebilmesini sağlamaktadır. Bu durum modelin daha iyi genelleştirmesini ve daha derin yapıların öğrenilmesini mümkün kılmaktadır [10]. Bir diğer model ise, modelin verimliliğini artırarak daha az parametreyle yüksek doğruluk elde etmeyi amaçlayan EfficientNet modelidir. Bu model, derinlik, genişlik ve çözünürlük arasındaki dengeyi optimize ederek, daha verimli bir şekilde ve daha yüksek doğruluk elde etmeyi amaçlamaktadır [11]. Diğer model görsel görevler için Transformer mimarisini ilk kez uygulayan Vision Transformer model olmaktadır. Bu model, görsel bilgileri işlemeyi dil işleme görevlerinden uyarlayarak başarılı sonuçlar elde etmektedir. Bu modelde görseller küçük parçalara (patch) bölünür ve bu parçalar birer kelime gibi işlenir. Her patch, bir embeding vektörüne dönüştürülür ve Transformer mimarisi ile işlenmektedir [12]. DeiT (Data-efficient Image Transformer), ViT'in veri verimliliğini artırmak için Facebook AI tarafından geliştirilen bir versiyondur [13]. Özellikle daha küçük veri setlerinde ViT modelinin başarılı olmasını sağlamak için distilasyon teknikleri kullanılmıştır. DeiT, eğitimde daha az veri kullanarak ViT'in performansını artırmayı hedeflemekte ve distilasyon sayesinde daha hızlı ve etkili bir öğrenme sağlamaktadır [14]. Swin Dönüştürücü (Swin Transformer – Swin-T), Transformer mimarisini daha verimli hale getiren bir modeldir. Görsel verilerin işlenmesinde, hiyerarşik bir yapıya sahip olup, daha verimli özellik çıkarımı sağlamaktadır. Swin-T, "shifted window" (kaydırılmış pencere) yaklaşımını kullanarak, daha büyük görsel bağlamları öğrenirken hesaplama verimliliğini artırmaktadır [15].

Araştırma kapsamında yapılan çalışmada kullanılan CNN ve ViT model arasındaki temel farkları mimari farklar, veri gereksinimleri, eğitim süresi ve genelleme yeteneği kriterleri bakımından şöyledir. Mimari farklar açısından, CNN'ler görsel verileri öğrenmek için konvolüsyonel katmanlar kullanırken, Vision Transformer'lar görsel veriyi küçük parçalara ayırıp, her birini Transformer yapısına geçirerek işlemektedir. Veri gereksinimleri açısından ViT özellikle büyük veri setlerinde üstün performans gösterirken, CNN'ler genellikle daha küçük veri setlerinde daha hızlı ve etkili çalışmaktadır. Eğitim süresi açısından, ViT daha uzun eğitim süreleri gerektirebilir ve büyük veri setlerine ihtiyaç duyabilir, bu nedenle GPU kullanımı önemli olmaktadır. CNN'ler ise genellikle daha hızlı eğitim sürelerine sahip olmaktadır. Genelleme yeteneği açısından, ViT global bağlamı öğrenme yeteneği sayesinde geniş kapsamlı verileri daha iyi genelleyebilirken, CNN'ler yerel özellikleri daha iyi çıkarma eğiliminde olmaktadır. Bu çalışmada LReLU, ReLU, ELU, GELU ve Mish aktivasyon fonksiyonları kullanılmıştır.

LReLU fonksiyonunun genel özelliği negatif girişler için küçük bir eğim içermesidir. Klasik ReLU'nun negatif bölgedeki sıfır değerini kırmak için kullanılmaktadır. ReLU'nun girişin negatif bölgesindeki "dying ReLU" problemini azalttığı için tercih edilmektedir. LReLU aktivasyon fonksiyonu retinopati hastalığının tespiti ve sınıflandırılmasında [16], Elektroensefalogram artefakt giderme çalışmalarında [17], insan etkinliği tanımlama çalışmalarında [18] ve başka birçok alanda kullanılmaktadır. Leaky ReLU fonksiyonunun matematiksel ifadesi Denklem 1 ile verilmiştir.

$$f(x) = \begin{cases} x \text{ eğer } x > 0 \\ \alpha x \text{ eğer } x \leq 0 \end{cases} \tag{1}$$

ReLU, doğrusal olmayan aktivasyon fonksiyonları arasında en yaygın kullanılan fonksiyondur. Bu aktivasyon fonksiyonunun özelliği giriş değeri negatifse çıkışı sıfır, pozitifse girişin kendisini döndürmektedir. Negatif girişlerin sıfırlanması, ağın hesaplama verimliliğini artırırken bazı nöronların "ölmesine" (dead neurons) yol açabilmektedir. Yüz maskesi algılamada [19], karışımların havuz kaynamasında kabarcık çıkış çapının tahmininde [20], parkinson hastalığı ve COVID-19 tanısını iyileştirmek için [21] ve başka birçok alanda kullanılmaktadır. Matematiksel denklemi Denklem 2 ile verilmiştir.

$$f(x) = max(0, x) \tag{2}$$

ELU, negatif girişlerde üssel bir eğri kullanarak doğrusal olmayan bir karakteristik sağlamaktadır. Genellikle ReLU'ya kıyasla daha iyi öğrenme dinamikleri sunmaktadır. Pozitif girişler için ReLU gibi doğrusal davranırken, negatif girişlerde üssel bir fonksiyon kullanmaktadır. Görüntü sınıflandırma modellerinde [22], optik bilgili sinir ağlarında [23], ses tekrarı saldırısı algılamak için [24] ve başka birçok alanda kullanılmaktadır. Matematiksel denklemi Denklem 3 ile verilmiştir.

$$f(x) = \begin{cases} x \text{ eğer } x > 0 \\ \alpha(e^{x-1}) \text{ eğer } x \leq 0 \end{cases} \tag{3}$$

GELU, Gauss Hata Doğrusal Birimi, aktivasyon fonksiyonudur ve özellikle Transformer tabanlı modellerde sıkça kullanılmaktadır. GELU, bir giriş değerinin belirli bir olasılıkla iletilmesini sağlayan doğrusal olmayan bir aktivasyon fonksiyonudur. Standart ReLU gibi sert eşikleme yapmamakla birlikte sigmoid tabanlı bir ağırlıklandırma uygulamaktadır. Yatak arıza sınıflandırmasında [25], borsa endeksi tahmininde [26], beyin tümörü sınıflandırmasında [27] ve başka birçok alanda kullanılmaktadır. Matematiksel denklemi Denklem 4 ile verilmiştir.

$$GELU(x) = x \cdot \Phi(x) \tag{4}$$

Mish, 2019 yılında Diganta Misra tarafından önerilen bir nonmonotonik aktivasyon fonksiyonudur [28]. Swish ve GELU'ya benzer şekilde yumuşak ve sürekli türevlenebilir bir fonksiyondur. Tıbbi görüntü segmentasyonunda [29], yapay zeka saldırılarının tespitinde [30], güç elektroniği uygulamalarında [31] ve başka birçok alanda kullanılmaktadır. Matematiksel olarak Mish, Denklem 5 ile verilmiştir.

$$Mish(x) = x \cdot tanh\big(softplus(x)\big) \tag{5}$$

Burada kullanılan softplus fonksiyonu Denklem 6 ile verilmiştir.

$$softplus(x) = ln(1 + e^{x}) \tag{6}$$

Araştırma kapsamında yapılan çalışmada, CIFAR-10 veri seti kullanılarak CNN ve ViT modellerinin performansları karşılaştırılmaktadır. Karşılaştırma işleminde farklı aktivasyon fonksiyonlarının (LReLU, ReLU, ELU, GELU ve Mish) etkisi analiz edilmektedir.

II. MATERYAL VE YÖNTEM

Araştırma kapsamında gerçekleştirilen deneysel çalışmada CIFAR-10 veri seti kullanılmıştır. CIFAR-10 veri seti, her biri 32x32 boyutunda olan 60.000 renkli görüntüden oluşan bir veri setidir. Bu veri setinde uçak, araba, kuş, kedi, geyik, köpek, kurbağa, at, gemi, kamyon olmak üzere 10 sınıf bulunmaktadır. 10 sınıfın her biri 6.000 adet görüntü içermektedir. Yapılan deneysel çalışmalarda eğitim için 50.000 adet, test için 10.000 adet görüntü kullanılmaktadır. Deneysel çalışmalarda CNN ve ViT modelleri kullanılmıştır. Bu modeller LReLU, ReLU, ELU, GELU ve Mish aktivasyon fonksiyonları kullanılarak 30 epok ve 5 çalıştırma için eğitim doğruluğu, doğrulama doğruluğu, eğitim kaybı ve doğrulama kaybı değerleri hesaplanarak CIFAR-10 veri seti üzerindeki performansları karşılaştırılmıştır.

III. DENEYSEL ÇALIŞMALAR

Bu bölümde CNN ve ViT modellerinde LReLU, ReLU, ELU, GELU ve Mish aktivasyon fonksiyonları kullanılarak 30 epok ve 5 çalıştırma sonucunda elde edilen eğitim doğruluğu, doğrulama doğruluğu, eğitim kaybı ve doğrulama kaybı değerleri tablolarla sunulmuş daha sonra her bir aktivasyon fonksiyonu için görselleştirilme sağlanmıştır.

A. CNN modelinde ReLU AF Performansı

Tablo 1 ile CNN modelin ReLU AF performansı verilmiştir.

Tablo 1: CNN modelin ReLU AF performansı

Epok	Ortalama Eğitim Doğruluğu	Ortalama Eğitim Kaybı	Ortalama Doğrulama Doğruluğu	Ortalama Doğrulama Kaybı
1	0.2701	1.9889	0.4412	1.5535
2	0.4576	1.5053	0.5022	1.396
3	0.5089	1.3833	0.5216	1.3427
4	0.5338	1.3181	0.5561	1.2653
5	0.5608	1.2473	0.5675	1.2171
6	0.5763	1.2042	0.5752	1.203
7	0.5968	1.1553	0.5901	1.1629
8	0.6151	1.1124	0.605	1.1327
9	0.627	1.0745	0.6197	1.0796
10	0.6427	1.0349	0.6315	1.0531
11	0.6467	1.0201	0.6338	1.0473
12	0.6554	0.9998	0.6474	1.0198
13	0.6617	0.975	0.66	0.9823
14	0.6746	0.9488	0.657	0.985
15	0.684	0.9197	0.6639	0.9701
16	0.6851	0.914	0.6708	0.9469
17	0.6891	0.9012	0.6734	0.9418
18	0.6986	0.8733	0.6712	0.9432
19	0.707	0.8554	0.6788	0.9324
20	0.7116	0.8415	0.6846	0.9339
21	0.7151	0.8248	0.69	0.8967
22	0.7212	0.8145	0.6972	0.8883

23	0.7218	0.8137	0.6923	0.9022
24	0.73	0.7838	0.695	0.8843
25	0.7346	0.7703	0.7021	0.8693
26	0.7364	0.7675	0.6934	0.8937
27	0.7447	0.7456	0.6931	0.8979
28	0.745	0.737	0.6954	0.8859
29	0.7503	0.721	0.7128	0.8474
30	0.7544	0.7168	0.7124	0.8457

Tablo 1 incelendiğinde CNN modelinde ReLU AF performansı görünmektedir. Eğitim doğruluğu %27 ile başlayıp %75 seviyesine kadar çıkmaktadır. Bu durum, modelin eğitim setinde iyi bir şekilde öğrenme gerçekleştirdiğini göstermektedir. Eğitim kaybı, 1.98'den 0.71 seviyesine kadar düşerek modelin hatalarının azaldığını göstermektedir. Doğrulama doğruluğu %44 seviyesinden başlayarak %71'e kadar yükselmektedir. Ancak, 22. epok sonrasında belirgin bir ilerleme kaydedilmemektedir. Doğrulama kaybı ise başlangıçta 1.55 olup zamanla 0.84 seviyelerine düşmektedir. Bu, modelin genelleştirme performansının geliştiğini göstermektedir. 22. epok civarında eğitim doğruluğu ile doğrulama doğruluğu arasındaki fark açılmaya başlamaktadır. Eğitim doğruluğu %75'e ulaşırken, doğrulama doğruluğu %71'de kalmaktadır. Bu durum, modelin eğitim verisini ezberlemeye başladığını ve aşırı öğrenme ihtimali olduğunu göstermektedir. Şekil 1 ile CNN model için ReLU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

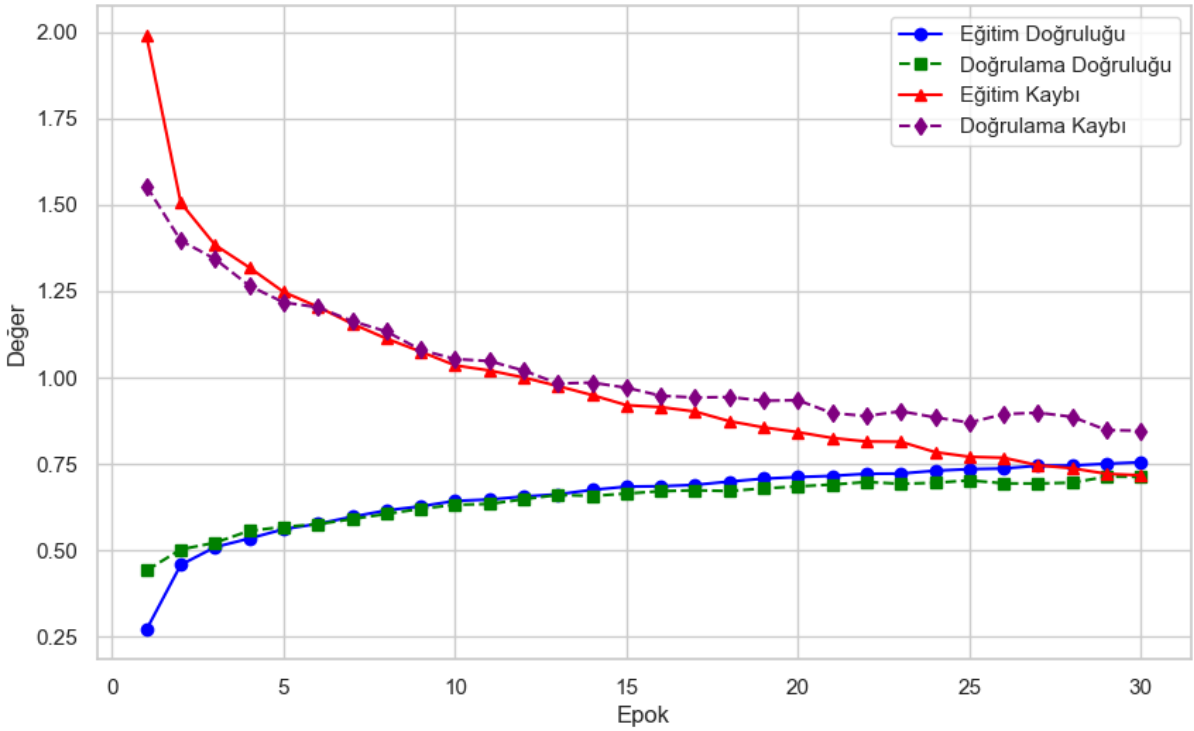

Şekil 1: CNN model için ReLU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

B. CNN modelinde LReLU Performansı

Tablo 2 ile CNN modelin LReLU AF performansı verilmiştir.

Tablo 2: CNN modelinde LReLU performansı

Epok	Ortalama Eğitim Doğruluğu	Ortalama Eğitim Kaybı	Ortalama Doğrulama Doğruluğu	Ortalama Doğrulama Kaybı
1	0.36414	1.72142	0.56218	1.22218
2	0.59404	1.1475	0.62838	1.06334
3	0.6638	0.95926	0.65998	0.97666
4	0.70566	0.83784	0.69238	0.88092
5	0.74078	0.74156	0.6979	0.88124
6	0.76842	0.66176	0.70128	0.87574
7	0.79018	0.59816	0.71574	0.8567
8	0.81276	0.53292	0.71988	0.8674
9	0.83272	0.47258	0.71162	0.91852
10	0.85266	0.4202	0.71348	0.95576
11	0.86984	0.3707	0.71164	0.99682
12	0.88376	0.32878	0.70468	1.07928
13	0.89706	0.29186	0.70566	1.13318
14	0.90822	0.25902	0.70798	1.1841
15	0.9192	0.2283	0.70564	1.25136
16	0.92868	0.20044	0.70086	1.37198
17	0.93504	0.18504	0.70274	1.42948
18	0.94038	0.16844	0.70146	1.54062
19	0.94408	0.15844	0.70412	1.57576
20	0.94918	0.14256	0.69774	1.66714
21	0.95276	0.13408	0.6974	1.71594
22	0.95474	0.1279	0.69752	1.77746
23	0.95844	0.1192	0.69568	1.85818
24	0.95912	0.11624	0.6963	1.93874
25	0.96144	0.1103	0.69436	2.0181
26	0.96044	0.1132	0.69488	2.0664
27	0.96322	0.1042	0.69254	2.11524
28	0.96454	0.10188	0.6945	2.16712
29	0.96484	0.10076	0.69262	2.21894
30	0.96686	0.0961	0.69274	2.26438

Tablo 2 incelendiğinde CNN modelinde ReLU AF performansı görünmektedir. Modelin eğitim doğruluğu ilk epokta %36 seviyesindeyken, eğitim ilerledikçe %96'ya kadar çıkmaktadır. Eğitim kaybı ise 1.72'den 0.09 seviyesine kadar düşmektedir. Bu durum, modelin eğitim setindeki verileri çok iyi öğrendiğini göstermektedir. İlk 10 epok boyunca doğrulama doğruluğu düzenli bir şekilde artmaktadır (%56 → %71). 10. epoktan sonra doğrulama doğruluğu %71 civarında sabitlenmektedir. Buna karşılık, doğrulama kaybı 10. epoktan sonra artmaya başlamakta ve 2.26 seviyesine kadar yükselmektedir. Bu veriler, modelin başta iyi bir öğrenme gerçekleştirdiğini ancak belli bir noktadan sonra doğrulama performansında bozulma olduğunu göstermektedir. Eğitim doğruluğu %96'ya ulaşırken, doğrulama doğruluğu %71 civarında sabit kalmaktadır. Doğrulama kaybı 10. epoktan sonra giderek artmaktadır (1.22 → 2.26). Bu durum, modelin eğitim setini çok iyi öğrendiğini fakat doğrulama setine genelleme yapamadığını göstermektedir. Buna göre model, eğitildiği veriyi ezberlemiş olabilir. 10-15. epok

civarında doğrulama doğruluğu sabitlenirken doğrulama kaybı artmaya başlamaktadır. 15. epok sonrası modelin doğrulama kaybı önemli ölçüde artış göstermektedir. Şekil 2 ile CNN model için LReLU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

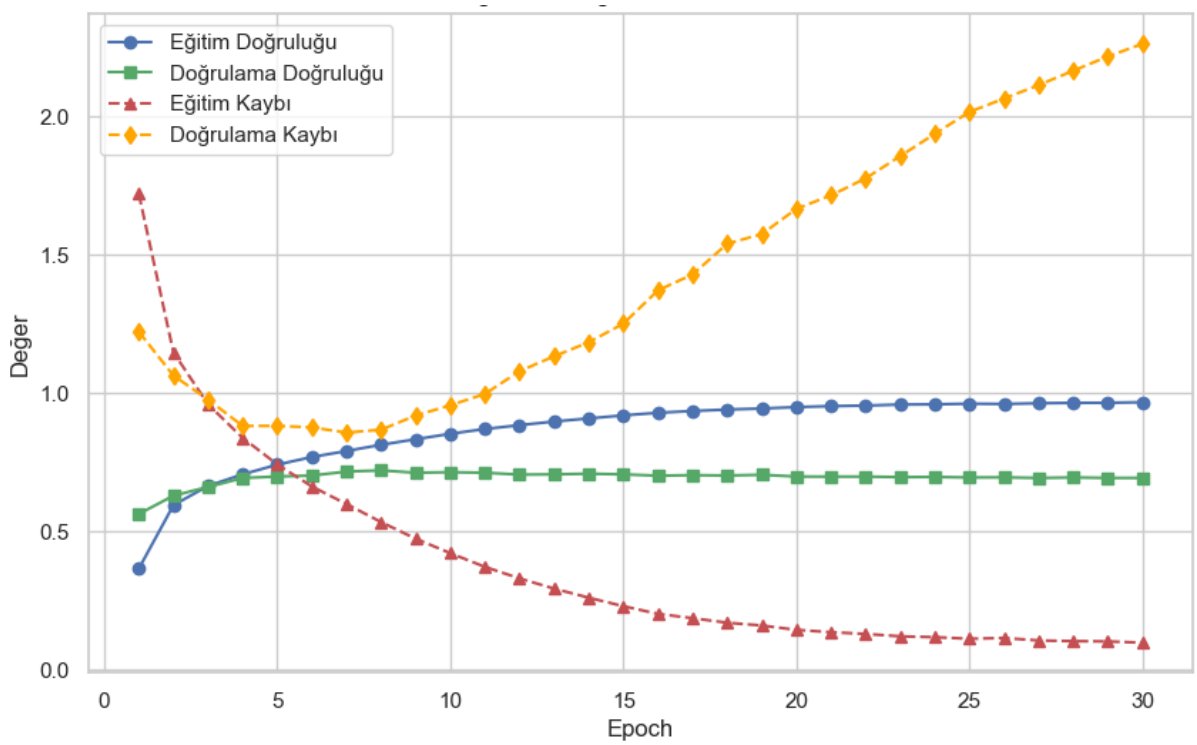

Şekil 2: CNN model için LReLU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

C. CNN modelinde ELU AF Performansı

Tablo 3 ile CNN modelin ELU AF performansı verilmiştir.

Tablo 3: CNN modelin Elu AF performansı

Epok	**Ortalama Eğitim Doğruluğu**	**Ortalama Eğitim Kaybı**	**Ortalama Doğrulama Doğruluğu**	**Ortalama Doğrulama Kaybı**
1	0.2951	1.9584	0.4473	1.5624
2	0.4648	1.5171	0.507	1.3863
3	0.5151	1.3712	0.5396	1.305
4	0.5468	1.2939	0.539	1.2894
5	0.5714	1.2207	0.5895	1.1872
6	0.5948	1.1624	0.6011	1.1522
7	0.6123	1.1176	0.6084	1.12
8	0.622	1.0858	0.6035	1.121
9	0.6366	1.0492	0.6284	1.0694
10	0.6482	1.0169	0.6305	1.0672
11	0.6544	0.9914	0.6431	1.0337
12	0.663	0.9751	0.6489	1.0108
13	0.6735	0.9466	0.6525	1.0052
14	0.6757	0.9306	0.6625	0.9815
15	0.6846	0.9136	0.6593	0.99

16	0.6934	0.8842	0.6662	0.9698
17	0.704	0.8624	0.6712	0.9557
18	0.709	0.8569	0.6754	0.9439
19	0.712	0.8362	0.6804	0.9348
20	0.7157	0.818	0.6859	0.9199
21	0.7242	0.795	0.6887	0.9138
22	0.7323	0.7719	0.6916	0.8998
23	0.735	0.7709	0.6834	0.929
24	0.7372	0.7615	0.6987	0.8874
25	0.7477	0.7359	0.6919	0.8967
26	0.7525	0.7192	0.6965	0.8834
27	0.7573	0.7131	0.7023	0.8715
28	0.7602	0.6988	0.6999	0.8743
29	0.7646	0.689	0.7028	0.8809
30	0.7692	0.6726	0.7063	0.8696

Tablo 3 incelendiğinde CNN modelinde ELU AF performansı görünmektedir. İlk epokta eğitim doğruluğu %29 seviyesinde, eğitim kaybının ise 1.95 olduğu görünmektedir. Modelin 30. epokta eğitim doğruluğunu %76 seviyesine çıkardığı ve eğitim kaybını 0.67 seviyesine düşürdüğü görünmektedir. Eğitim doğruluğu sürekli artarken, eğitim kaybı düzenli olarak azalmaktadır. Bu durum modelin, eğitim setindeki veriyi iyi öğrenmiş olduğunu göstermektedir. İlk 10 epok boyunca hem eğitim hem doğrulama doğruluğu hızlı artmaktadır (%44 → %63). 10. epoktan sonra doğrulama doğruluğundaki artış hızı yavaşlamakta ve %70 civarına yakınsadığı görünmektedir. Doğrulama kaybı 14. epoktan sonra belirgin şekilde azalmaya devam etmektedir. 30. epokta doğrulama doğruluğu %70 seviyesine ulaştığı ve doğrulama kaybının 0.86'ya düştüğü görülmektedir. Bu model, ilk 10-15 epok boyunca iyi bir öğrenme gerçekleştirmekte, ancak sonraki epoklarda öğrenme hızı yavaşlamaktadır. Eğitim doğruluğu %76'ya ulaşırken, doğrulama doğruluğu %70 seviyesinde kalmaktadır. Eğitim kaybı 0.67'ye düşerken, doğrulama kaybı 0.86 seviyesinde kalmaktadır. Doğrulama doğruluğu 21-30. epok arasında %68-70 bandında kaldığından modelin genel performansında durağanlaşma olduğu söylenebilmektedir. Şekil 3 ile CNN model için ELU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

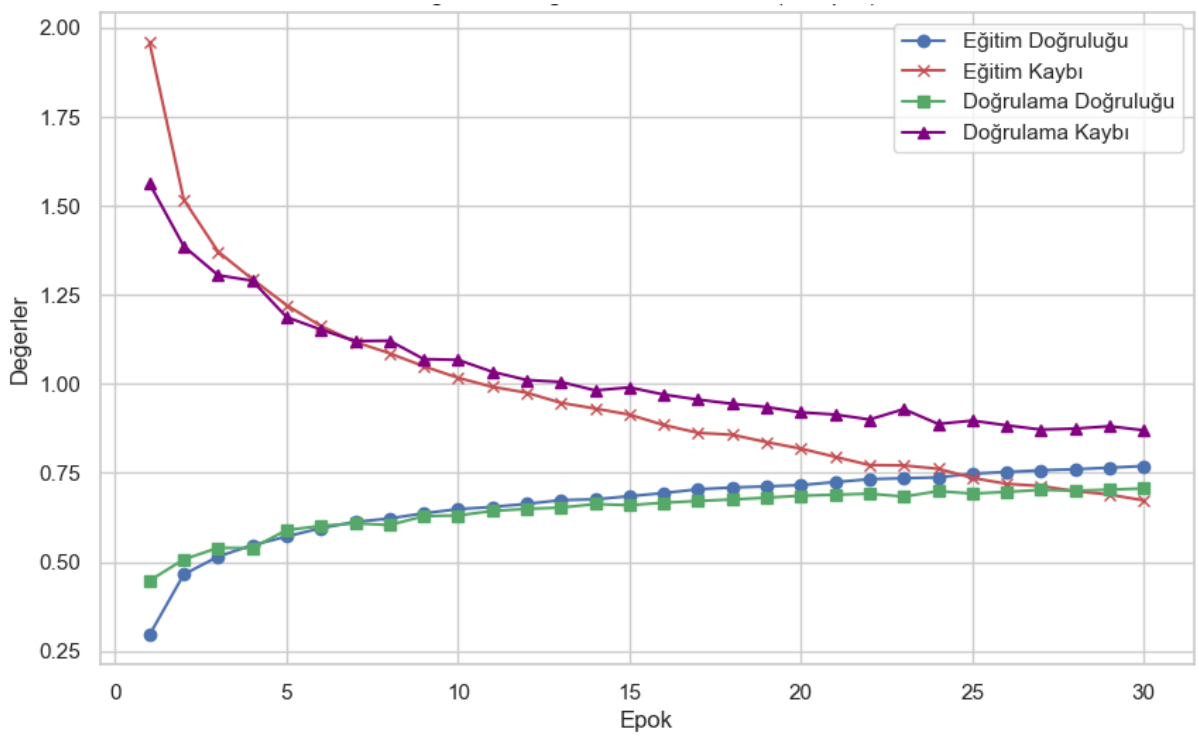

Şekil 3: CNN model için ELU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

D. CNN modelinde GELU AF Performansı

Tablo 4 ile CNN modelin GELU AF performansı verilmiştir.

Tablo 4: CNN modelin GELU AF performansı

Epok	**Ortalama Eğitim Doğruluğu**	**Ortalama Eğitim Kaybı**	**Ortalama Doğrulama Doğruluğu**	**Ortalama Doğrulama Kaybı**
1	0.2647	2.0237	0.3972	1.6631
2	0.4206	1.6124	0.4595	1.5039
3	0.4663	1.4892	0.4977	1.4127
4	0.4977	1.4013	0.5083	1.3683
5	0.5254	1.3435	0.5337	1.3085
6	0.5389	1.3075	0.54	1.2897
7	0.5531	1.2711	0.5626	1.2546
8	0.5674	1.2272	0.5732	1.2117
9	0.5832	1.1869	0.579	1.1911
10	0.5967	1.1591	0.5937	1.1583
11	0.6107	1.1186	0.6089	1.1201
12	0.6203	1.0864	0.6096	1.1104
13	0.632	1.0569	0.619	1.0915
14	0.6385	1.0369	0.6236	1.0725
15	0.6504	1.0021	0.6309	1.0566
16	0.6562	0.9849	0.6343	1.0372
17	0.6657	0.957	0.6429	1.0253
18	0.6701	0.9415	0.65	1.0083
19	0.6782	0.9249	0.6527	1.0005

20	0.6888	0.8946	0.6546	0.9886
21	0.6954	0.8785	0.656	0.9899
22	0.6975	0.8676	0.6605	0.9812
23	0.704	0.8492	0.6709	0.9628
24	0.7078	0.836	0.6654	0.9737
25	0.7199	0.815	0.6738	0.9462
26	0.7224	0.8041	0.6765	0.9472
27	0.7312	0.7753	0.6709	0.9527
28	0.732	0.7787	0.6686	0.9647
29	0.7366	0.758	0.6771	0.9479
30	0.7467	0.7401	0.6705	0.9574

Tablo 4 incelendiğinde CNN modelinde GELU AF performansı görünmektedir. Başlangıçta eğitim doğruluğu %26, eğitim kaybının ise 2.02 seviyesinde olduğu görünmektedir. Son epokta eğitim doğruluğu %74'e ulaştığı, eğitim kaybı ise 0.74'e düştüğü görünmektedir. Eğitim doğruluğu istikrarlı bir şekilde artmakta, eğitim kaybı ise sürekli azalmaktadır. Modelin eğitim setindeki veriyi iyi bir şekilde öğrendiği görünmektedir. Başlangıçta doğrulama doğruluğu %39 ve doğrulama kaybının ise 1.66 olduğu görünmektedir. En yüksek doğrulama doğruluğu %67 civarında iken son epokta doğrulama doğruluğu %67 civarında sabit kalmakta ve doğrulama kaybı %0.95 seviyesinde olduğu görünmektedir. 24. epoktan itibaren doğrulama doğruluğu çok az değişmekte, bu da modelin doğrulama setinde ilerlemesinin yavaşladığını göstermektedir. İlk 10 epok boyunca modelin doğruluk değerleri hızla artmaktadır (%39 → %59). 10-20. epok arasında model yavaşlamaya başlamakta ve %65 seviyelerinde bir plato oluşmaktadır. 20-30. epok arasında eğitim doğruluğu artmaya devam etse de, doğrulama doğruluğundaki artış çok küçük olmaktadır. 26. epoktan sonra doğrulama doğruluğu dalgalanmaya başlamakta ve artış durmaktadır. Şekil 4 ile CNN model için GELU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

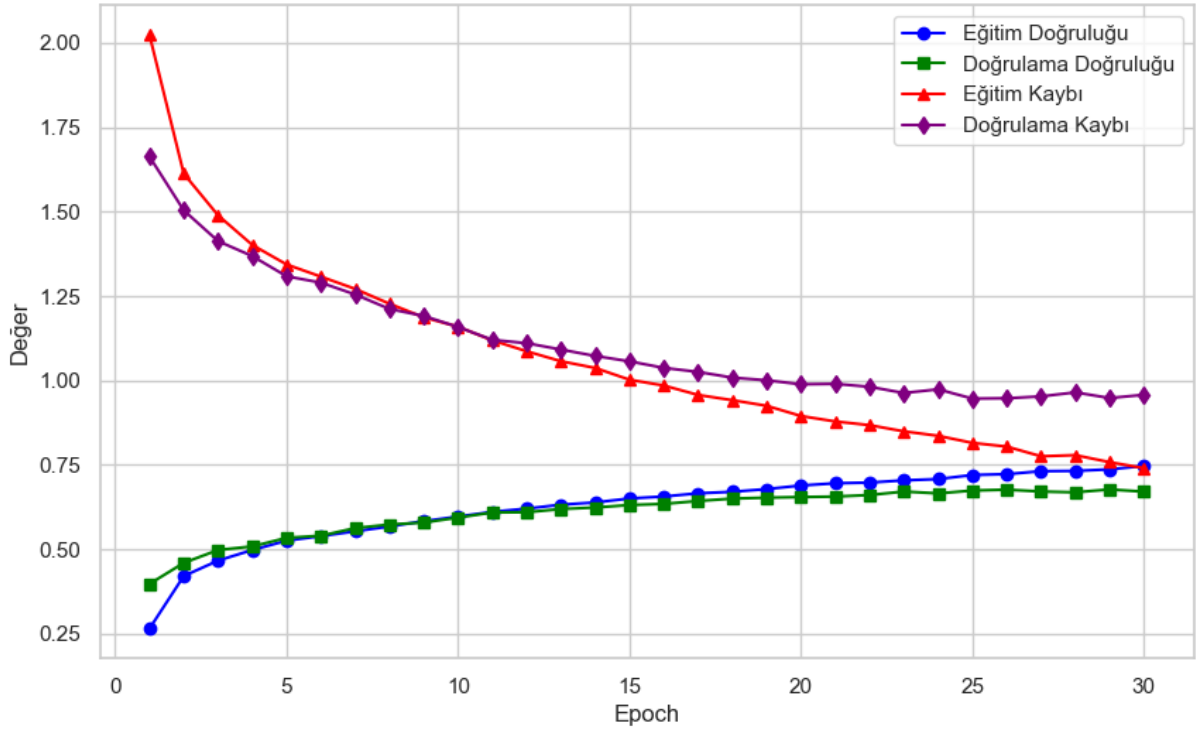

Şekil 4: CNN model için GELU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

E. CNN modelinde Mish AF Performansı

Tablo 5 ile CNN modelin Mish AF performansı verilmiştir.

Tablo 5: CNN modelin Mish AF performansı

Epok	Ortalama Eğitim Doğruluğu	Ortalama Eğitim Kaybı	Ortalama Doğrulama Doğruluğu	Ortalama Doğrulama Kaybı
1	0.2707	2.0135	0.4267	1.6176
2	0.4309	1.5749	0.4796	1.4676
3	0.4794	1.4592	0.5028	1.3903
4	0.5057	1.3857	0.5241	1.3456
5	0.5269	1.3293	0.5396	1.2926
6	0.5428	1.2888	0.5548	1.2579
7	0.5685	1.2318	0.5656	1.2201
8	0.5773	1.1927	0.5788	1.1893
9	0.5958	1.1533	0.5924	1.1609
10	0.6085	1.1261	0.6024	1.1328
11	0.6202	1.095	0.6086	1.1054
12	0.625	1.0672	0.6164	1.0876
13	0.6382	1.0461	0.6258	1.0644
14	0.6481	1.0106	0.6294	1.0563
15	0.6579	0.9829	0.6384	1.0255
16	0.666	0.956	0.6435	1.0148
17	0.6756	0.9339	0.6541	0.9969
18	0.6825	0.9168	0.6354	1.0181
19	0.6856	0.8989	0.6608	0.9771
20	0.6912	0.8801	0.6611	0.9721
21	0.7015	0.8685	0.6618	0.9708
22	0.7062	0.8419	0.6694	0.9514
23	0.7145	0.8256	0.6684	0.9588
24	0.7181	0.8154	0.6612	0.9794
25	0.7195	0.8011	0.6771	0.936
26	0.7274	0.788	0.6746	0.9363
27	0.739	0.7563	0.6792	0.939
28	0.7417	0.7422	0.6836	0.9293
29	0.7466	0.7322	0.6834	0.922
30	0.7555	0.709	0.6827	0.9294

Tablo 5 incelendiğinde CNN modelinde Mish AF performansı görünmektedir. Başlangıçta eğitim doğruluğu %27, eğitim kaybının 2.01 seviyesinde olduğu görünmektedir. Son epokta eğitim doğruluğu %75.6'ya ulaştığı, eğitim kaybının 0.71'e düştüğü görünmektedir. Eğitim doğruluğu istikrarlı bir şekilde artımakta ve eğitim kaybı sürekli olarak azalmaktadır. Model eğitim süreci boyunca sürekli olarak gelişmektedir. Başlangıçta (1. epok) doğrulama doğruluğu %43 ve doğrulama kaybı 1.62 olduğu görünmektedir. En yüksek doğrulama doğruluğu %68 civarında olduğu görünmektedir. Son epokta doğrulama doğruluğu %68 seviyelerinde sabit kaldığı ve doğrulama kaybının %0.93 seviyesinde olduğu görünmektedir. Doğrulama doğruluğu 28. epokta zirve yapmakta ve sonrasında çok az bir değişim

göstermektedir. İlk 10 epok boyunca modelin doğruluk değerleri hızla artmaktadır (%43 → %60). 10-20. epok arasında doğrulama doğruluğu da artmakta ve %63 seviyelerine çıkmaktadır. 20-30. epok arasında doğrulama doğruluğu %68 civarında sabit kalmakta, eğitim doğruluğu ise artmaya devam etmektedir. 28-30. epok arasında doğrulama doğruluğunda önemli bir değişim olmadığı görünmektedir. Şekil 5 ile CNN model için Mish AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

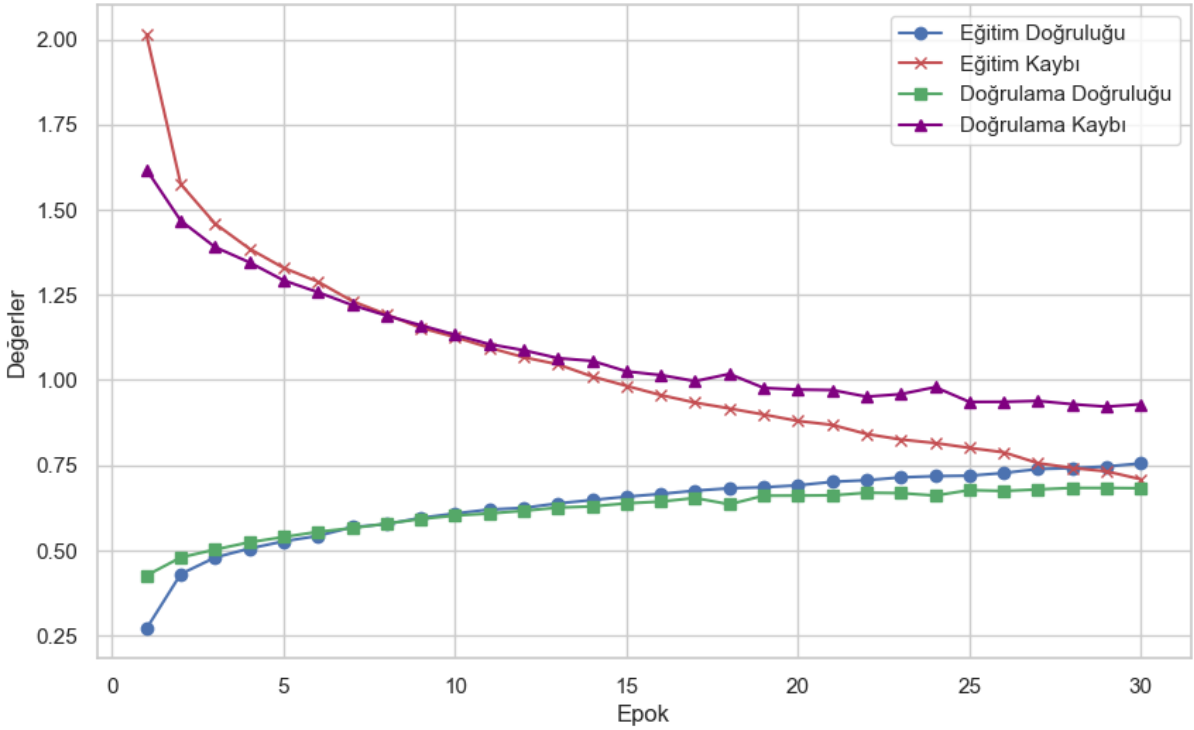

Şekil 5: CNN model için Mish AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

F. ViT modelinde ReLU AF Performansı

Tablo 6 ile ViT modelin ReLU AF performansı verilmiştir.

Tablo 6: ViT modelin ReLU AF performansı

Epok	**Ortalama Eğitim Doğruluğu**	**Ortalama Eğitim Kaybı**	**Ortalama Doğrulama Doğruluğu**	**Ortalama Doğrulama Kaybı**
1	0.2612	2.008	0.4364	1.5625
2	0.4516	1.5265	0.4908	1.4332
3	0.4983	1.4045	0.5222	1.3337
4	0.5364	1.3214	0.5437	1.2868
5	0.558	1.2623	0.5526	1.2518
6	0.5695	1.219	0.5799	1.1899
7	0.5862	1.1778	0.5781	1.188
8	0.5997	1.1477	0.5938	1.1486
9	0.6124	1.1118	0.6158	1.0946
10	0.6274	1.0745	0.6149	1.1011
11	0.6292	1.0583	0.6292	1.0658
12	0.6425	1.0288	0.6319	1.0496

13	0.6508	1.0094	0.6323	1.0503
14	0.6576	0.9842	0.6546	1.0035
15	0.6656	0.9603	0.653	0.997
16	0.6761	0.9313	0.6522	0.994
17	0.6834	0.9164	0.6521	0.9955
18	0.6934	0.8991	0.6597	0.9837
19	0.6945	0.8875	0.6709	0.959
20	0.7017	0.8712	0.6733	0.9442
21	0.7052	0.8518	0.6782	0.9326
22	0.7168	0.8282	0.6802	0.9382
23	0.7158	0.8273	0.6786	0.9376
24	0.7202	0.8053	0.6669	0.9506
25	0.7248	0.7996	0.6931	0.9
26	0.7378	0.7706	0.6854	0.9079
27	0.7384	0.7628	0.6992	0.8872
28	0.737	0.7634	0.6962	0.8946
29	0.7454	0.7415	0.7032	0.8831
30	0.7519	0.7253	0.7098	0.8615

Tablo 6 incelendiğinde ViT modelinde ReLU AF performansı görünmektedir. Başlangıçta eğitim doğruluğunun %26.1 ve eğitim kaybının 2.01 olduğu görünmektedir. Son epokta eğitim doğruluğu %75.2 ve eğitim kaybı 0.73 olmaktadır. Eğitim doğruluğu zamanla düzenli bir artış göstermekte ve eğitim kaybı ise düşüşe geçmektedir. Başlangıçta doğrulama doğruluğunun %43.6 ve doğrulama kaybının 1.56 olduğu görünmektedir. Son epokta doğrulama doğruluğu %70.98, doğrulama kaybı ise 0.86 seviyelerine inmektedir. Doğrulama doğruluğu önemli bir artış göstererek %70.98 seviyesine ulaştığı, doğrulama kaybının da azaldığı görünmektedir. İlk 10 epok boyunca model doğruluğu hızla artmaktadır (Doğruluk: %26.1 → %61.2, Kaybı: 2.01 → 1.07). 10-20. epoklar arasında doğrulama doğruluğu %61.2 → %69.4 seviyelerine çıkarken eğitim doğruluğu da hızlı bir şekilde artmaya devam etmektedir. 20-30. epoklar arasında eğitim doğruluğu %75.2 seviyesine ulaşırken doğrulama doğruluğu %70.98'e çıkmakta ve her iki metrik de stabil kalmaktadır. Şekil 6 ile ViT model için ReLU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

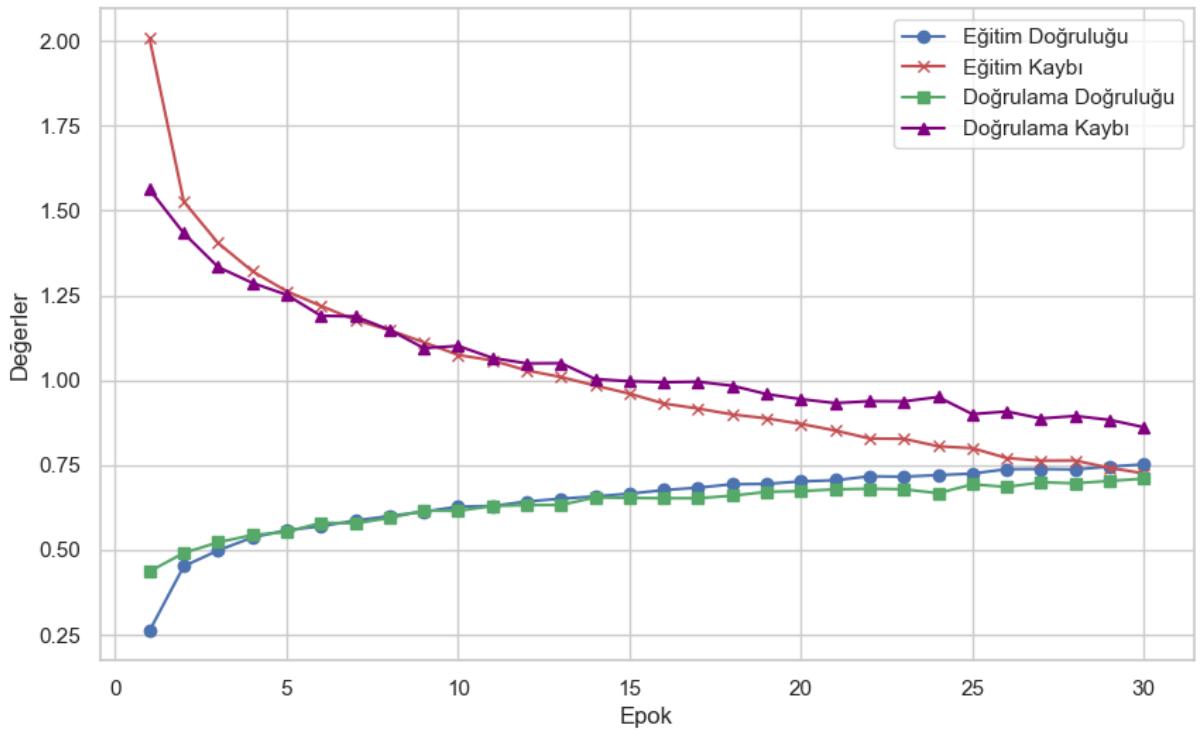

Şekil 6: ViT model için ReLU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

G. ViT modelinde LReLU AF Performansı

Tablo 7 ile ViT modelin LReLU AF performansı verilmiştir.

Tablo 7: ViT modelin LReLU AF performansı

Epok	**Ortalama Eğitim Doğruluğu**	**Ortalama Eğitim Kaybı**	**Ortalama Doğrulama Doğruluğu**	**Ortalama Doğrulama Kaybı**
1	0.1147	2.396028571	0.1529	2.203214286
2	0.160028571	2.195657143	0.219271429	2.017157143
3	0.211971429	2.047671429	0.276657143	1.894714286
4	0.264671429	1.929085714	0.347214286	1.752557143
5	0.317842857	1.8172	0.377842857	1.656771429
6	0.354128571	1.729485714	0.410414286	1.586514286
7	0.389571429	1.650471429	0.4419	1.524228571
8	0.415114286	1.597885714	0.466142857	1.467285714
9	0.436957143	1.548971429	0.4867	1.418871429
10	0.438114286	1.616414286	0.440585714	1.541357143
11	0.416628571	1.600771429	0.476957143	1.453485714
12	0.431928571	1.567371429	0.487114286	1.409671429
13	0.461885714	1.490171429	0.509085714	1.361742857
14	0.475228571	1.460285714	0.514228571	1.347242857
15	0.488428571	1.426928571	0.531671429	1.295242857
16	0.4985	1.396557143	0.5398	1.278385714
17	0.510528571	1.367514286	0.545171429	1.260928571
18	0.516357143	1.349171429	0.560028571	1.227342857

19	0.526528571	1.326457143	0.563314286	1.214514286
20	0.5337	1.305585714	0.566585714	1.208557143
21	0.539642857	1.291057143	0.578271429	1.178571429
22	0.547114286	1.266528571	0.581085714	1.173028571
23	0.550428571	1.264528571	0.571342857	1.192185714
24	0.544771429	1.275714286	0.578885714	1.1757
25	0.557328571	1.246357143	0.595328571	1.128457143
26	0.558828571	1.2385	0.598228571	1.1264
27	0.5695	1.210942857	0.606271429	1.100628571
28	0.577257143	1.191971429	0.607814286	1.095957143
29	0.581885714	1.179442857	0.615385714	1.077571429
30	0.5866	1.164414286	0.618342857	1.0738

Tablo 7 incelendiğinde ViT modelinde LReLU AF performansı görünmektedir. Eğitim doğruluğu %11.5 ve eğitim kaybı 2.40 seviyesinde olduğu görünmektedir. Son epokta eğitim doğruluğu %58.7 ve eğitim kaybı 1.16 olmaktadır. Eğitim doğruluğu zamanla sürekli bir artış göstermekte ve eğitim kaybı da azalma eğiliminde olduğu görünmektedir. Model eğitim süreci boyunca gelişim göstermektedir. Başlangıçta doğrulama doğruluğu %15.3 ve doğrulama kaybı 2.20 seviyesinde olmaktadır. son epokta doğrulama doğruluğu %61.8, doğrulama kaybı ise 1.07 seviyelerine düştüğü görünmektedir. Doğrulama doğruluğu başlangıçtaki düşük seviyeden %61.8 seviyelerine ulaşmakta ve doğrulama kaybı ise sürekli azalmaktadır. İlk 10 epok boyunca model doğruluğu hızla artmaktadır (Doğruluk: %11 → %43, Kaybı: 2.40 → 1.55). 10-20. epoklar arasında doğrulama doğruluğu %50 seviyelerine yaklaşırken eğitim doğruluğu da hızla artmaktadır. 20-30. epok arasında eğitim doğruluğu %58'e çıkarken, doğrulama doğruluğu %61.8'e ulaşmakta ve daha sonra ise stabil hale geldiği görünmektedir. 30. epokta modelin doğrulama doğruluğu %61.8'de, eğitim doğruluğu ise %58.6'ya ulaşmaktadır. Şekil 7 ile ViT model için LReLU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

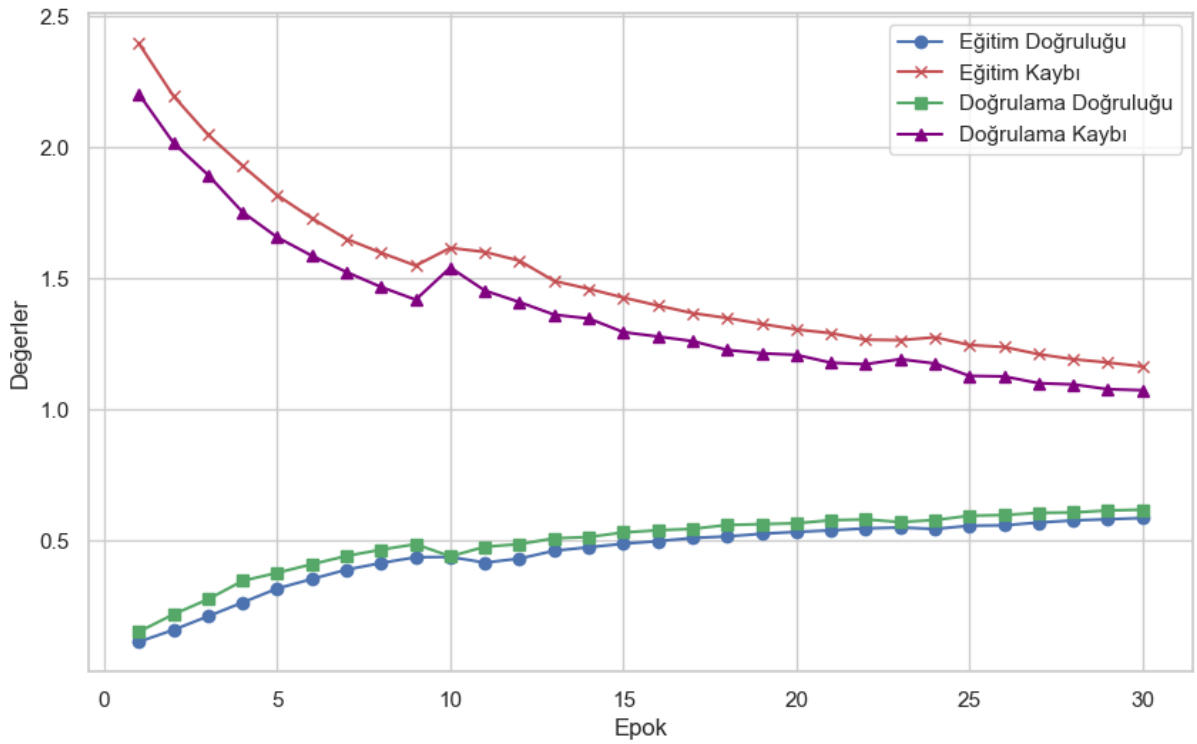

Şekil 7: ViT model için LReLU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

H. ViT modelinde ELU AF Performansı

Tablo 8 ile ViT modelin ELU AF performansı verilmiştir.

Tablo 8: ViT modelin ELU AF performansı

Epok	Ortalama Eğitim Doğruluğu	Ortalama Eğitim Kaybı	Ortalama Doğrulama Doğruluğu	Ortalama Doğrulama Kaybı
1	0.1937	2.7925	0.4313	1.5771
2	0.333	2.0282	0.4899	1.4275
3	0.4039	1.7531	0.5338	1.2931
4	0.4447	1.5826	0.5572	1.2202
5	0.4965	1.4315	0.5619	1.2209
6	0.5169	1.3616	0.5776	1.1687
7	0.5425	1.2791	0.5883	1.1584
8	0.5577	1.2412	0.5795	1.1726
9	0.5694	1.1992	0.6129	1.0777
10	0.5848	1.1555	0.6245	1.0438
11	0.6034	1.1207	0.6238	1.0462
12	0.6083	1.1016	0.6412	0.9967
13	0.6159	1.0779	0.6455	0.9787
14	0.6247	1.056	0.6535	0.9522
15	0.6279	1.0391	0.6567	0.9604
16	0.64	1.0087	0.6436	1.0053
17	0.6443	1.0024	0.6593	0.9574
18	0.6527	0.9776	0.6658	0.9193
19	0.6602	0.9613	0.6707	0.9301
20	0.6642	0.9491	0.6782	0.897
21	0.6717	0.9334	0.6746	0.9091
22	0.6702	0.9285	0.6758	0.9011
23	0.6817	0.9031	0.6994	0.8525
24	0.6844	0.8929	0.6869	0.8668
25	0.6828	0.8888	0.6955	0.8713
26	0.6892	0.8737	0.7009	0.8394
27	0.69	0.8701	0.6997	0.8544
28	0.6957	0.8576	0.7037	0.8394
29	0.7049	0.8445	0.6968	0.863
30	0.7041	0.8287	0.7079	0.8204

Tablo 8 incelendiğinde ViT modelinde ELU AF performansı görünmektedir. Başlangıçta eğitim doğruluğunun %19.37 ve eğitim kaybının 2.7925 olduğu görünmektedir. Son epokta eğitim doğruluğu %70.41 ve eğitim kaybı 0.8287 olmaktadır. Eğitim doğruluğu hızla artmakta ve eğitim kaybı düşmektedir. Başlangıçta doğrulama doğruluğu %43.13 ve doğrulama kaybı 1.5771 olmaktadır. Son epokta doğrulama doğruluğu %70.79, doğrulama kaybı ise 0.8204 seviyelerine inmektedir. Doğrulama

doğruluğu, eğitim doğruluğuna yaklaşmakta ve doğrulama kaybı da önemli ölçüde azalmaktadır. İlk 10 epok boyunca model doğruluğu hızla artmaktadır (Doğruluk: %19.37 → %58.48, Kaybı: 2.79 → 1.16). 10-20. epoklar arasında doğrulama doğruluğu %58.48 → %66.42 seviyelerine çıkarken eğitim doğruluğu da hızla artmaya devam ettiği görünmektedir. 20-30. epoklar arasında eğitim doğruluğu %70.41 seviyesine ulaşırken doğrulama doğruluğu %70.79'a çıkmaktadır. Şekil 8 ile ViT model için ELU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

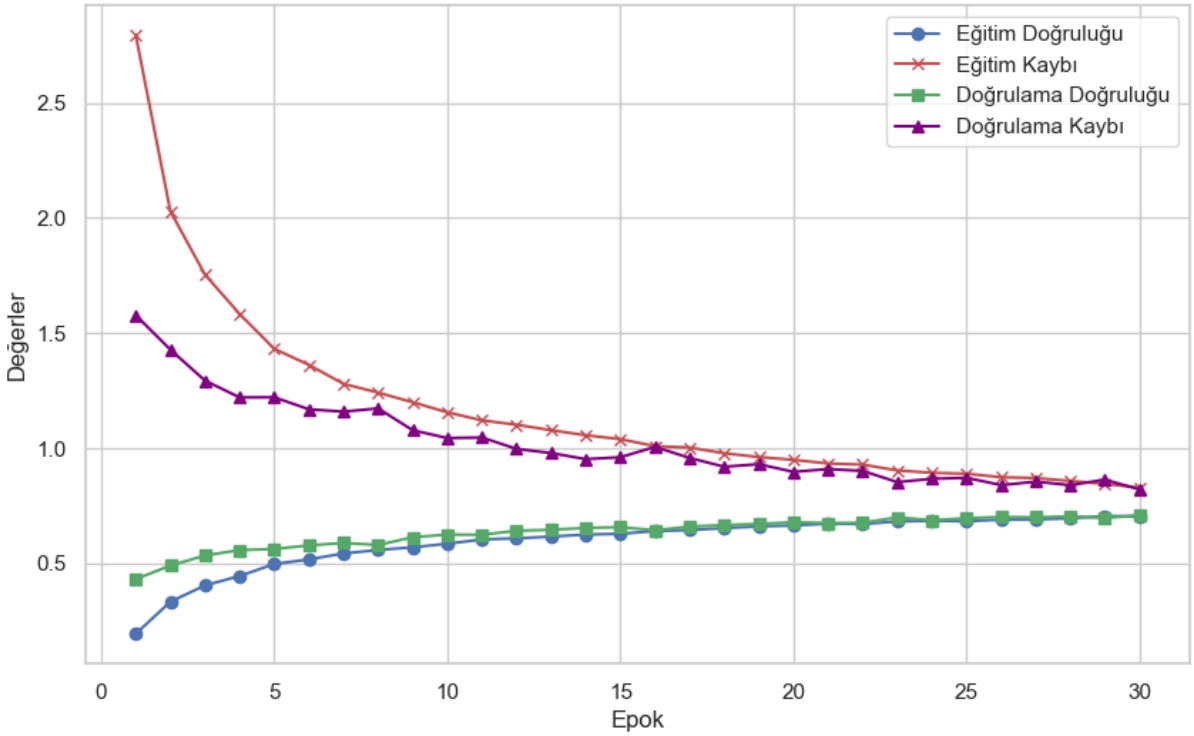

Şekil 8: ViT model için Elu AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

İ. ViT modelinde GELU AF Performansı

Tablo 9 ile ViT modelin GELU AF performansı verilmiştir.

Tablo 9: ViT modelin GELU AF performansı

Epok	Ortalama Eğitim Doğruluğu	Ortalama Eğitim Kaybı	Ortalama Doğrulama Doğruluğu	Ortalama Doğrulama Kaybı
1	0.1622	2.36	0.3397	1.8263
2	0.2967	1.9185	0.4111	1.6273
3	0.349	1.7782	0.4545	1.5065
4	0.3907	1.6701	0.4654	1.5052
5	0.4239	1.5952	0.5064	1.3545
6	0.4452	1.5417	0.5096	1.3192
7	0.465	1.4871	0.5501	1.2772
8	0.4837	1.4422	0.5524	1.2313
9	0.4983	1.4066	0.5607	1.2086
10	0.5139	1.3664	0.5644	1.1981
11	0.5231	1.3416	0.5776	1.1759

12	0.5284	1.3207	0.5883	1.1412
13	0.5442	1.2847	0.5955	1.1306
14	0.551	1.2719	0.5917	1.1266
15	0.5657	1.2401	0.6025	1.1049
16	0.5647	1.232	0.6062	1.0916
17	0.5778	1.2004	0.6035	1.0953
18	0.5807	1.185	0.6148	1.0702
19	0.5861	1.1721	0.6206	1.0517
20	0.5973	1.1565	0.6172	1.0617
21	0.6059	1.1266	0.6339	1.024
22	0.6081	1.1177	0.6327	1.0207
23	0.6145	1.1008	0.6408	1.0087
24	0.6198	1.0866	0.6447	0.9955
25	0.6203	1.0819	0.6453	0.9903
26	0.6296	1.0565	0.6431	0.9949
27	0.6334	1.0498	0.6514	0.9733
28	0.6396	1.0344	0.6558	0.9644
29	0.637	1.0327	0.6558	0.9688
30	0.6429	1.0254	0.6643	0.9449

Tablo 9 incelendiğinde ViT modelinde GELU AF performansı görünmektedir. Başlangıçta eğitim doğruluğu %16.2 ve eğitim kaybı 2.36 olmaktadır. Son epokta eğitim doğruluğunun %64.3 ve eğitim kaybının 1.03 olduğu görünmektedir. Eğitim doğruluğu zamanla artmakta, eğitim kaybı ise sürekli olarak düşmektedir. Başlangıçta doğrulama doğruluğunun %33.97 ve doğrulama kaybının 1.83 olduğu görünmektedir. Son epokta doğrulama doğruluğu %66.43, doğrulama kaybı ise 0.94 seviyelerine inmektedir. Doğrulama doğruluğunun, eğitim doğruluğuna yakın bir seviyeye çıktığı ve doğrulama kaybınun da önemli ölçüde düştüğü görünmektedir. İlk 10 epok boyunca model doğruluğu hızla artmaktadır (Doğruluk: %16.2 → %51.39, Kaybı: 2.36 → 1.37). 10-20. epok arasında doğrulama doğruluğu %51.39 → %61.72 seviyelerine çıkarken eğitim doğruluğu da hızlı bir şekilde artmaya devam etmektedir. 20-30. epok arasında eğitim doğruluğu %64.3 seviyesine ulaşırken doğrulama doğruluğu %66.43'e çıkmakta ve her iki metrik de sabit hale gelmektedir. Şekil 9 ile ViT model için GELU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

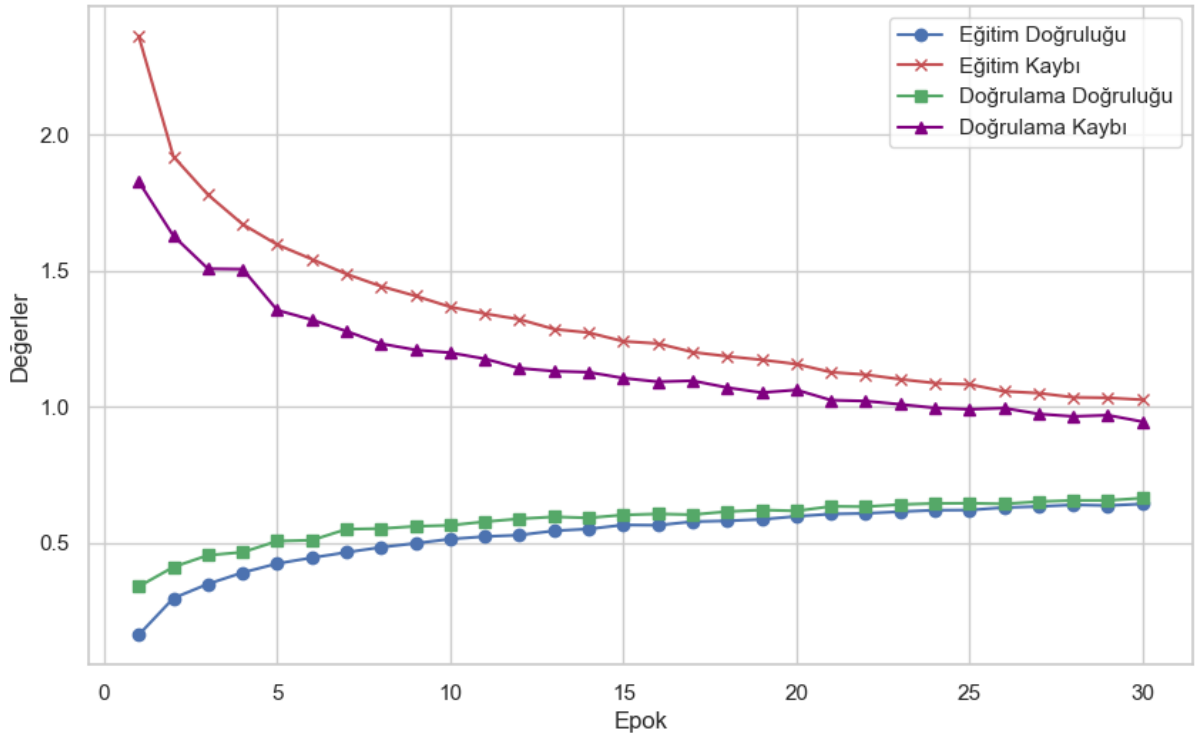

Şekil 9: ViT model için GELU AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

J. *ViT modelinde Mish AF Performansı*

Tablo 10 ile ViT modelin Mish AF performansı verilmiştir.

Tablo 10: ViT modelin Mish AF performansı

Epok	Ortalama Eğitim Doğruluğu	Ortalama Eğitim Kaybı	Ortalama Doğrulama Doğruluğu	Ortalama Doğrulama Kaybı
1	0.1764	2.3136	0.3625	1.7749
2	0.3125	1.8614	0.4248	1.6058
3	0.3775	1.7141	0.4741	1.4394
4	0.4256	1.609	0.5081	1.3611
5	0.4616	1.5179	0.5198	1.3135
6	0.4888	1.4537	0.5391	1.2734
7	0.5051	1.3907	0.5481	1.2453
8	0.5293	1.3383	0.5627	1.1928
9	0.5458	1.296	0.5746	1.1877
10	0.5609	1.2504	0.5866	1.1586
11	0.5718	1.216	0.6024	1.1138
12	0.5866	1.1849	0.6111	1.0864
13	0.5937	1.163	0.6165	1.0789
14	0.6035	1.141	0.6081	1.0847
15	0.6105	1.1124	0.6148	1.0767
16	0.6152	1.0948	0.6213	1.0557
17	0.6251	1.0701	0.6456	0.9975
18	0.6288	1.0595	0.6419	1.0009
19	0.6393	1.0392	0.6437	0.9935

20	0.6451	1.0117	0.6464	0.9936
21	0.6537	0.9938	0.6541	0.9624
22	0.6602	0.977	0.6614	0.9457
23	0.6622	0.9675	0.6609	0.9557
24	0.6633	0.9612	0.6544	0.9851
25	0.6692	0.9443	0.6646	0.9356
26	0.6744	0.9348	0.6633	0.9426
27	0.672	0.9354	0.6745	0.9174
28	0.6815	0.9193	0.6832	0.8906
29	0.6834	0.9039	0.6848	0.8909
30	0.6898	0.8961	0.6855	0.8874

Tablo 10 incelendiğinde ViT modelinde Mish AF performansı görünmektedir. Başlangıçta eğitim doğruluğunun %17.64 ve eğitim kaybının 2.3136 olduğu görünmektedir. Son epokta eğitim doğruluğu %68.98 ve eğitim kaybı 0.8961 olmaktadır. Eğitim doğruluğu zamanla artmakta, eğitim kaybı ise düşmektedir. Başlangıçta doğrulama doğruluğu %36.25 ve doğrulama kaybı 1.7749 olmaktadır. Son epokta doğrulama doğruluğu %68.55, doğrulama kaybı ise 0.8874 seviyelerine inmektedir. Doğrulama doğruluğu, eğitim doğruluğuna yakın bir seviyeye çıkmakta ve doğrulama kaybı da önemli ölçüde düşmektedir. İlk 10 epok boyunca model doğruluğu hızla artmaktadır (Doğruluk: %17.64 → %56.09, Kaybı: 2.31 → 1.25). 10-20. epoklar arasında doğrulama doğruluğu %56.09 → %64.51 seviyelerine çıkarken eğitim doğruluğu da hızla artmaya devam etmektedir. 20-30. epok arasında eğitim doğruluğu %68.98 seviyesine ulaşırken doğrulama doğruluğu %68.55'e çıkmakta ve her iki metrik de sabit hale gelmektedir. Şekil 10 ile ViT model için Mish AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli verilmiştir.

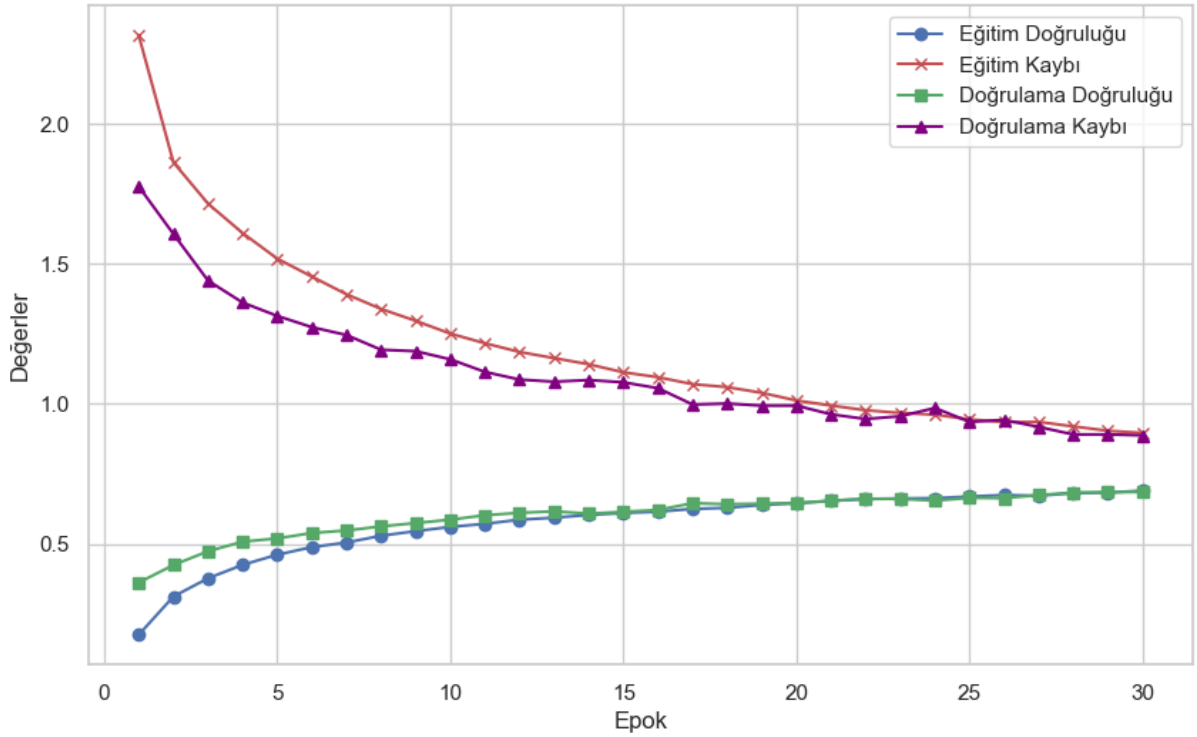

Şekil 10: ViT model için Mish AF eğitim ve doğrulama doğruluğu ile eğitim ve doğrulama kaybı görseli

.

IV. SONUÇLAR

Araştırma kapsamında yapılan çalışmada CNN ve ViT modelleri kullanılarak 5 farklı çalıştırma ve 30 epok sonucunda elde edilen ortalama eğitim ve doğrulama doğrulukları ile ortalama eğitim ve doğrulama kayıpları değerleri kullanılan beş farklı aktivasyon fonksiyonuna göre Tablo 11 ile özet olarak verilmiştir.

Tablo 11: CNN ve ViT modellerin AF karşılaştırması

Model Adı	**AF Adı**	**Ortalama Eğitim Doğruluğu**	**Ortalama Eğitim Kaybı**	**Ortalama Doğrulama Doğruluğu**	**Ortalama Doğrulama Kaybı**
CNN	ReLU	0.65188	0.99893333	0.64115667	1.03066667
	LReLU	**0.86356667**	**0.38502133**	**0.69312933**	1.428956
	ELU	0.66242	0.97120333	0.64339333	1.03039333
	GELU	0.62394667	1.07094	0.60872	1.11655333
	Mish	0.63222667	1.04743333	0.61605667	1.09484333
ViT	ReLU	0.64296	1.02252667	0.63094	1.05753667
	LReLU	0.45253905	1.50497143	0.49548476	1.38140286
	ELU	0.59531333	1.16467333	0.63454667	**1.02069**
	GELU	0.52995667	1.32278	0.58	1.16631333
	Mish	0.57376	1.20903333	0.60129667	1.11158667

Tablo 11 incelendiğinde CNN modellerin ViT modellerine kıyasla genellikle daha yüksek eğitim doğruluğuna ulaştığı görülmektedir. Leaky ReLU (LReLU), CNN için en yüksek eğitim doğruluğunu sağlamış (%86,35), ancak doğrulama doğruluğu %69,31 olup overfitting (aşırı öğrenme) ihtimali olabileceği düşünülmektedir. ViT modelleri genel olarak daha düşük eğitim doğruluğuna sahip, ancak bazı aktivasyon fonksiyonları (ELU, Mish) doğrulama doğruluğunda nispeten başarılı oldukları görülmektedir. Aktivasyon fonksiyonlarının etkisi açısından bakıldığında Leaky ReLU (LReLU) CNN modelinde en iyi eğitim doğruluğunu (%86,35) verse de, doğrulama kaybı (1.42) ile diğerlerine göre oldukça yüksek, yani genelleme sorunu olabileceği düşünülmektedir. GELU ve Mish, her iki modelde de orta seviye doğruluk değerleri sunmuş ancak kayıpları nispeten yüksek olduğu düşünülmektedir. ELU, özellikle ViT modeli için en iyi doğrulama doğruluğunu sağladığı görülmektedir (%63,45). ReLU, CNN için en iyi doğrulama doğruluğunu sağladığı görülmektedir. (%64,11). Aşırı öğrenme ve yetersiz öğrenme durumu açısından değerlendirildiğinde ise CNN LReLU modelinin eğitim doğruluğu çok yüksek (%86,35) ancak doğrulama doğruluğu %69,31, ayrıca doğrulama kaybı en yüksek seviyede (1.42) olduğundan aşırı öğrenmiş olabileceği düşünülmektedir. ViT GELU ve ViT Mish modelleri eğitim doğruluğu düşük ve doğrulama doğruluğu yeterince iyi olmadığı için yetersiz öğrenme yaşıyor olabileceği düşünülmektedir. Şekil 11 ile çalışma kapsamında kullanılan aktivasyon fonksiyonlarının CNN ve ViT model üzerindeki eğitim ve doğrulama doğrulukları, Şekil 12 ile çalışma kapsamında kullanılan aktivasyon fonksiyonlarının CNN ve ViT model üzerindeki eğitim ve doğrulama kayıpları görselleri verilmiştir.

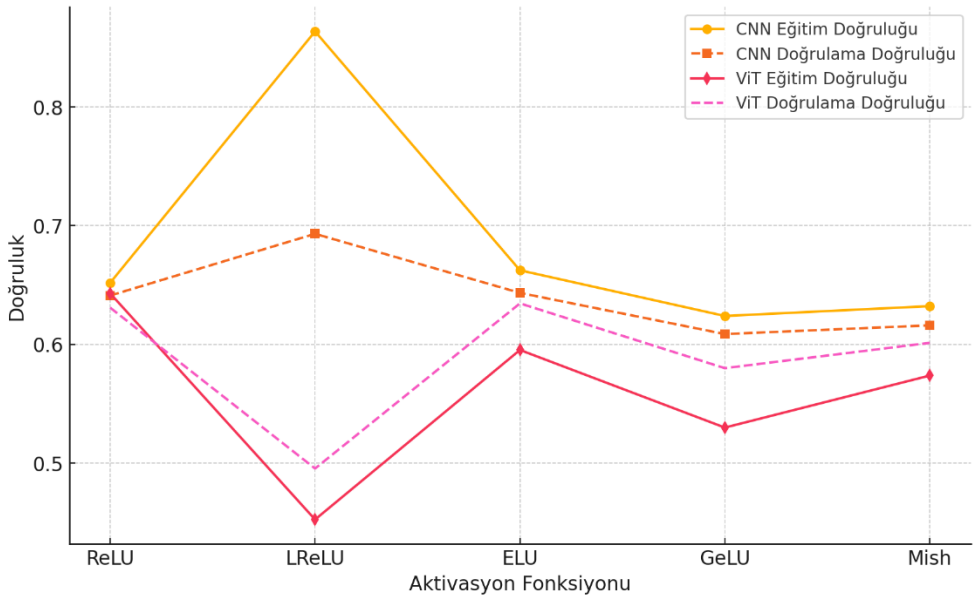

Şekil 11: Kullanılan aktivasyon fonksiyonlarının CNN ve ViT üzerindeki doğrulukları

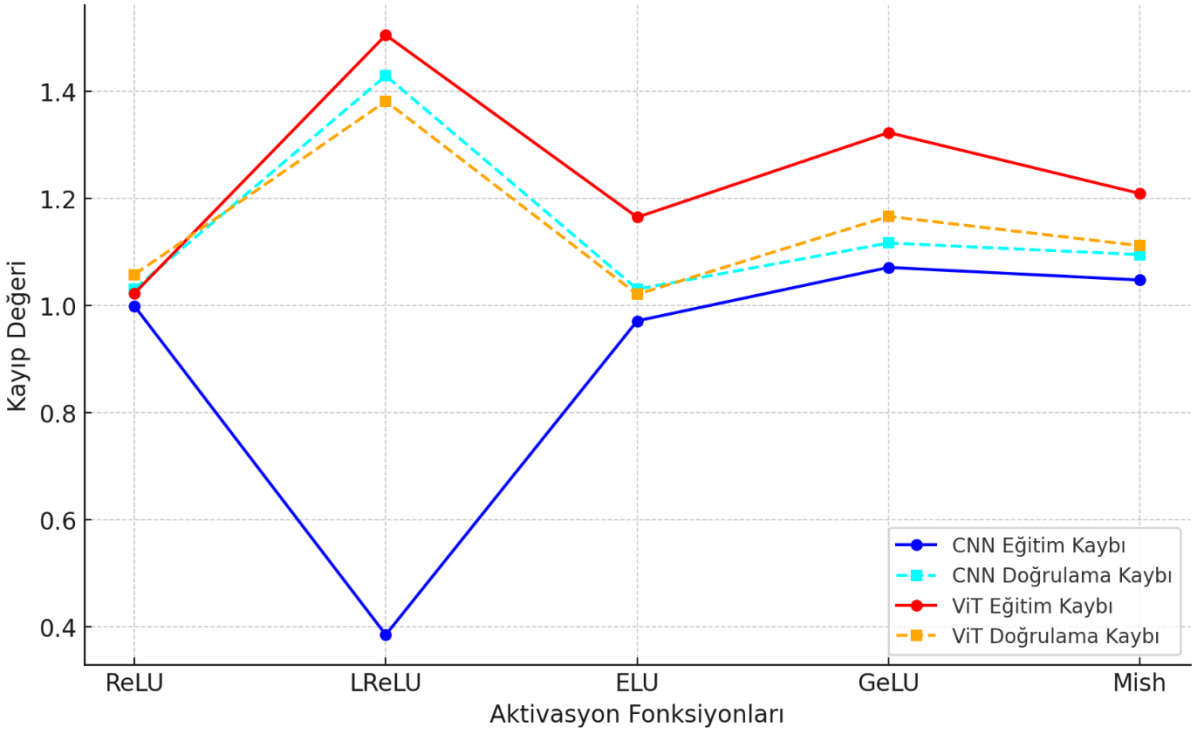

Şekil 12: Kullanılan aktivasyon fonksiyonlarının CNN ve ViT üzerindeki kayıpları

KAYNAKLAR

[1] Y. Zheng, J. Huang, T. Chen, Y. Ou, ve W. Zhou, "CNN classification based on global and local features", içinde *Real-Time Image Processing and Deep Learning 2019*, SPIE, May. 2019, ss. 96-108. doi: 10.1117/12.2519660.

[2] L. Bao, B. Ma, H. Chang, ve X. Chen, "Preserving Structural Relationships for Person Re-Identification", içinde *2019 IEEE International Conference on Multimedia & Expo Workshops (ICMEW)*, Tem. 2019, ss. 120-125. doi: 10.1109/ICMEW.2019.00028.

[3] M. Hussain, J. J. Bird, ve D. R. Faria, “A Study on CNN Transfer Learning for Image Classification”, içinde *Advances in Computational Intelligence Systems*, A. Lotfi, H. Bouchachia, A. Gegov, C. Langensiepen, ve M. McGinnity, Ed., Cham: Springer International Publishing, 2019, ss. 191-202. doi: 10.1007/978-3-319-97982-3_16.

[4] X. Xie, G. Cheng, J. Wang, X. Yao, ve J. Han, “Oriented R-CNN for Object Detection”, program adı: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021, ss. 3520-3529. Erişim: 26 Şubat 2025. [Çevrimiçi]. Erişim adresi: https://openaccess.thecvf.com/content/ICCV2021/html/Xie_Oriented_R-CNN_for_Object_Detection_ICCV_2021_paper.html

[5] A. Gillioz, J. Casas, E. Mugellini, ve O. A. Khaled, “Overview of the Transformer-based Models for NLP Tasks”, içinde *2020 15th Conference on Computer Science and Information Systems (FedCSIS)*, Eyl. 2020, ss. 179-183. doi: 10.15439/2020F20.

[6] H. Chen *vd.*, “Pre-Trained Image Processing Transformer”, program adı: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021, ss. 12299-12310. Erişim: 26 Şubat 2025. [Çevrimiçi]. Erişim adresi: https://openaccess.thecvf.com/content/CVPR2021/html/Chen_Pre-Trained_Image_Processing_Transformer_CVPR_2021_paper.html

[7] H. Yin, A. Vahdat, J. M. Alvarez, A. Mallya, J. Kautz, ve P. Molchanov, “A-ViT: Adaptive Tokens for Efficient Vision Transformer”, program adı: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, ss. 10809-10818. Erişim: 26 Şubat 2025. [Çevrimiçi]. Erişim adresi: https://openaccess.thecvf.com/content/CVPR2022/html/Yin_A-ViT_Adaptive_Tokens_for_Efficient_Vision_Transformer_CVPR_2022_paper.html?ref=https://githubhelp.com

[8] Y. Lecun, L. Bottou, Y. Bengio, ve P. Haffner, “Gradient-based learning applied to document recognition”, *Proc. IEEE*, c. 86, sy 11, ss. 2278-2324, Kas. 1998, doi: 10.1109/5.726791.

[9] “AlexNet论文翻译-ImageNet Classification with Deep Convolutional Neural Networks | the”. Erişim: 21 Şubat 2025. [Çevrimiçi]. Erişim adresi: https://www.lmlphp.com/user/57787/article/item/612167

[10] K. He, X. Zhang, S. Ren, ve J. Sun, “Identity Mappings in Deep Residual Networks”, içinde *Computer Vision – ECCV 2016*, B. Leibe, J. Matas, N. Sebe, ve M. Welling, Ed., Cham: Springer International Publishing, 2016, ss. 630-645. doi: 10.1007/978-3-319-46493-0_38.

[11] B. Koonce, “EfficientNet”, içinde *Convolutional Neural Networks with Swift for Tensorflow: Image Recognition and Dataset Categorization*, B. Koonce, Ed., Berkeley, CA: Apress, 2021, ss. 109-123. doi: 10.1007/978-1-4842-6168-2_10.

[12] A. Dosovitskiy *vd.*, “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”, 03 Haziran 2021, *arXiv*: arXiv:2010.11929. doi: 10.48550/arXiv.2010.11929.

[13] S. Jeon, “2nd Place Solution to Facebook AI Image Similarity Challenge Matching Track”, 15 Kasım 2021, *arXiv*: arXiv:2111.09113. doi: 10.48550/arXiv.2111.09113.

[14] S. Cong, H. Wang, Y. Zhou, Z. Wang, X. Yao, ve C. Yang, “Comprehensive review of Transformer-based models in neuroscience, neurology, and psychiatry”, *Brain-X*, c. 2, sy 2, s. e57, 2024, doi: 10.1002/brx2.57.

[15] Z. Liu *vd.*, “Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows”, program adı: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021, ss. 10012-10022. Erişim: 22 Şubat 2025. [Çevrimiçi]. Erişim adresi: https://openaccess.thecvf.com/content/ICCV2021/html/Liu_Swin_Transformer_Hierarchical_Vision_Transformer_Using_Shifted_Windows_ICCV_2021_paper

[16] P. B. Chopade, P. N. Kota, B. D. Jadhav, P. M. Ghate, ve S. S. Kulkarni, “Retinopathy Disease Detection and Classification Using a Coordinate Attention Module-Based Convolutional Neural Network with Leaky Rectified Linear Unit”, *IIUM Eng. J.*, c. 26, sy 1, ss. 129-147, Oca. 2025, doi: 10.31436/iiumej.v26i1.3194.

[17] Y. Tang, W. Huang, C. Chen, ve D. Chen, “CT-DCENet: Deep EEG Denoising via CNN-Transformer-based Dual-stage Collaborative Ensemble Learning”, *IEEE J. Biomed. Health Inform.*, ss. 1-14, 2025, doi: 10.1109/JBHI.2025.3535592.

[18] A. Waghumbare ve U. Singh, “Diat-separable-cnn-eca-harnet: a lightweight and explainable model for efficient human activity recognition”, *Signal Image Video Process.*, c. 19, sy 3, s. 245, Oca. 2025, doi: 10.1007/s11760-025-03838-w.

[19] R. Dasgupta, Y. S. Chowdhury, ve S. Nanda, “Performance Comparison of Benchmark Activation Function ReLU, Swish and Mish for Facial Mask Detection Using Convolutional Neural Network”, içinde *Intelligent Systems*, A. Sheth, A. Sinhal, A. Shrivastava, ve A. K. Pandey, Ed., Singapore: Springer, 2021, ss. 355-367. doi: 10.1007/978-981-16-2248-9_34.

[20] S. A. A. Fazel, “Prediction of bubble departing diameter in pool boiling of mixtures by ANN using modified ReLU”, *Heliyon*, c. 10, sy 11, Haz. 2024, doi: 10.1016/j.heliyon.2024.e31261.

[21] L. Parisi, D. Neagu, R. Ma, ve F. Campean, “Quantum ReLU activation for Convolutional Neural Networks to improve diagnosis of Parkinson’s disease and COVID-19”, *Expert Syst. Appl.*, c. 187, s. 115892, Oca. 2022, doi: 10.1016/j.eswa.2021.115892.

[22] D. Al-Alimi, Z. Cai, ve M. A. A. Al-qaness, “FHIC: Fast Hyperspectral Image Classification Model Using ETR Dimensionality Reduction and ELU Activation Function”, *IEEE Trans. Geosci. Remote Sens.*, c. 61, ss. 1-17, 2023, doi: 10.1109/TGRS.2023.3314619.

[23] S. Kovaios *vd.*, “Programmable Tanh- and ELU-Based Photonic Neurons in Optics-Informed Neural Networks”, *J. Light. Technol.*, c. 42, sy 10, ss. 3652-3660, May. 2024, doi: 10.1109/JLT.2024.3366711.

[24] C.-I. Lai, A. Abad, K. Richmond, J. Yamagishi, N. Dehak, ve S. King, “Attentive Filtering Networks for Audio Replay Attack Detection”, içinde *ICASSP 2019 - 2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, May. 2019, ss. 6316-6320. doi: 10.1109/ICASSP.2019.8682640.

[25] K. K. K ve S. Mandava, “A Novel Lightweight Customized Convolution Neural Network for Bearing Fault Classification”, içinde *2023 International Conference on Next Generation Electronics (NEleX)*, Ara. 2023, ss. 1-5. doi: 10.1109/NEleX59773.2023.10421623.

[26] C. Yañez, W. Kristjanpoller, ve M. C. Minutolo, “Stock market index prediction using transformer neural network models and frequency decomposition”, *Neural Comput. Appl.*, c. 36, sy 25, ss. 15777-15797, Eyl. 2024, doi: 10.1007/s00521-024-09931-4.

[27] S. Panigrahi, D. R. D. Adhikary, ve B. Kumar Pattanayak, “Analyzing Activation Functions With Transfer Learning-Based Layer Customization for Improved Brain Tumor Classification”, *IEEE Access*, c. 12, ss. 168707-168727, 2024, doi: 10.1109/ACCESS.2024.3497346.

[28] D. Misra, “Mish: A Self Regularized Non-Monotonic Activation Function”, 13 Ağustos 2020, *arXiv*: arXiv:1908.08681. doi: 10.48550/arXiv.1908.08681.

[29] T. Hussain ve H. Shouno, “MAGRes-UNet: Improved Medical Image Segmentation Through a Deep Learning Paradigm of Multi-Attention Gated Residual U-Net”, *IEEE Access*, c. 12, ss. 40290-40310, 2024, doi: 10.1109/ACCESS.2024.3374108.

[30] S. Chan, “The Triumvirate of Bespoke Diverse Hybridized Activation Functions, Adaptive Momentum, and Enhanced Entropic Wavelet Energy Spectrum Discernment for Higher Efficacy Detection of Artificial Intelligence-centric Attacks”, 13 Kasım 2023, *Social Science Research Network, Rochester, NY*: 4679251. doi: 10.2139/ssrn.4679251.

[31] W. Bai, G. Zhuang, X. Zhao, ve Z. Wei, “High-Precision Intelligent Identification of Complex Power Quality Disturbances Based on Improved KST and CNNs”, *IEEE Access*, c. 12, ss. 86434-86443, 2024, doi: 10.1109/ACCESS.2024.3416684.