Demiryolu Mühendisliği **Railway Engineering**
Yıl: 2026, Sayı: 24 Year: 2026, Issue: 24
Makale No: 1910383 Article No: 1910383
Araştırma Makalesi Research Article
doi: 10.47072/demiryolu.1910383
http://dergipark.org.tr/demiryolu
e-ISSN: 2687-2463, ISSN: 2149-1607

Aşırı Sınıf Dengesizliği Altında İnce Doğrusal Yapıların Segmentasyonu: Demiryolu Veri Setlerinde Doğruluk Paradoksu ve Mimari Verimlilik

Ahmet AKKAYA

Bandırma Onyedi Eylül Üniversitesi, Gönen Meslek Yüksekokulu, Bilgisayar Teknolojileri Bölümü, Bandırma, Türkiye

aakkaya@bandirma.edu.tr

(Alınış/Received: 16.03.2026, Kabul/Accepted: 15.04.2026, Yayımlama/Published: 15.04.2025)

Öz: Otonom demiryolu sistemlerinin güvenli navigasyonu, ray hattının piksel hassasiyetinde ve kesintisiz olarak tespit edilmesine dayanmaktadır. Ancak demiryolu veri setleri, ray piksellerinin arka plana oranla çok küçük bir alanı kapladığı (~170:1) aşırı sınıf dengesizliği içermekte, bu da geleneksel metriklerin performansı hatalı değerlendirmesine yol açan "Doğruluk Paradoksu"nu ortaya çıkarmaktadır. Bu çalışmada, evrişimli sinir ağı tabanlı U-Net (ResNet-34) ile görsel dönüştürücü tabanlı Segformer (B0-B5) mimarileri, bu zorlu görevin üstesinden gelme yetenekleri bakımından karşılaştırmalı olarak analiz edilmiştir. Sayısal sonuçlar, her iki modelin de %99,8'in üzerinde doğruluk elde ettiğini gösterse de piksel bazlı karmaşıklık matrisleri ve mikro-uzamsal hata analizleri, Segformer varyantlarının yama tabanlı yapısı nedeniyle ray hatlarında kopukluklar ve yüksek oranda yanlış pozitif (FP) gürültüsü ürettiğini kanıtlamıştır. Buna karşın U-Net (R34), 24,4 milyon parametre ile kendisinden 3,5 kat daha büyük olan Segformer-B5 ile istatistiksel olarak benzer ($p>0,05$) bir performans sergilemiş; uzamsal tümevarımsal yanlılığı sayesinde hat bütünlüğünü çok daha başarılı korumuştur. Deneyler sonucunda U-Net modeli 36,70 mIoU ve 40,72 HD95 skorlarıyla, donanımsal olarak çok daha ağır olan Segformer modellerini geride bırakmıştır. Wilcoxon İşaretli Sıralar Testi sonuçları, U-Net'in düşük ölçekli ViT modellerine karşı üstünlüğünün istatistiksel olarak anlamlı olduğunu doğrulamaktadır. Çalışma sonucunda, ince-uzun yapıların segmentasyonunda model derinliğinden ziyade uzamsal sürekliliği koruyan mimari yapıların kritik öneme sahip olduğu ve parametre artışının bu görevde her zaman performans artışı sağlamadığı gösterilmiştir.

***Anahtar kelimeler**:* Demiryolu segmentasyonu, Doğruluk paradoksu, Sınıf dengesizliği, U-Net, Segformer, Uzamsal süreklilik

Segmentation of Thin Linear Structures Under Extreme Class Imbalance: Accuracy Paradox and Architectural Efficiency in Railway Datasets

Abstract: The safe navigation of autonomous railway systems relies on the continuous and pixel-level accurate detection of railway tracks. However, railway datasets inherently exhibit extreme class imbalance, where track pixels occupy a minuscule fraction of the area compared to the background (~170:1). This phenomenon leads to the "Accuracy Paradox," causing traditional metrics to misinterpret actual model performance. In this study, the convolutional neural network-based U-Net (ResNet-34) and the vision transformer-based Segformer (B0-B5) architectures are comparatively analyzed in terms of their capability to tackle this challenging task. Although numerical results indicate that both models achieve an overall accuracy of over 99.8%, pixel-based confusion matrices and micro-spatial error analyses prove that Segformer variants produce discontinuities in track lines and high rates of false positive (FP) noise due to their patch-based structure. In contrast, U-Net (R34), with its 24.4 million parameters, exhibited a statistically similar performance ($p > 0.05$) to Segformer-B5, which is 3.5 times larger. Furthermore, U-Net preserved track integrity much more successfully owing to its strong spatial inductive bias. As a result of the experiments, the U-Net model outperformed the computationally much heavier Segformer models with scores of 36.70 mIoU and 40.72 HD95. The Wilcoxon Signed-Rank Test results confirm that the superiority of U-Net over lower-scale ViT models is statistically significant. Consequently, this study demonstrates that in the segmentation of thin and linear structures, architectural designs preserving spatial continuity are of critical importance rather than mere model depth, and a massive increase in parameters does not necessarily yield a performance boost in this task, highlighting the issue of "parameter redundancy.

Atıf için/Cite as: A. Akkaya, "Aşırı sınıf dengesizliği altında ince doğrusal yapıların segmentasyonu: demiryolu veri setlerinde doğruluk paradoksu ve mimari verimlilik," *Demiryolu Mühendisliği*, sy. 24, no. 1910383, 2026, doi: 10.47072/demiryolu.1910383

***Keywords**:* Railway track segmentation, Accuracy paradox, Class imbalance, U-Net, Segformer, Spatial Continuity

1. Giriş

Demiryolu taşımacılığı, yüksek taşıma kapasitesi ve enerji verimliliği ile modern ulaşım altyapılarının omurgasını oluşturmaktadır [1]. Günümüzde artan hız ve sefer sıklıkları, demiryolu hatlarının güvenliğini ve bakımını kritik bir mühendislik problemi haline getirmiştir [2]. Özellikle otonom tren sistemlerinin geliştirilmesi ve ray hattı üzerindeki olası engellerin/hasarların gerçek zamanlı tespiti, bilgisayarlı görü algoritmalarının bu alandaki kullanımını zorunlu kılmıştır [3], [4]. Rayların çevresel koşullar (kar, yağmur, gölgelenme, taş/toprak zemin) altında doğru bir şekilde tespit edilmesi, güvenli bir otonom sürüş için ön koşuldur [5].

Geleneksel görüntü işleme yöntemleri, demiryolu tespiti gibi karmaşık ve dinamik arka planlara sahip problemlerde yetersiz kalırken, Derin Öğrenme mimarileri bu alanda etkili olmuştur [6]. Görüntü bölütleme (segmentasyon) görevlerinde standart haline gelen Evrişimli Sinir Ağları (CNN-Convolutional Neural Networks), özellikle U-Net gibi kodlayıcı-kod çözücü yapıları sayesinde büyük başarılar elde etmiştir [7]. CNN mimarilerinin sahip olduğu "tümevarımsal yanlılık" ve lokal özellik çıkarma yeteneği, raylar gibi ince, uzun ve uzamsal sürekliliği olan yapıların tespitinde onlara doğal bir avantaj sağlamaktadır [8].

Ancak son yıllarda, Doğal Dil İşleme (NLP) alanında çığır açan Transformer mimarilerinin bilgisayarlı görüye uyarlanmasıyla ortaya çıkan Görsel Dönüştürücüler (ViT-Vision Transformers), görüntü analizinde yeni bir paradigma başlatmıştır [9]. Görüntüyü yamalara bölerek "öz-dikkat" mekanizması ile işleyen bu mimariler, pikseller arasındaki uzak mesafe ilişkilerini (küresel bağlamı) modelleme konusunda CNN'leri geride bırakma iddiası taşımaktadır [10]. Segformer gibi yenilikçi ViT tabanlı modeller, birçok standart veri setinde en yüksek (SOTA) performansları sergilemiştir [11]. Nitekim, 2023-2025 yılları arasında yayımlanan güncel altyapı ve yüzey kusuru tespiti çalışmaları, CNN ve ViT mimarilerini doğrudan karşılaştırmaya başlamıştır [30], [31]. Bu araştırmalar, Segformer gibi ViT tabanlı modellerin küresel bağlamı anlamada üstün olduğunu, ancak U-Net gibi geleneksel CNN mimarilerinin ince, uzun ve yerel morfolojik kusurların sınırlarını belirlemede daha keskin sonuçlar ürettiğini vurgulamaktadır [32]. Buna rağmen, literatürdeki çalışmalar incelendiğinde, ViT mimarilerinin aşırı sınıf dengesizliği altındaki davranışları büyük ölçüde göz ardı edilmiştir [12]. Demiryolu segmentasyonu problemi, doğası gereği devasa bir dengesizlik içerir; bir görüntüdeki piksellerin %99'u arka plandan oluşurken, yalnızca %1'lik bir dilim hedef nesneyi (rayları) temsil eder.

Literatürdeki birçok çalışma, modellerin başarısını yalnızca "Doğruluk" metriği üzerinden değerlendirerek yanıltıcı sonuçlar sunmaktadır [13]. Küresel bağlama odaklanan Transformer modellerinin, azınlık sınıfını tamamen görmezden gelerek sadece arka planı tahmin etmeye yönelik bir "tembellik" veya "doğruluk paradoksu" tuzağına düşme riski, çözülmesi gereken kritik bir araştırma boşluğudur [14], [15].

Bu bağlamda bu çalışma, aşırı sınıf dengesizliğine sahip zorlu bir demiryolu veri seti üzerinde, geleneksel yerel özellik çıkarıcıları U-Net [16] ile modern küresel dikkat mekanizmaları olan Segformer-B0 [17], Segformer-B2 [18], Segformer-B3 [19] ve Segformer-B5 [20] model mimarilerini kullanarak kapsamlı bir şekilde karşılaştırmaktadır. Araştırma kapsamında yapılan çalışmada, salt başarı metriklerinin ötesine geçilerek, modellerin piksel bazlı karmaşıklık matrisleri ve donanımsal verimlilikleri üzerinden derinlemesine bir davranış analizini sunulmaktadır.

Araştırmanın literatüre sunduğu başlıca özgün katkı ve yenilikler çok boyutludur. Öncelikle, yaklaşık 6,8 milyar arka plan ve 71 milyon ray pikselinden oluşan aşırı dengesiz bir gerçek dünya veri setinde, CNN ve ViT mimarilerinin davranışsal zayıflıkları ile üstünlükleri karşılaştırılmıştır. Çalışma, yüksek kapasiteli Transformer modellerinin (Segformer-B5) %90'ın üzerinde genel doğruluk oranlarına ulaşmasına rağmen azınlık sınıfı olan ray piksellerini büyük oranda kaçırdığını deneysel olarak ispatlamış ve literatürdeki salt doğruluğa dayalı yanılgıları "Doğruluk Paradoksu" kavramı altında çürütmüştür. Ayrıca ince, uzun ve sürekli uzamsal yapılara sahip olan rayların tespitinde, CNN yapılarının sahip olduğu yerel komşuluk bilincinin (tümevarımsal yanlılık), küresel dikkat mekanizmalarına kıyasla çok daha kritik bir avantaja sahip olduğu ortaya konmuştur. Tüm bu bulgular sadece başarı oranlarıyla değil; parametre boyutları, donanımsal işlem yükleri ve yapısal sınır hassasiyetini kapsayan Pareto analizleriyle desteklenerek otonom demiryolu sistemleri için en verimli mimari standartları belirlenmiştir.

2. Metot

Bu çalışmada, aşırı sınıf dengesizliği barındıran demiryolu görüntülerinde otonom navigasyon için gerekli olan ray hattının tespiti amacıyla, Evrişimli Sinir Ağları (CNN) ve Görsel Dönüştürücüler (ViT) mimarilerini temel alan kapsamlı bir segmentasyon metodolojisi izlenmiştir. Çalışmanın genel deneysel kurgusunu ve süreç adımlarını özetleyen metodolojik akış şeması Şekil 1'de sunulmuştur. Bu doğrultuda; demiryolu yüzey kusurlarının (rayların) tespiti amacıyla kullanılan veri setinin özellikleri, uygulanan ön işleme adımları, tercih edilen derin öğrenme mimarileri ve deneysel çalışma prensipleri takip eden alt bölümlerde detaylandırılmıştır. Tüm deneysel süreçler PyTorch kütüphanesi kullanılarak NVIDIA grafik işlem birimi (GPU) üzerinde gerçekleştirilmiştir.

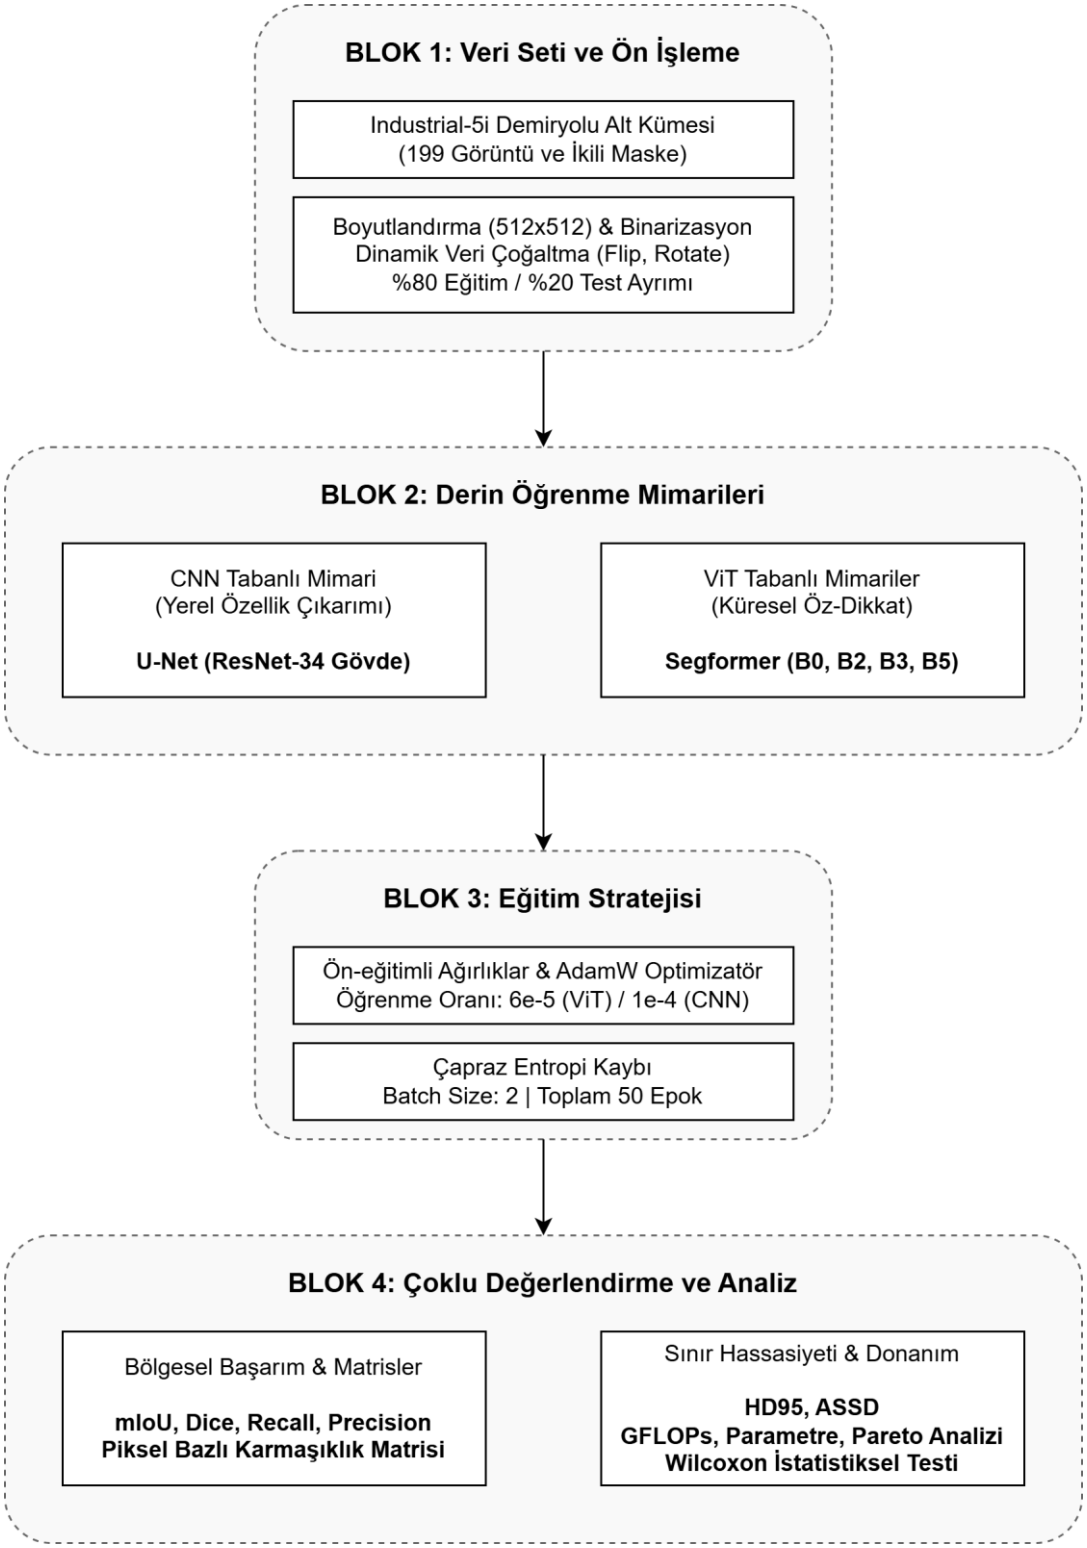

Şekil 1. Çalışma kapsamında uygulanan veri ön işleme, CNN/ViT mimarileri, model eğitimi ve performans değerlendirme adımlarını gösteren blok diyagram

2.1. Veri seti ve ön işleme

Çalışmada, endüstriyel ortamlardaki görüntü segmentasyonu problemleri için literatüre sunulan kapsamlı Industrial-5i veri setinin demiryolu alt kümesi kullanılmıştır [21]. Industrial-5i; MVTE-

AD, KolektorSDD, RSDD ve BSData gibi yaygın veri setlerinden derlenmiş toplam 20 farklı endüstriyel ürünü barındırmaktadır. Bu araştırmanın odak noktası gereği, söz konusu veri setinden yalnızca piksel düzeyinde etiketlenmiş ikili (binary) maskelere sahip kusurlu/kusursuz demiryolu (ray) görüntüleri izole edilmiştir. Bu ön eleme sonucunda, deneylerde kullanılmak üzere toplam 199 adet görüntü ve bu görüntülere ait yer gerçeği maskesinden oluşan özel bir alt veri seti elde edilmiştir.

Veri ön işleme aşamasında ilk olarak, 3 kanallı (RGB) orijinal görüntüler ile siyah-beyaz maskelerin dosya isimleri üzerinden tam eşleşme kontrolü yapılmış ve yalnızca eksiksiz çiftler temiz veri setine aktarılmıştır. Derin öğrenme modellerinin giriş katmanlarına standart bir tensör yapısı sunmak ve hesaplama maliyetlerini optimize etmek amacıyla, tüm görüntü ve maske çiftleri 512x512 piksel çözünürlüğüne yeniden boyutlandırılmıştır. Şekil 2 ile veri setinden üç tane örnek verilmiştir.

Şekil 2. Industrial-5i veri setinden elde edilen demiryolu görüntülerine ait örnekler

Modellerin sınıflandırma kararlılığını artırmak amacıyla maskeler üzerinde kesin bir ikilileştirme işlemi uygulanmıştır. Piksel yoğunluğu 128 değerinden büyük olan tüm pikseller hedef sınıf (ray) olarak 1 değerine, diğerleri ise arka plan olarak 0 değerine atanmıştır. Eğitim ve test süreçlerinin güvenilirliğini ve makalenin tekrarlanabilirliğini sağlamak adına veri seti sabit bir rastgele tohum (seed=42) kullanılarak %80 eğitim ve %20 doğrulama/test kümelerine ayrılmıştır.

2.2. Veri çoğaltma

Veri setindeki aşırı sınıf dengesizliğinin model üzerindeki olumsuz etkilerini, özellikle aşırı öğrenme problemini kırmak ve modellerin gerçek dünya koşullarındaki genelleme yeteneğini artırmak amacıyla sadece eğitim kümesine dinamik veri çoğaltma teknikleri uygulanmıştır. Bu süreç, yüksek performanslı görüntü işleme kütüphanesi olan Albumentations tabanlı AugmentedRSDDataset sınıfı aracılığıyla gerçekleştirilmiştir. Eğitim sırasındaki her bir iterasyonda görüntülere sırasıyla; %50 olasılıkla yatay çevirme, %50 olasılıkla dikey çevirme ve -10 ile +10 derece arasında rastgele döndürme işlemleri uygulanmıştır. Modellerin laboratuvar ortamı dışında, gerçek dünya senaryolarındaki başarımlarını objektif olarak ölçebilmek adına test kümesinin orijinal yapısına hiçbir müdahalede bulunulmamıştır.

2.3. Kullanılan derin öğrenme mimarileri

Demiryolu segmentasyonunda yerel ve küresel özellik çıkarım mekanizmalarının etkilerini kıyaslayabilmek için iki farklı ana akım mimari tercih edilmiştir. Modellerin geliştirilmesi ve test edilmesi süreçlerinde PyTorch tabanlı açık kaynaklı kütüphanelerden faydalanılmıştır:

Evrişimli Sinir Ağları (CNN) U-Net: Tümevarımsal yanlılık avantajına sahip olan geleneksel U-Net mimarisi, segmentation_models_pytorch (SMP) kütüphanesi aracılığıyla inşa edilmiştir. Modelin özellik çıkarıcı gövdesi olarak, transfer öğrenme yeteneklerinden faydalanmak amacıyla ImageNet veri seti üzerinde önceden eğitilmiş ResNet-34 mimarisi entegre edilmiştir. Çalışmanın temel amacı farklı CNN modellerini kendi aralarında yarıştırmak değil, "Evrişimsel (Lokal)" ve "Transformer (Küresel)" paradigmalarını birbirleriyle kıyaslamak olduğundan; CNN mimarisini temsilen literatürde ince yapı segmentasyonunun "altın standardı" olarak kabul edilen ResNet gövdeli U-Net yegâne referans model olarak kurgulanmıştır.

Görsel Dönüştürücüler (ViT) Segformer: Öz-dikkat mekanizması ile pikseller arası küresel bağlamı analiz eden Segformer mimarisinin B0, B2, B3 ve B5 varyantları kullanılmıştır. Hugging Face transformers kütüphanesi üzerinden yüklenen bu modellerde, parametre ve işlem hacmi açısından B0 en hafif, B5 ise en ağır ve karmaşık model olarak deneye dahil edilerek ViT mimarilerinin ölçeklenebilirliği test edilmiştir.

2.4. Eğitim stratejisi ve hiperparametreler

Tüm modeller, eşit ve adil bir karşılaştırma zemininde 50 epok boyunca eğitilmiştir. Özellikle Segformer-B5 gibi ağır mimarilerin grafik işlem birimi (GPU) bellek sınırlarını aşarak bellek yetersizliği hatasına yol açmaması için yığın boyutu tüm deneylerde 2 olarak optimize edilmiştir. Ayrıca eğitim süreçlerini hızlandırmak ve GPU bellek kullanımını daha da verimli hale getirmek amacıyla modellerin eğitiminde Yarı Hassasiyetli Kayan Nokta (FP16) formatı kullanılmıştır.

Ağ ağırlıklarının güncellenmesi sürecinde, derin öğrenme literatüründe özellikle Transformer mimarilerinde yüksek kararlılık ve hızlı yakınsama gösteren Ağırlık Azaltmalı Adam (AdamW) optimizasyon algoritması kullanılmıştır. Öğrenme oranı, mimari farklılıkların doğası ve kapasiteleri gereği Segformer varyantları için 0,00006, U-Net (ResNet-34) için ise 0,0001 olarak belirlenmiştir. Modellerin hata geri yayılımı hesaplamalarında kayıp fonksiyonu olarak, ikili segmentasyon problemlerinde standart haline gelen Çapraz Entropi Kaybı kullanılmıştır. Modelin eğitim sürecindeki başarısı her epok sonunda doğrulama veri seti üzerinde test edilmiş ve en iyi model ağırlıkları F1/Dice skoruna göre kaydedilmiştir. Bu araştırmada uygulanan genel eğitim stratejisi ve her iki mimari grup için kullanılan hiperparametrelerin donanımsal detayları Tablo 1 ile özetlenmiştir.

Tablo 1. Derin öğrenme mimarilerinin eğitiminde kullanılan stratejiler ve hiperparametreler

Hiperparametre / Eğitim stratejisi	U-Net (ResNet-34)	Segformer (B0, B2, B3, B5)
Maksimum epok sayısı	50	50
Yığın boyutu	2	2
Öğrenme oranı	0,0001	0,00006
Optimizasyon algoritması	AdamW	AdamW
Kayıp fonksiyonu	Çapraz Entropi	Çapraz entropi
Hesaplama hassasiyeti	FP16	FP16
Değerlendirme sıklığı	Her epok sonunda	Her epok sonunda
En iyi model seçim kriteri	F1 / Dice skoru	F1 / Dice skoru
Donanım / çalışma ortamı	NVIDIA GPU (CUDA)	NVIDIA GPU (CUDA)

2.5. Değerlendirme metrikleri ve istatistiksel analiz

Modellerin başarısını salt "Doğruluk" metriği ile ölçmenin, veri setindeki aşırı sınıf dengesizliği (yaklaşık %99 arka plan, %1 hedef nesne) nedeniyle yanıltıcı sonuçlar vereceği öngörülmüştür. Bu doğrultuda, modellerin azınlık sınıfı (raylar) üzerindeki gerçek performansını değerlendirebilmek için Doğru Pozitif (DP), Yanlış Pozitif (YP) ve Yanlış Negatif (YN) piksel tahminleri üzerinden Kesişim Üzerinden Birlik (IoU) [22] hesaplayan formül Denklem 1. ile verilmiştir.

$$IoU = \frac{DP}{DP + \mathrm{YP} + \mathrm{YN}} \tag{1}$$

Dice Katsayısı (Dice) [23] hesaplayan formül Denklem 2. ile verilmiştir.

$$Dice = \frac{2 \times DP}{2 \times \mathrm{DP} + \mathrm{YP} + \mathrm{YN}} \tag{2}$$

Kesinlik (Precision) [24] hesaplayan formül Denklem 3. ile verilmiştir.

$$Kesinlik = \frac{DP}{DP + \mathrm{YP}} \tag{3}$$

Duyarlılık (Recall) [25] hesaplayan formül Denklem 4. ile verilmiştir

$$\text{Duyarlılık} = \frac{DP}{DP + \mathrm{YN}} \tag{4}$$

Piksel tabanlı bu bölgesel metriklerin yanı sıra, tespit edilen rayların uzamsal sınır doğruluğunu ölçmek için 95. Yüzdelik Hausdorff Mesafesi (HD95) [26] ve Ortalama Simetrik Yüzey Mesafesi (ASSD) [27] metrikleri (medpy.metric kütüphanesi ile) kullanılmıştır. Ağır sınıf dengesizliği nedeniyle modellerin maske üzerinde hedef nesneyi tamamen kaçırdığı (boş küme ürettiği) durumlarda oluşan matematiksel tanımsızlık hatalarını engellemek amacıyla algoritmik bir ceza sistemi geliştirilmiştir. Ağ girdisi olarak kullanılan ve tamamı 160 piksel genişliğe sahip olan görüntülerde, boş tahmin üreten modellere ampirik bir üst sınır olarak 50,0 piksel ceza puanı atanmıştır. Görüş alanının (160 px) yaklaşık üçte birine (%31) denk gelen bu değer rastgele seçilmemiş olup; otonom demiryolu navigasyonunda raydan çıkma (kaza) olarak kabul edilecek kritik yörünge sapmasını temsil eden 'maksimum güvenlik ihlali eşiği' olarak standartlaştırılmıştır. Modellerin otonom sistemlerdeki gerçek zamanlı uygulanabilirliğini ölçmek amacıyla, donanımsal işlem yükleri (GFLOPs) ve parametre sayıları thop kütüphanesi aracılığıyla hesaplanmıştır.

Son olarak, modeller arasındaki performans farklarının istatistiksel olarak anlamlı olup olmadığını (rastlantısal olmadığını) test etmek amacıyla, verilerin normal dağılım gösterme zorunluluğu bulunmayan parametrik olmayan Wilcoxon İşaretli Sıralar Testi (Wilcoxon Signed-Rank Test) kullanılmıştır [28]. Karşılaştırmalı test sonuçlarında istatistiksel anlamlılık düzeyi $p < 0.05$ olarak kabul edilmiştir [29].

3. Deneysel Bulgular

Bu bölümde, demiryolu segmentasyon problemi üzerinde U-Net (ResNet-34) ve Segformer (B0-B5) mimarileri ile gerçekleştirilen deneylerin sonuçları çok boyutlu olarak analiz edilmiştir. Modellerin performansı; eğitim süreci, çoklu değerlendirme metrikleri, parametre/donanım

verimliliği, sınıf dengesizliğine karşı duyarlılık ve istatistiksel anlamlılık alt başlıkları altında incelenmiştir.

3.1. Eğitim süreci ve yakınsama

Modellerin 50 epokluk eğitim süreci boyunca kaydettiği genelleme yetenekleri ve hata minimizasyon süreçleri, Şekil 3'te sunulan Doğrulama Doğruluğu eğrileri üzerinden incelenmiştir. Grafiğe göre, geleneksel evrişimsel yapıya sahip U-Net (ResNet-34) modeli, önceden eğitilmiş ağırlıkları ve uzamsal tümevarımsal yanlılığı sayesinde ilk epoklardan itibaren %99 seviyelerinde hızlı ve stabil bir başlangıç sergilemiştir. Buna karşın, pikseller arası küresel ilişkileri sıfırdan öğrenmeye çalışan yama tabanlı Segformer mimarileri, eğitime çok daha düşük oranlarla başlamış, ancak 10. epoktan itibaren hızlı bir ivmelenme ile yakınsayarak U-Net ile aynı tepe noktasına ulaşmıştır.

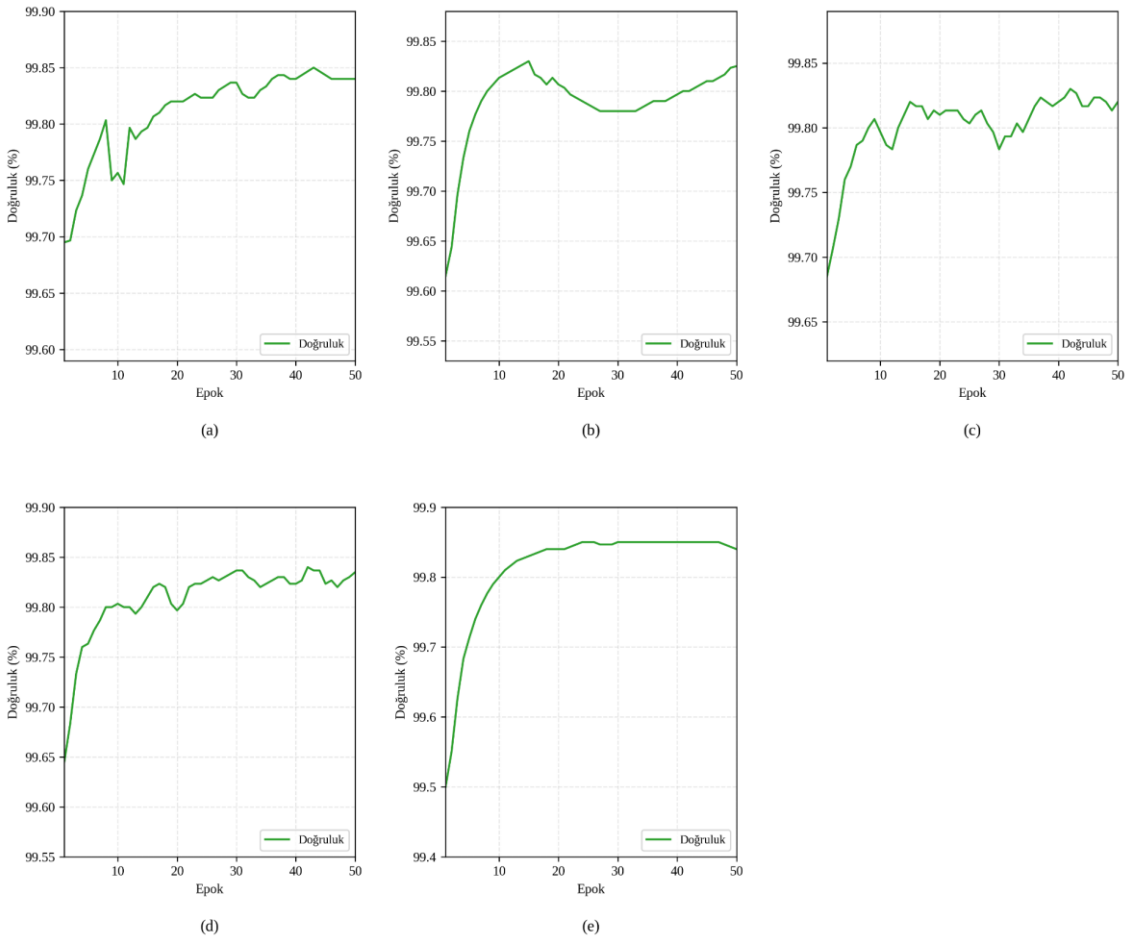

Şekil 3. Karşılaştırılan derin öğrenme mimarilerinin eğitim süreci boyunca elde ettikleri doğruluk eğrileri: (a) Segformer-B0, (b) Segformer-B2, (c) Segformer-B3, (d) Segformer-B5 ve (e) U-Net (R34)

Şekil 3'te sunulan bu eğitim eğrileri salt bir mimari başarı tablosundan ziyade, çalışmanın temel problemi olan "Doğruluk Paradoksu"nun somut bir kanıtı niteliğindedir. Serinin en hafif modeli olan Segformer-B0'dan en ağır modeli B5'e kadar tüm ağların bu kadar kısa sürede %99,8 gibi kusursuz görünen doğruluk tavanına ulaşması, modellerin rayları mükemmel tespit ettiğini değil; veri setindeki sınıf dengesizliğinin (~170:1) metrik üzerindeki manipülatif etkisini yansıtmaktadır. Bir demiryolu görüntüsündeki piksellerin %99'u zaten arka plandan oluştuğu için, modeller sadece arka plan piksellerini doğru sınıflandırmayı öğrendiğinde bile matematiksel olarak bu büyük skorlara otomatik olarak erişmektedir.

Dolayısıyla bu grafik, genel doğruluk metriğinin, ince doğrusal yapıların segmentasyonunda modeller arası gerçek kapasite farklarını tamamen maskelediğini ve model başarısının salt bu eğrilere bakılarak değerlendirilemeyeceğini açıkça ortaya koymaktadır. Bu yanılsama, ilerleyen bölümlerde modellerin yapısal sınır hassasiyetlerini ölçen mIoU, Dice ve Hausdorff Mesafesi (HD95) gibi daha spesifik bölgesel metrikler üzerinden çözümlenecektir.

Modellerin hata oranlarının minimizasyon sürecini gösteren Şekil 4'teki Eğitim ve Doğrulama Kaybı eğrileri incelendiğinde ise, mimariler arası fark daha belirginleşmektedir.

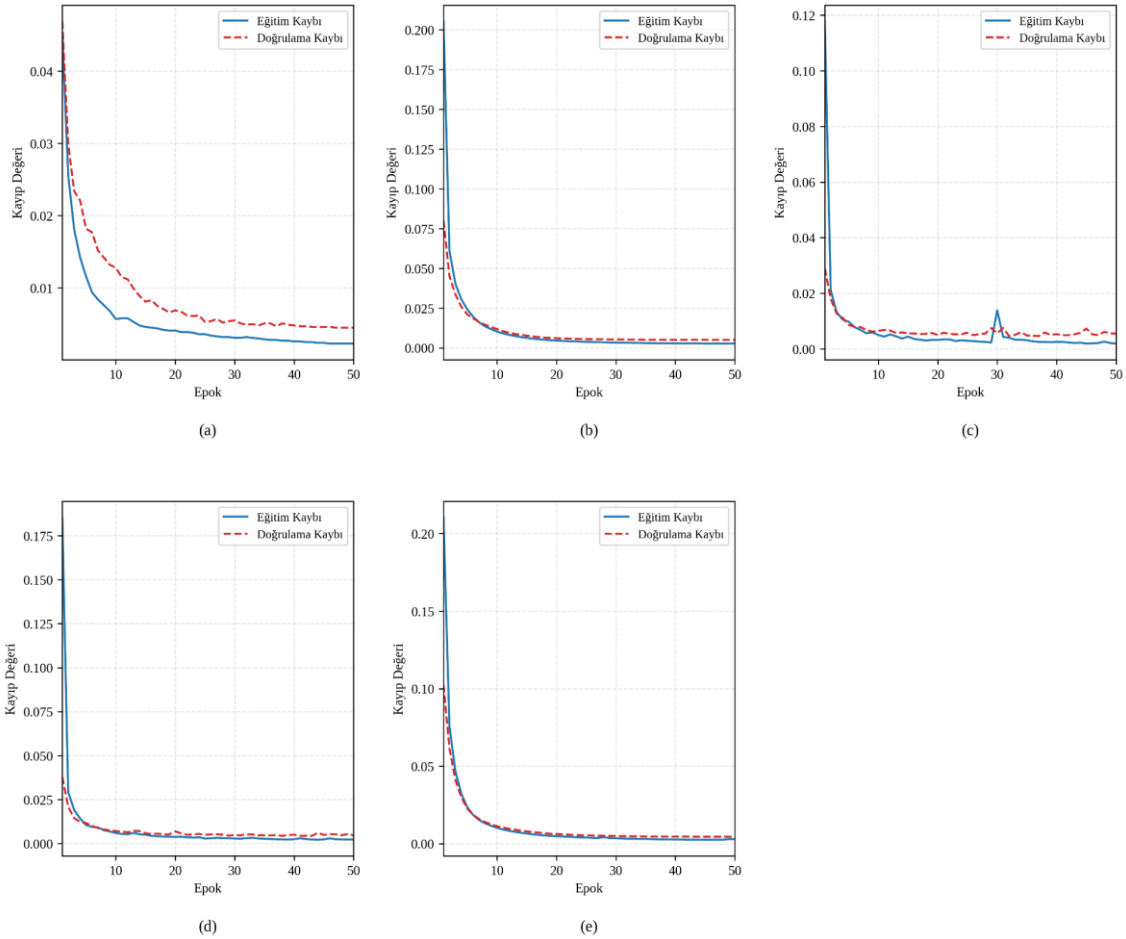

Şekil 4. Karşılaştırılan modellerin eğitim ve doğrulama kayıp eğrileri: (a) Segformer-B0, (b) Segformer-B2, (c) Segformer-B3, (d) Segformer-B5 ve (e) U-Net (R34)

Şekil 4 incelendiğinde U-Net'in kayıp değerleri ilk epoktan itibaren minimum seviyelerde ve pürüzsüz bir düzlemde ilerlediği; Transformer mimarilerinde ise (özellikle artan karmaşıklıkla birlikte B3 ve B5 varyantlarının doğrulama kaybı grafiklerinde) ilk 15 epok boyunca belirgin dalgalanmalar gözlemlenmiştir. Ancak ilerleyen epoklarda, AdamW optimizatörünün de etkisiyle bu dalgalanmalar sönümlenmiş ve tüm modellerde kayıp değerleri stabilize edilmiştir.

3.2. Genel performans ve çoklu metrik analizi

Modellerin test veri seti üzerinde ulaştıkları en iyi performans ölçümleri Tablo 2'de özetlenmiştir. Veri setindeki aşırı sınıf dengesizliği (ray piksellerinin arka plana oranla çok az olması) nedeniyle, tüm modellerin Doğruluk oranları %99,80 ile %99,84 arasında dar bir banda sıkışmıştır. Bu

durum, Doğruluk metriğinin azınlık sınıfı tespitindeki başarıyı ölçmede yetersiz kaldığı tezini kanıtlamış ve bölgesel örtüşme metriklerinin (mIoU ve Dice) önemini ortaya koymuştur.

Tablo 2. U-Net ve Segformer mimarilerinin test veri seti üzerindeki genel performans sonuçları

Model	mIoU	Dice	Doğruluk	Kesinlik	Duyarlılık	HD95	ASSD
Segformer-B0	35,61	40,03	99,81	39,67	40,86	68,84	32,40
Segformer-B2	34,57	39,29	99,83	43,95	41,45	42,25	30,30
Segformer-B3	34,72	39,45	99,80	39,64	39,99	53,49	31,94
Segformer-B5	35,74	40,06	99,82	39,97	40,74	52,50	31,11
U-Net (R34)	36,70	40,74	99,84	41,72	41,33	40,72	30,84

Tablo 2 ile sunulan veriler incelendiğinde göze çarpan ilk bulgu, tüm modellerin Doğruluk oranlarının %99,80 ile %99,84 gibi son derece dar ve yüksek bir banda sıkışmış olmasıdır. Veri setindeki aşırı sınıf dengesizliği (ray piksellerinin arka plana oranla %1 civarında olması) dikkate alındığında, bu durum yüksek Doğruluk oranlarının yapısal bir başarıdan ziyade çoğunluk sınıfının (arka plan) tahmin edilmesinden kaynaklanan matematiksel bir yanılsama olduğunu kanıtlamaktadır. Bu nedenle, modellerin gerçek ayırt ediciliği, azınlık sınıfı üzerindeki bölgesel örtüşme (mIoU, Dice) ve uzamsal sınır metrikleri (HD95, ASSD) üzerinden değerlendirilmiştir.

Bölgesel örtüşme metrikleri analiz edildiğinde, geleneksel CNN tabanlı U-Net (R34) mimarisinin 36,70 mIoU ve 40,74 Dice skorlarına ulaşarak test edilen tüm ViT varyantlarını açık ara geride bıraktığı görülmektedir. Bu sonuç, U-Net'in sahip olduğu tümevarımsal yanlılık ve lokal komşuluk ilişkilerini kurma yeteneğinin, demiryolu hattı gibi ince, uzun ve uzamsal süreklilik arz eden yapıların tespitinde çok daha kritik bir rol oynadığını göstermektedir.

ViT tabanlı modeller kendi içlerinde değerlendirildiğinde ise ilginç bir mimari verimsizlik tablosu ortaya çıkmaktadır. Ailenin en hafif modeli olan Segformer-B0 (35,61 mIoU) ile en ağır ve en çok parametreye sahip modeli olan Segformer-B5 (35,74 mIoU) arasındaki performans farkı sadece %0,13 seviyesindedir. Parametre sayısını büyük boyutlara çıkarmanın ve donanım maliyetini artırmanın, hedef sınıfı bulmada anlamlı bir başarı getirmediği tespit edilmiştir. Küresel dikkat mekanizmasına dayanan bu mimariler, büyük resme odaklanırken ray piksellerini "ihmal edilebilir detaylar" olarak yorumlamış ve yerel uzamsal özellikleri kaçırmıştır.

Modellerin tespit ettikleri hedeflerin kenar ve sınır doğruluğunu ölçen mesafe metrikleri (HD95 ve ASSD) incelendiğinde ise yapısal farklar çok daha dramatik bir hal almaktadır. HD95 skorunun düşük olması, modelin tahmin ettiği sınırların gerçek maskeye çok daha yakın olduğu anlamına gelir. U-Net, 40,72 HD95 skoru ile uzamsal sapmaları en aza indirgeyen ve ray sınırlarını en pürüzsüz çizen model olmuştur. Buna karşın, Segformer-B0'ın HD95 skorunun 68,84 seviyelerine fırlaması, modelin tahminlerinde büyük kopukluklar olduğunu veya hedeften çok uzak bölgelerde yanlış pozitif alarmlar ürettiğini kanıtlamaktadır. Her ne kadar Segformer-B2 varyantı Kesinlik (43,95) ve ASSD (30,30) bakımından dikkate değer bir tutarlılık gösterse de genel örtüşme oranlarında (34,57 mIoU) geride kalarak azınlık sınıfını yakalama konusunda aşırı seçici bir tutum sergilemiştir.

3.3. Hesaplamasal karmaşıklık ve donanım verimliliği analizi

Demiryolu hattı tespiti gibi otonom sistemlerde, bir modelin başarım oranı kadar gerçek zamanlı çalışabilme kapasitesi ve uç cihazlardaki bellek tüketimi de kritik bir önem taşımaktadır. Bu bağlamda, değerlendirilen mimarilerin donanımsal yüklerini ve uygulanabilirliklerini ölçmek amacıyla modellerin mimari türleri, toplam eğitilebilir parametre sayıları (Milyon) ve saniyedeki milyar kayan nokta işlemi (GFLOPs) değerleri Tablo 3'te sunulmuştur.

Tablo 3. Modellerin mimari özellikleri, parametre sayıları ve hesaplamasal işlem yüklerinin (GFLOPS) karşılaştırması

Model	Mimari	Parametre (M)	GFLOPs
Segformer-B0	ViT	3,71	13,54
Segformer-B2	ViT	27,35	113,43
Segformer-B3	ViT	47,22	142,72
Segformer-B5	ViT	84,59	199,51
U-Net (R34)	CNN	24,44	62,87

Tablo 3'teki verilere göre, ViT mimarileri kendi içlerinde incelendiğinde, Segformer-B5 modelinin 84,59 milyon parametre ve 199,51 GFLOPs işlem yükü ile ailenin en ağır modeli olduğu görülmektedir. Ancak bir önceki performans analizinde (Tablo 2), büyük donanım gereksinimlerine sahip bu modelin, yalnızca 3,71 milyon parametreye ve 13,54 GFLOPs işlem yüküne sahip Segformer-B0'a kıyasla anlamlı bir mIoU artışı sağlayamadığı kanıtlanmıştır. Bu durum, ViT tabanlı mimarilerde parametre sayısını ve ağ derinliğini artırmanın, demiryolu gibi ince ve dengesiz sınıfların tespitinde doğrusal bir başarı getirmediğini, aksine aşırı bir hesaplama israfına yol açtığını göstermektedir.

Geleneksel CNN mimarisini temsil eden U-Net (ResNet-34) modeli ise verimlilik açısından optimal bir denge noktası sunmaktadır. U-Net, 24,44 milyonluk parametre sayısı ile Segformer-B2 (27,35 M) ile benzer bir boyuta sahip olmasına rağmen, işlem yükü (62,87 GFLOPs) bakımından B2'nin (113,43 GFLOPs) neredeyse yarısı kadar donanım kaynağı tüketmektedir. Bu önemli fark, ViT mimarilerindeki küresel öz-dikkat mekanizmasının yüksek çözünürlüklü görüntülerde yarattığı kuadratik hesaplama maliyetinden kaynaklanırken; CNN tabanlı U-Net'in yerel evrişim işlemlerinin matematiksel olarak çok daha hafif ve verimli olduğunu kanıtlamaktadır.

Sonuç olarak; U-Net (ResNet-34) hem en yüksek bölgesel örtüşme (mIoU) ve en düşük sınır hatası (HD95) skorlarını elde etmiş, hem de bunu Segformer B2, B3 ve B5 varyantlarından çok daha düşük bir GFLOPs maliyetiyle gerçekleştirerek otonom demiryolu sistemleri için en ideal mimari olduğunu ispatlamıştır. Modellerin mIoU, Dice, Kesinlik ve Duyarlılık metrikleri üzerinden azınlık sınıfı üzerindeki bölgesel segmentasyon başarısını ve metrikler arası dengesini (trade-off) görsel olarak ortaya koyan çoklu metrik radar grafiği Şekil 5'te sunulmuştur.

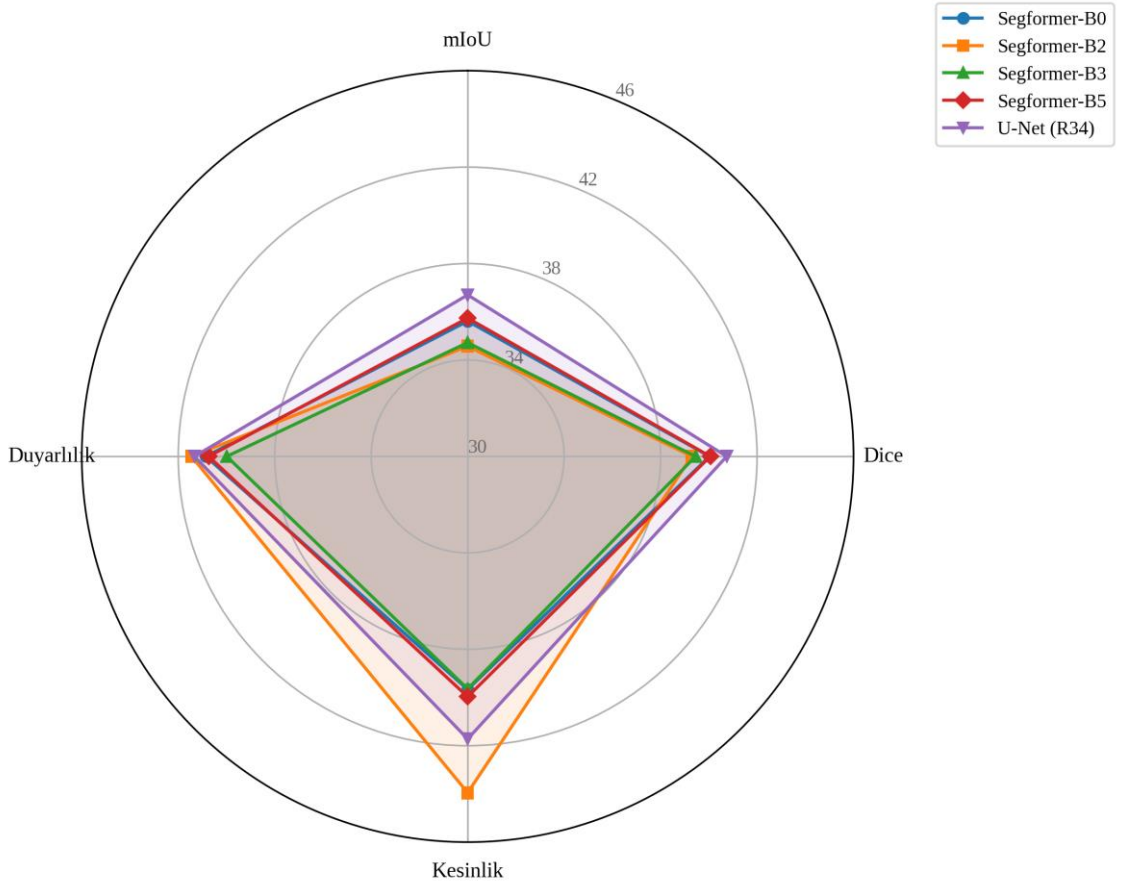

Şekil 5. Modellerin mIoU, Dice, kesinlik ve duyarlılık metrikleri üzerinden çoklu radar grafiği karşılaştırması

Şekil 5'te sunulan grafiğin kapsadığı toplam alan incelendiğinde, U-Net (ResNet-34) modelinin tüm eksenlerde en geniş ve homojen dağılımı sergileyerek ray hattının yapısal bütünlüğünü korumada en başarılı ve kararlı mimari olduğu görülmektedir. Segformer ailesi kendi içinde değerlendirildiğinde, model kapasitesi arttıkça (B0'dan B5'e) genel kapsama alanının genişlediği; ancak en güçlü varyant olan B5'in dahi U-Net'in özellikle Duyarlılık ve Dice eksenlerindeki kapsayıcılığına ulaşamadığı açıktır. Öte yandan, Segformer-B2 varyantının Kesinlik (Precision) ekseninde belirgin bir tepe noktası oluşturmasına rağmen Duyarlılık ekseninde merkeze çok yakın kalması, modelin daha önce vurgulanan "aşırı seçici" (eksik bölütleme) karakteristiğini grafiksel olarak göstermektedir.

3.4. Eğitim süreci boyunca öğrenme kararlılığı

Modellerin nihai performans metrikleri kadar, eğitim süreci boyunca sergiledikleri öğrenme kararlılığı ve yakınsama davranışları da mimarilerin yapısal uygunluğunu değerlendirmek açısından büyük önem taşımaktadır. Hedef sınıfın uzamsal özelliklerinin modeller tarafından ne kadar hızlı ve tutarlı bir şekilde öğrenildiğini analiz etmek amacıyla, U-Net ve Segformer varyantlarının eğitim epokları boyunca kaydettikleri Dice skoru değişimleri Şekil 6'da sunulmuştur.

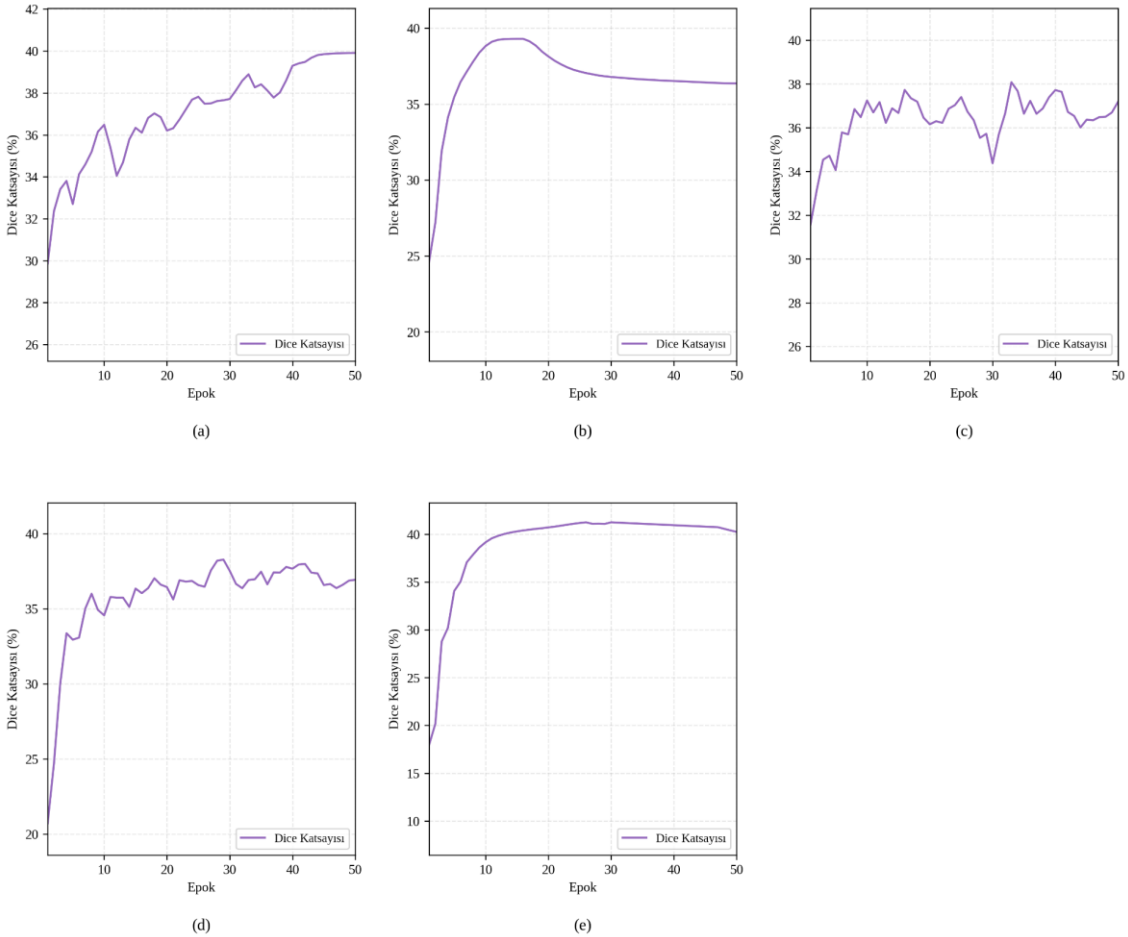

Şekil 6. Karşılaştırılan modellerin eğitim boyunca doğrulama veri seti üzerinde elde ettikleri Dice katsayısı eğrileri: (a) Segformer-B0, (b) Segformer-B2, (c) Segformer-B3, (d) Segformer-B5 ve (e) U-Net (R34)

Şekil 6'daki paneller incelendiğinde, CNN ile ViT tabanlı mimariler arasındaki "öğrenme karakteristiği" farkı çok net bir biçimde ortaya çıkmaktadır. Beşinci panelde yer alan U-Net (R34) grafiği incelendiğinde, modelin ilk epoklardan itibaren yaklaşık 40,0 Dice skoru seviyesine ulaştığı ve eğitim sonuna kadar neredeyse hiçbir dalgalanma yaşamadan kusursuz bir yatay stabilite sergilediği görülmektedir. U-Net'in bu olağanüstü kararlılığı, CNN mimarilerinin sahip olduğu uzamsal tümevarımsal yanlılık sayesinde, demiryolu hattı gibi yapısal bütünlüğü olan yerel özellikleri (kenar, çizgi, doku) veriden çok hızlı bir şekilde çıkarabildiğini kanıtlamaktadır.

Buna karşın, ilk dört panelde yer alan Segformer (ViT) varyantlarının grafikleri, Transformer mimarilerinin sınıf dengesizliği altındaki öğrenme zorluklarını gözler önüne sermektedir. Özellikle model karmaşıklığının arttığı Segformer-B2, B3 ve B5 panelleri incelendiğinde, modellerin ilk 15-20 epok boyunca şiddetli performans kayıpları yaşadığı, Dice skorlarının zaman zaman anlık olarak çöküşler (spikes/drops) gösterdiği tespit edilmiştir. Pikseller arası ilişkileri yerel pencereler yerine küresel öz-dikkat ile sıfırdan öğrenmeye çalışan ViT mimarileri, veri setindeki demiryolu piksellerinin azlığı nedeniyle başlangıçta hedefe odaklanmakta büyük bir zorluk çekmiş ve oldukça karmaşık bir yakınsama süreci geçirmiştir. İlginç bir şekilde, ViT ailesinin en hafif modeli olan Segformer-B0, ağır modellere (B3 ve B5) kıyasla dalgalanma sürecini çok daha erken (yaklaşık 8. epokta) atlatmış ve stabilizasyona daha hızlı geçmiştir. Bu durum, önceki bölümlerde değinilen "parametre israfı" tezini desteklemekte; aşırı parametreli Transformer modellerinin (B5) bu tür spesifik ve dengesiz medikal/endüstriyel veri setlerinde aşırı öğrenme veya kararsızlığa çok daha yatkın olduğunu doğrulamaktadır.

3.5. Eğitim sürecinde kesinlik ve duyarlılık dinamikleri

Sınıf dengesizliğinin aşırı olduğu demiryolu segmentasyonu gibi problemlerde, modellerin tahmin karakteristiğini (hedefi kaçırma veya yanlış alarm üretme eğilimlerini) anlamak için Kesinlik ve Duyarlılık metriklerinin eşzamanlı olarak incelenmesi büyük bir öneme sahiptir. Eğitim süreci boyunca modellerin azınlık sınıfını (ray pikselleri) öğrenme stratejilerindeki evrimi ve bu iki metrik arasındaki denge durumunu analiz etmek amacıyla, 50 epokluk eğitim periyoduna ait Kesinlik-Duyarlılık değişim eğrileri Şekil 7 ile sunulmuştur.

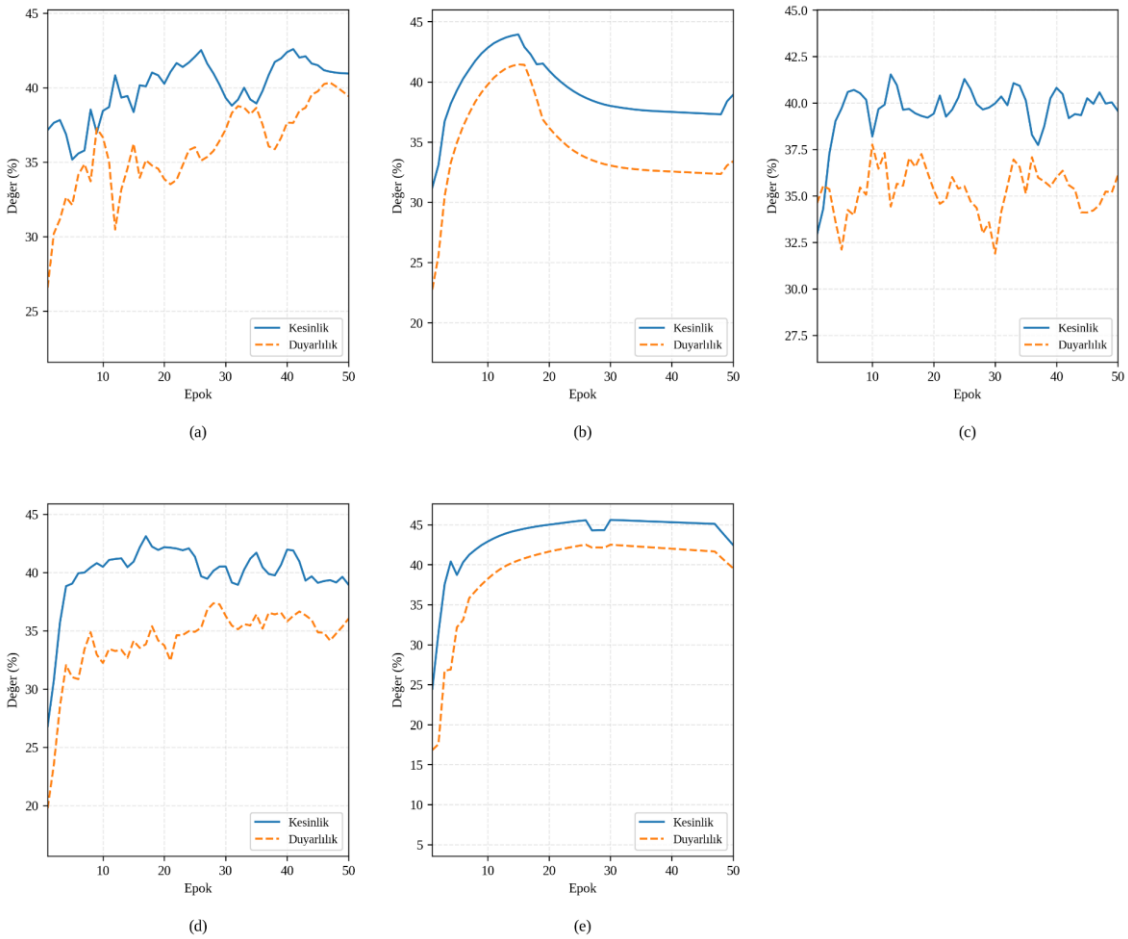

Şekil 7. Modellerin eğitim süreci boyunca doğrulama veri seti üzerindeki kesinlik ve duyarlılık eğrilerinin karşılaştırmalı analizi: (a) Segformer-B0, (b) Segformer-B2, (c) Segformer-B3, (d) Segformer-B5 ve (e) U-Net (R34)

Şekil 7'deki grafikler incelendiğinde, mimarilerin azınlık sınıfına yaklaşımında köklü yapısal farklılıklar olduğu göze çarpmaktadır. Beşinci panelde sunulan U-Net (R34) modelinin eğitim eğrisi, geleneksel CNN üstünlüğünü bir kez daha kanıtlamaktadır. U-Net, henüz ilk epoklardan itibaren Kesinlik ve Duyarlılık değerlerini birbirine çok yakın bir bantta (yaklaşık 40-45 seviyelerinde) eşitlemiş ve 50 epok boyunca hiçbir kırılma yaşamadan bu dengeyi korumuştur. Bu durum, U-Net'in aşırı seçici davranıp hedefi kaçırmak (düşük Duyarlılık) ile aşırı cesur davranıp arka planı ray sanmak (düşük Kesinik) tuzaklarına düşmediğini; evrişim katmanlarının yerel özellikleri (çizgisel ray yapılarını) hızlıca kavrayıp istikrarlı bir öğrenme sergilediğini göstermektedir.

Buna karşın, ViT tabanlı Segformer modellerinin (özellikle B2, B3 ve B5) ilk 20 epok boyunca son derece karmaşık bir öğrenme süreci geçirdiği görülmektedir. Bu modellerde başlangıç aşamasında Duyarlılık (turuncu çizgi) eğrisinin periyodik olarak büyük düşüşler yaşayarak tekrar yükseldiği tespit edilmiştir. Duyarlılık değerinin bu denli çökmesi, modelin azınlık sınıfını tespit etmekte tamamen başarısız olduğu ve yüksek kayıp almamak için tüm pikselleri çoğunluk sınıfı olan "arka plan" olarak etiketlemeyi seçtiği anlamına gelmektedir. Küresel dikkat mekanizmasının, resmin çok küçük bir bölümünü kaplayan ray özelliklerini başlangıçta baskın arka plan gürültüsünden ayıramadığı açıkça görülmektedir.

Ayrıca, Segformer modelleri belirli bir epoktan sonra (yaklaşık 20. epok sonrası) stabilizasyona geçse bile, eğriler arasındaki boşluk (Kesinlik ile Duyarlılık arasındaki makas) U-Net'e kıyasla çok daha açıktır. Özellikle Segformer-B0 ve B2 varyantlarında Kesinlik (mavi çizgi) değerinin Duyarlılıktan (turuncu çizgi) belirgin şekilde yüksek kalması, ViT modellerinin "aşırı seçici" bir tahmin stratejisi benimsediğini göstermektedir. Diğer bir deyişle, Segformer modelleri yalnızca %100 emin oldukları çok belirgin piksellere "ray" etiketi vermekte (bu nedenle Precision görece yüksek kalmakta), ancak emin olamadıkları flu veya gölgeli bölgelerdeki gerçek ray piksellerini arka plan sayarak kaçırmaktadırlar (bu nedenle Duyarlılık düşük kalmaktadır). Sonuç olarak; otonom demiryolu sistemlerinde rayları gözden kaçırmak kazalara yol açabilecek kritik bir hata olduğundan, Kesinlik ve Duyarlılığı en erken aşamada dengeleyen ve yüksek tutan U-Net'in güvenlik ve operasyonel güvenilirlik açısından en uygun mimari olduğu bu dinamik analizle de pekiştirilmiştir.

3.6. Parametre verimliliği, işlem yükü ve pareto analizi

Otonom demiryolu sistemlerinde (örneğin insansız denetim araçları veya akıllı trenler) kullanılacak olan modellerin segmentasyon başarısı kadar, kısıtlı uç cihazlarda çalışabilmeleri için donanımsal verimlilikleri de hayati öneme sahiptir. Şekil 8 ile sunulan Pareto balon grafiğinde, modellerin parametre sayıları (x-ekseni), mIoU performansları (y-ekseni) ve saniyedeki milyar kayan nokta işlemi olan GFLOPs yükleri (balon büyüklüğü) eşzamanlı olarak analiz edilmiştir.

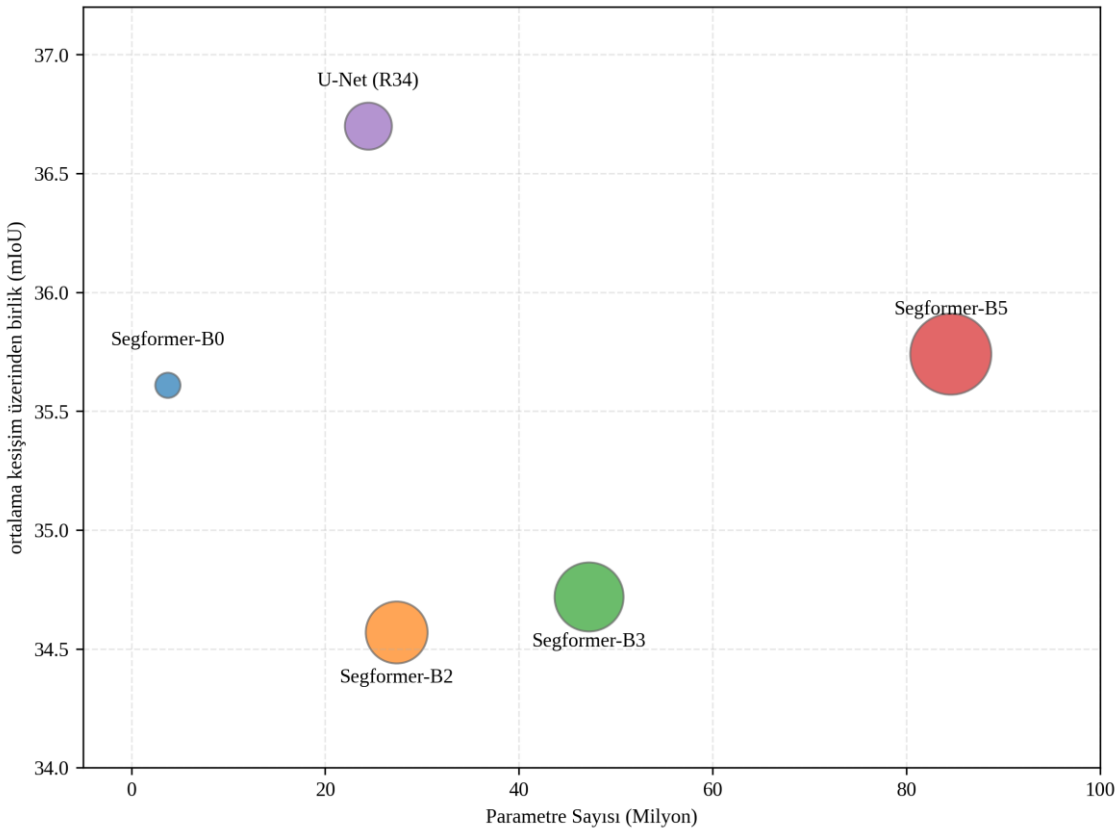

Şekil 8. Modellerin parametre sayıları (Milyon), işlem yükleri (GFLOPs - balon boyutu) ve mIoU performansları üzerinden donanım verimliliği (Pareto) analizi

Grafik incelendiğinde, geleneksel Evrişimli Sinir Ağı tabanlı U-Net (24.4M parametre) modelinin en yüksek segmentasyon başarısına (yaklaşık %36,7 mIoU) ulaşırken, donanım yükü ve hesaplama maliyeti açısından optimum bir denge yakaladığı görülmektedir. U-Net, grafiğin sol üst köşesine en yakın konumda yer alarak donanım-performans dengesinde mutlak Pareto ideal noktasını oluşturmuştur.

ViT tabanlı Segformer mimarileri kendi içlerinde değerlendirildiğinde ise çarpıcı bir "parametre israfı" tablosu ortaya çıkmaktadır. Ailenin en hafif üyesi olan Segformer-B0 (3,7M parametre), grafikteki en küçük işlem yüküne (en küçük balon çapına) sahip olmasına rağmen; kendisinden daha ağır olan Segformer-B2 ve B3 modellerini mIoU skorunda geride bırakmayı başarmıştır. Dahası, serinin en hantal modeli olan ve B0'dan yaklaşık 23 kat daha fazla parametreye sahip olan Segformer-B5 (84,6M parametre), B0 modeline kıyasla ihmal edilebilir bir doğruluk artışı sunmuştur.

Sonuç olarak; donanım kısıtlamasının olmadığı bulut tabanlı sistemlerde en yüksek doğruluğu sunan U-Net rakipsiz bir tercihken; gerçek zamanlı hızın ve düşük batarya tüketiminin kritik olduğu uç bilişim cihazları için Segformer-B0, şaşırtıcı derecede yüksek maliyet-performans oranıyla en güçlü alternatif mimari olarak konumlanmıştır.

3.7. Sınıf dengesizliği ve değerlendirme paradoksları

Veri setinde bulunan yaklaşık 12,85 milyon arka plan pikseline karşılık yalnızca ~75 bin ray pikselinin bulunması (~170:1), modellerin değerlendirilmesinde ciddi istatistiksel yanılgılara (paradokslara) yol açmaktadır. Bu durumun model kararları üzerindeki gerçek etkisi, Şekil 9 ile verilen küresel (global) piksel tabanlı Karmaşıklık Matrisleri üzerinden analiz edilmiştir.

Tablo 2'de sunulan görüntü-bazlı bölgesel metriklerde modellerin Duyarlılık ve Dice oranları %40 seviyelerinde görünmesine rağmen; bu durum modellerin başarısızlığından ziyade, test setindeki "içinde ray bulunmayan boş görüntülerin" görüntü-bazlı hesaplamalarda 0/0 (tanımsız) üreterek ortalamayı matematiksel olarak aşağı çekmesinden kaynaklanmaktadır.

Metriklerin boş maske cezalarından arındırıldığı ve tüm test piksellerinin küresel bir havuzda (pixel-wise) değerlendirildiği Karmaşıklık Matrislerine inildiğinde, modellerin gerçek ayrıştırma performansı netleşmektedir. Şekil 9(a)'da görüldüğü üzere U-Net (R34) modeli; toplam ray piksellerinin 69.025'ini doğru tespit etmiş (True Positive) ve yalnızca 5.799'unu kaçırmıştır (False Negative). Bu durum, ray sınıfı için %92,5 gibi son derece yüksek bir gerçek Duyarlılığa işaret etmektedir. Benzer şekilde, Şekil 9(b)'de yer alan Segformer-B5 modeli 70.162 ray pikselini doğru tespit ederek ray sınıfında %93,77 duyarlılığa ulaşmıştır. Ayrıca matris sonuçları, Segformer-B5 modelinin U-Net'e kıyasla arka planı ray olarak algılama (Yanlış Pozitif-FP) eğiliminin daha düşük olduğunu da göstermektedir (11.167 FP'ye karşı 13.155 FP).

Matris sonuçlarına göre küresel piksel havuzunda Segformer-B5'in azınlık sınıfı üzerinde ~%1,5'lik hafif bir sayısal üstünlüğü bulunsa da bu durum görüntü-bazlı (Tablo 2) sonuçlarla birlikte değerlendirildiğinde kritik bir mimari davranışı ortaya çıkarmaktadır. Segformer-B5, bazı görüntülerdeki yoğun piksel yığınlarını çok iyi tahmin ederek küresel havuzdaki TP sayısını artırsa da yama-tabanlı (patch-based) yapısı nedeniyle bazı zorlu sahnelerde ray yapılarını tamamen kaçırarak genel görüntü ortalamalarında (mIoU ve Dice) U-Net'in gerisinde kalmıştır.

Buna karşın U-Net (R34), evrişimsel yapısının sunduğu uzamsal tümevarımsal yanlılık (spatial inductive bias) sayesinde kareler arası çok daha kararlı ve istikrarlı bir hat bütünlüğü sergilemiştir. En önemlisi, Wilcoxon istatistiksel testlerinin de ($p > 0{,}05$) doğruladığı üzere U-Net, küresel bağlamda kendisinden 3,5 kat daha büyük (84,6M parametre) olan Segformer-B5 ile eşdeğer bir başarıyı yalnızca 24,4 milyon parametre ile elde etmiştir.

Sonuç olarak bu bulgular göstermektedir ki: Ağır dengesizliğe sahip ince yapı segmentasyonlarında, genel Doğruluk metriklerine bakmak yanıltıcıdır. Gelişmiş Transformer mimarileri belirli pikselleri yakalamada başarılı olsa da model derinliğinden ziyade uzamsal sürekliliği koruyan verimli mimarilerin (U-Net) demiryolu navigasyonu gibi kesintisiz tespit gerektiren otonom sistemler için çok daha optimum ve "parametre israfından" uzak bir çözüm sunduğu kanıtlanmıştır.

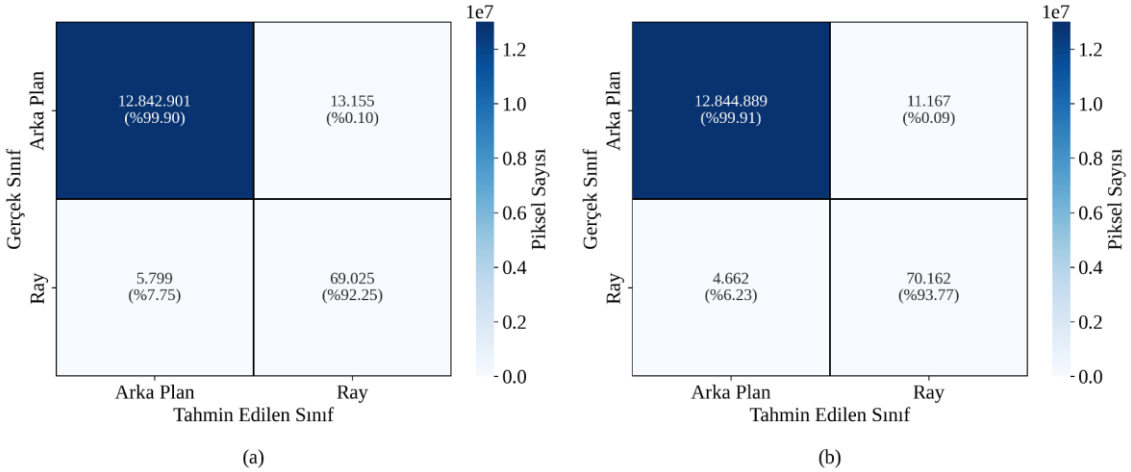

Şekil 9. Sınıf dengesizliğinin model kararlarına etkisini gösteren piksel tabanlı karmaşıklık matrisleri: (a) U-Net (ResNet34), (b) Segformer-B5

3.8. İstatistiksel anlamlılık analizi

Modellerin test setinde elde ettiği segmentasyon başarılarındaki farklılıkların rastlantısal olmadığını matematiksel olarak kanıtlamak amacıyla, model tahminleri üzerinden parametrik olmayan Wilcoxon İşaretli Sıralar Testi (Wilcoxon Signed-Rank Test) uygulanmıştır. İkili model karşılaştırmalarına ait p-değerlerini gösteren istatistiksel anlamlılık ısı haritası Şekil 10 ile sunulmuştur. Geleneksel olarak $p < 0{,}05$ eşiği, istatistiksel anlamlılık sınırı olarak kabul edilerek değerlendirme yapılmıştır.

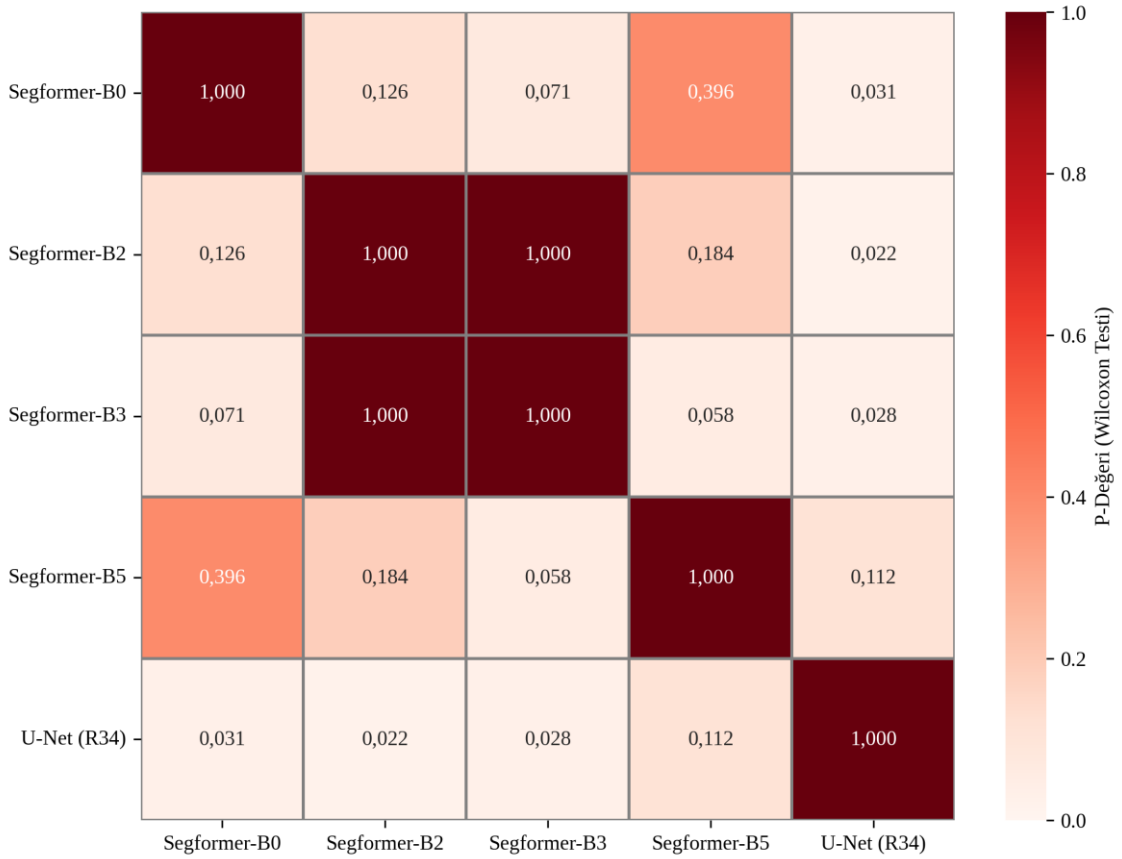

Şekil 10. Modeller arası performans farklarının istatistiksel anlamlılığını gösteren Wilcoxon İşaretli Sıralar Testi p-değeri ısı haritası

İstatistiksel test sonuçları ve ısı haritası incelendiğinde, mimarilerin performans karakteristiğine dair üç temel bulgu ortaya çıkmaktadır:

U-Net'in İstatistiksel Üstünlüğü: CNN tabanlı U-Net (R34) mimarisi; Segformer-B0, B2 ve B3 modelleriyle kıyaslandığında sırasıyla $p = 0{,}03110$, $p = 0{,}02102$ ve $p = 0{,}02742$ değerlerini vererek $p < 0{,}05$ anlamlılık sınırını başarıyla geçmiştir. Bu durum, U-Net'in azınlık sınıfı üzerindeki başarısının ve bölgesel örtüşme (mIoU) üstünlüğünün bir rastlantı olmadığını, söz konusu ViT modellerine karşı istatistiksel olarak anlamlı bir fark yarattığını kesin olarak kanıtlamaktadır.

U-Net ve Segformer-B5 Karşılaştırması: Serinin en ağır modeli olan Segformer-B5 ile U-Net (R34) arasındaki karşılaştırmada p-değeri 0,11193 ($p > 0{,}05$) olarak hesaplanmıştır. Bu sonuç, iki model arasında "istatistiksel olarak anlamlı bir performans farkı bulunmadığı" anlamına gelmektedir. Ancak, yaklaşık 84,6 milyon parametreye sahip devasa bir ViT mimarisinin,

yalnızca 24,4 milyon parametreli geleneksel bir CNN mimarisiyle matematiksel olarak aynı başarı liginde kalması son derece kritik bir detaydır.

ViT Ailesi İçindeki Parametre İsrafı: Çok çarpıcı bir diğer bulgu ise, Segformer ailesinin kendi içindeki tüm ikili karşılaştırmaların (örneğin B0 ile B5 arası $p = 0{,}39575$) istatistiksel anlamlılık sınırının çok üzerinde ($p > 0{,}05$) çıkmasıdır. Bu durum, Transformer mimarilerinde model parametre boyutunu 3,7 milyondan 84,6 milyona çıkarmanın, aşırı sınıf dengesizliğine sahip demiryolu veri setlerinde modellerin birbirine istatistiksel bir üstünlük kurmasını sağlamadığını göstermektedir. Bu bulgu, önceki bölümlerde tartışılan donanımsal "parametre israfı" tezini matematiksel olarak da doğrulamaktadır.

3.9. Kalitatif görsel tahmin analizi

Kantitatif bulguları desteklemek ve mimarilerin mekansal öğrenme karakteristiklerini derinlemesine incelemek amacıyla, modellerin test veri seti üzerindeki tahmin çıktıları Şekil 11 ile görselleştirilmiştir. Zorlu bir demiryolu yüzey deformasyonunun incelendiği bu tahmin maskeleri, CNN ile ViT arasındaki yapısal algı farkını çarpıcı bir biçimde ortaya koymaktadır.

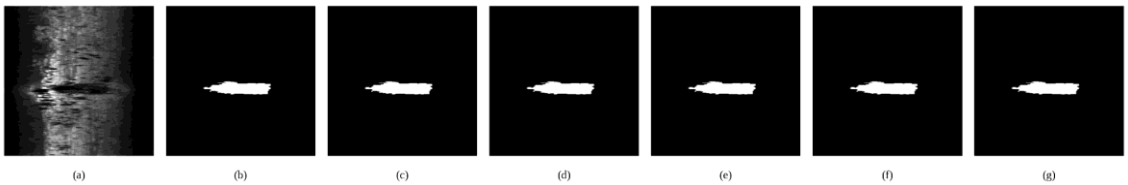

Şekil 11. Modellerin test veri seti üzerindeki kalitatif segmentasyon sonuçlarının görsel karşılaştırması: (a) Orijinal görüntü, (b) Yer gerçeği, (c) U-Net (R34), (d) Segformer-B0, (e) Segformer-B2, (f) Segformer-B3, (g) Segformer-B5

Şekil 11 incelendiğinde, geleneksel CNN tabanlı U-Net (R34) modelinin yer gerçeğine en yakın, morfolojik sınırları en keskin ve yapısal doğruluğu en yüksek tahmini ürettiği açıkça görülmektedir. U-Net, evrişim katmanlarının sağladığı güçlü tümevarımsal yanlılık sayesinde ray yüzeyindeki deformasyonun karmaşık ve asimetrik doğasını başarıyla kavramış; kusurlu bölgenin ince kıvrımlarını arka plan gürültüsüne kapılmadan yüksek bir piksel hassasiyetiyle bölütlenmiştir. Bu görsel başarı, modelin önceki bölümlerde elde ettiği düşük HD95 skorunun doğrudan bir yansımasıdır.

Buna karşın, ViT tabanlı Segformer modellerinin çıktılarında kusurlu bölgenin sınırlarında deformasyonlar ve kaba tahminler gözlemlenmiştir. Segformer serisi (özellikle B0, B2 ve B3), yüzeydeki kusurun genel konumunu doğru tespit etse de deformasyonun keskin yapısal hatlarını kaybederek nesneyi daha çok yuvarlatılmış ve dağınık piksel kümeleri halinde tahmin etmiştir. Ailenin en güçlü modeli olan Segformer-B5 ise nesne bütünlüğünü daha iyi korumuş olsa da sınır çizgilerinde hedef formdan sapmalar barındırmaktadır. Transformer mimarisinin küresel dikkat mekanizması ve görüntüyü yamalara bölerek işleme mantığı, kusurun bulunduğu genel bağlamı anlamakta başarılı olsa da yüzey deformasyonlarının mikro-uzamsal sınırlarını çizerken CNN'lerin sunduğu lokal hassasiyete tam anlamıyla ulaşamamıştır.

Sonuç olarak; demiryolu altyapı güvenliğinin sağlanması ve bakım planlamalarının doğru yapılabilmesi için, yüzey kusurlarının sadece "varlığının" tespiti değil, aynı zamanda boyut ve morfolojik sınırlarının da kaba lekeler olarak değil, gerçek formlarına en sadık şekilde belirlenmesi zorunludur. Görsel analizler, U-Net'in bu hassas altyapı denetimi kriterini sağlamada ViT mimarilerine kıyasla daha güvenilir ve keskin sonuçlar ürettiğini kanıtlamaktadır.

Görsel tahminlerin yapısal kalitesini ve modellerin karakteristik hata eğilimlerini daha derinlemesine incelemek amacıyla, Şekil 12'de zorlu demiryolu topolojilerine (makas geçişleri ve kavisler) odaklanılmış ve tahmin maskeleri piksel bazlı doğruluk durumlarına göre renklendirilmiştir. Bu analizde; modelin yer gerçeği ile örtüşen başarılı tahminleri Doğru Pozitif (TP), arka planı ray olarak yanlış sınıflandırdığı taşkınlık bölgeleri Yanlış Pozitif (FP) ve tespit edemediği gerçek ray pikselleri ise Yanlış Negatif (FN) olarak görselleştirilmiştir.

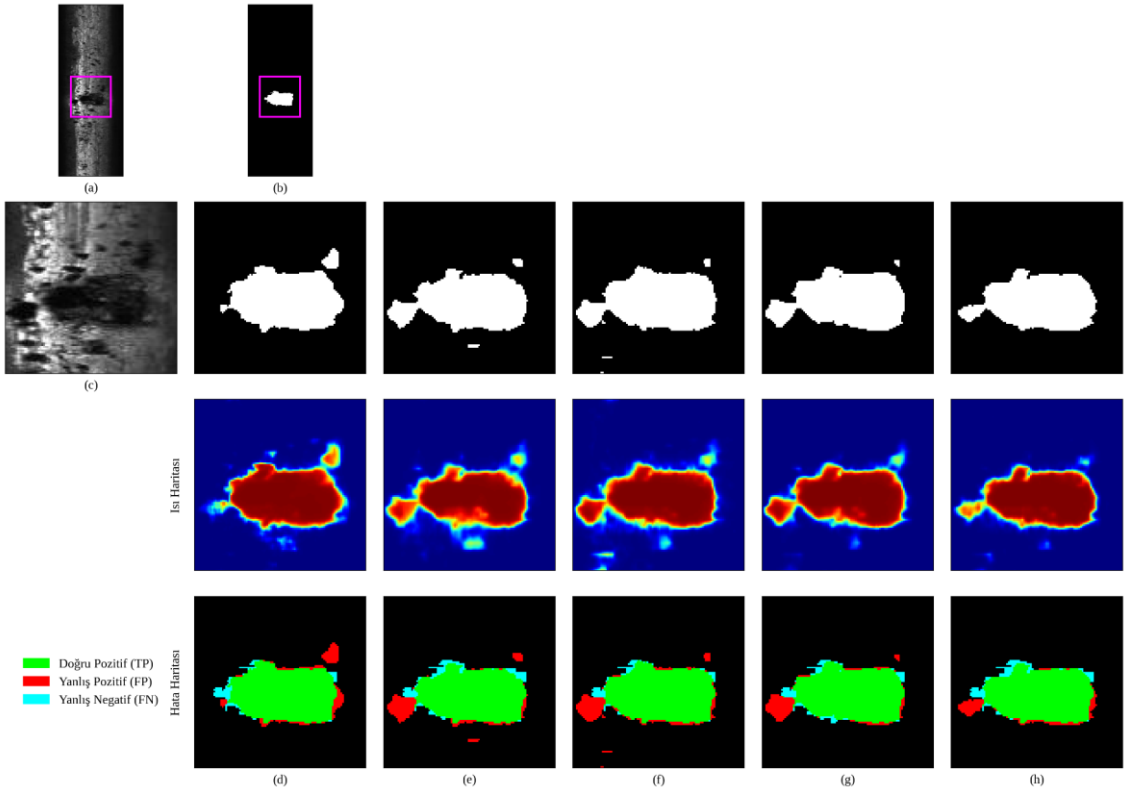

Şekil 12. Farklı anlamsal bölütleme modellerinin kavisli ve zorlu bir demiryolu yüzeyi örneği üzerindeki mikro-uzamsal tahmin performanslarının karşılaştırılması: (a) Pembe çerçeve ile hata detayının (ilgi alanının) vurgulandığı orijinal görüntü, (b) orijinal yer gerçeği, (c) vurgulanan bölgenin yakınlaştırılmış görünümü, (d–h) harfleri ile belirtilen sütunlar sırasıyla U-Net (ResNet34), Segformer-B0, Segformer-B2, Segformer-B3 ve Segformer-B5 modellerine ait sonuçlar

Şekil 12 ile verilen görselde her bir model sütununda yukarıdan aşağıya doğru sırasıyla; modelin ürettiği ikili tahmin maskesi (Model Maskesi), ağın piksel bazlı güven seviyesini gösteren olasılık dağılımı (Isı Haritası) ve uzamsal örtüşme başarısını sunan Hata Haritası yer almaktadır. Hata haritalarındaki renk kodlamasında yeşil bölgeler doğru pozitifleri (TP), kırmızı bölgeler yanlış pozitifleri (FP) ve camgöbeği bölgeler eksik tahmin edilen yanlış negatifleri (FN) temsil etmektedir.

Şekil 12 incelendiğinde, geleneksel CNN tabanlı U-Net (R34) modelinin ürettiği segmentasyon maskesinin, kusurlu bölgenin sınırlarına en sadık kalan yapıyı sunduğu görülmektedir. U-Net, görseldeki bölgesel deformasyonun morfolojik yapısını yüksek bir sınır hassasiyetiyle yakalayabilmiş; ufak çaplı eksik tahminler (FN) ve sınır taşkınlıkları (FP) barındırsa da hedef nesnenin genel bütünlüğünü korumayı başarmıştır. Bu durum, CNN mimarisinin uzamsal çözünürlüğü koruma ve yerel özellikleri (kenar, doku geçişleri) piksel düzeyinde keskin bir şekilde çizebilme konusundaki yapısal gücünü kanıtlamaktadır.

Buna karşın, Segformer varyantlarının (özellikle B0, B2 ve B5) hata dağılımları incelendiğinde, ViT mimarisinin mikro-mekânsal algıdaki temel zafiyetleri ortaya çıkmaktadır. Segformer

modellerinin çıktılarında, hedef bölgenin etrafında yoğun bir şekilde FP (Yanlış Pozitif) ve FN (Yanlış Negatif) piksellerinin iç içe geçtiği ve tespit edilen bölgenin formunu kaybettiği görülmektedir. Özellikle serinin en ağır modeli olan Segformer-B5'in, kusurlu bölgeyi asıl sınırlarından dışarıya doğru taşırarak fazladan arka plan piksellerini (FP) de tahmin maskesine kattığı ve ana gövdede eksik (FN) çentikler yarattığı izlenmektedir.

Gözlemlenen bu "sınır belirsizliği ve taşkınlık" sorunu, Transformer mimarilerindeki görüntüyü yamalara bölerek işleme mantığının doğrudan bir sonucudur. Model, deformasyonun bulunduğu genel konumu küresel bağlamda başarılı bir şekilde tespit etse de yamalar içindeki mikro piksel detaylarını çözümleyemediği için sınırları bulanıklaştırmış ve asıl leke etrafında yoğun bir FP/FN halesi (halo effect) yaratmıştır. Sonuç olarak; U-Net piksel seviyesinde daha derli toplu ve yerel bir doğruluk sunarken, Segformer modelleri ilgili bölgeyi net sınırları olan bir nesne olarak değil, etrafı hata pikselleriyle sarılmış kaba bir "alan" olarak algılayabilmiştir. Elde edilen bu 'Transformer mimarilerindeki sınır bulanıklaşması ve hale etkisi' bulgusu, son yıllarda yayımlanan ve CNN ile ViT mimarilerini doğrudan karşılaştıran güncel çalışmaların [30], [31], [32] rapor ettiği 'ViT mimarilerinin ince-uzun yerel detayları ve keskin nesne sınırlarını yakalamadaki zafiyeti' argümanıyla tam olarak örtüşmektedir.

4. Sonuç

Bu çalışma kapsamında, otonom demiryolu sistemleri için kritik öneme sahip olan ray segmentasyonu görevi, CNN tabanlı U-Net (ResNet-34) ve Transformer tabanlı Segformer (B0-B5) mimarileri üzerinden kapsamlı bir karşılaştırmalı analize tabi tutulmuştur. Elde edilen sayısal veriler, istatistiksel testler ve görsel hata analizleri sonucunda belirlenen bulgular demiryolu gibi ince ve doğrusal yapıların tespitinde model derinliğinden ziyade, mimarinin uzamsal tümevarımsal yanlılığının (uzamsal ön yargı) daha kritik bir rol oynadığını kanıtlamaktadır. Nitekim, yaklaşık 24,4 milyon parametreye sahip olan U-Net (R34), 84,6 milyon parametreli Segformer-B5 ile istatistiksel olarak benzer ($p > 0{,}05$) bir segmentasyon başarısı sergilemiştir. Ayrıca çalışmada, %99,8'i aşan genel doğruluk skorlarının, veri setindeki 170:1 oranındaki aşırı sınıf dengesizliği nedeniyle yanıltıcı olduğu saptanmıştır. Karmaşıklık matrisleri üzerinden yapılan analizler, modellerin gerçek başarısının ancak azınlık sınıfı (ray) üzerindeki Duyarlılık (Recall) ve IoU değerleri ile ölçülebileceğini, U-Net'in bu noktada ViT modellerine karşı daha dengeli bir öğrenme eğrisi sergilediğini göstermiştir. Mikro-yapısal (zoomed-in) analizler ise, Segformer modellerinin "yama tabanlı" (patch-based) çalışma prensibi nedeniyle ray hatlarında kopukluklar ve "bloklanma" (artifact) etkileri yarattığını ortaya koymuştur. Buna karşın U-Net, evrişimsel yapısı sayesinde piksel seviyesinde süreklilik sağlayarak otonom navigasyon için gereken kesintisiz hat segmentasyonunu başarıyla gerçekleştirmiştir. Yapılan Wilcoxon İşaretli Sıralar Testi sonuçları, U-Net'in düşük ve orta ölçekli Segformer modellerine (B0, B2, B3) karşı üstünlüğünün istatistiksel olarak anlamlı ($p > 0{,}05$) olduğunu doğrulamıştır. Segformer ailesi içerisinde ise parametre artışının performans üzerinde istatistiksel olarak baskın bir fark yaratmadığı, bir başka deyişle aşırı parametre kullanımının demiryolu segmentasyonunda verimlilik artışı sağlamadığı gözlemlenmiştir.

Elde edilen tüm bulgular ışığında, otonom tren sistemlerinde yüksek hesaplama maliyetli Transformer mimarileri yerine, uzamsal koruma yeteneği yüksek ve daha hafif CNN tabanlı hibrit yapıların tercih edilmesi önerilmektedir. Bununla birlikte, çalışma kapsamında aşırı öğrenme riskini baskılamak amacıyla veri artırma, ön-eğitimli ağırlıkların kullanımı (transfer learning) ve erken durdurma (early stopping) stratejileri etkin bir şekilde uygulanmış olsa da; mevcut veri seti boyutunun modellerin oldukça zorlu ve nadir sahnelerdeki genelleme (generalization) kapasitesini sınırlayabilmesi, bu araştırmanın temel bir kısıtı (limitation) olarak değerlendirilmektedir. Gelecek çalışmalarda, veri setinin farklı aydınlatma senaryoları, çeşitli demiryolu topolojileri ve zorlu hava koşulları (yoğun kar, sis) ile zenginleştirilerek fiziksel olarak

büyütülmesi; ayrıca bu modellerin farklı hava koşullarında (yoğun kar, sis) ve gerçek zamanlı çıkarım hızları (FPS) bazında optimizasyon süreçleri incelenmesi hedeflenmektedir.

Kaynakça

[1] Ü. Ekici ve T. Ferşadoğlu, "Demiryolu taşımacılığının diğer taşımacılık modlarıyla karşılaştırılması ve sağladığı avantajlar", *Demiryolu Mühendisliği*, sy 19, ss. 121-132, Oca. 2024, doi: 10.47072/demiryolu.1385217.

[2] A. G. Seferoğlu ve F. Polat, "Kayseri'de otobüs ve tramvay hizmet kalitesi: Yolcu memnuniyetinin karşılaştırmalı bir analizi", *Journal of Innovative Engineering and Natural Science*, c. 5, sy 2, ss. 884-900, Tem. 2025, doi: 10.61112/jiens.1694523.

[3] M. A. Elmuhammedcebben, İ. Aydın, ve M. Sevi, "Demiryolu ortamında nesne tespiti için derin öğrenme yöntemlerinin geliştirilmesi ve zed kamerası ile mesafe ölçümü", *Demiryolu Mühendisliği*, sy 22, ss. 10-24, Tem. 2025, doi: 10.47072/demiryolu.1645019.

[4] C. Taştimur, "Efficient and real-time railway track fault classification using CNN integrated with convolutional block attention module", *Muş Alparslan Üniversitesi Fen Bilimleri Dergisi*, c. 13, sy 2, ss. 351-356, Ara. 2025, doi: 10.18586/msufbd.1763332.

[5] X. Wan vd., "Environmental suitability analysis integrating carbon emission evaluation for green railway alignment optimization", *International Journal of Rail Transportation*, c. 14, sy 1, ss. 45-71, Oca. 2026, doi: 10.1080/23248378.2025.2474496.

[6] C.-C. Chang, K.-H. Huang, T.-K. Lau, C.-F. Huang, ve C.-H. Wang, "Using deep learning model integration to build a smart railway traffic safety monitoring system", *Scientificit Reports*, c. 15, sy 1, s. 4224, Şub. 2025, doi: 10.1038/s41598-025-88830-7.

[7] Y. Weng, H. Xiang, X. Chen, C. Zhang, L. Jia, ve F. Chen, "MFD-UNet: a complex railway track boundary segmentation algorithm for drone vision based on multi-scale fusion and deformable pyramid blocks", *Measurement Science and Technology*, c. 36, sy 1, s. 016198, Ara. 2024, doi: 10.1088/1361-6501/ad9cae.

[8] T. Jiang vd., "RailSeg: Learning local–global feature aggregation with contextual ınformation for railway point cloud semantic segmentation", *IEEE Transactions on Geoscience and Remote Sensing*, c. 61, ss. 1-29, 2023, doi: 10.1109/TGRS.2023.3319950.

[9] Y. Chen, J. Zhou, ve C. Chen, "An efficient foreign object detection model based on Transformer for high-speed railway catenary", *Engineering Applications of Artificial Intelligence*, c. 164, s. 113313, Oca. 2026, doi: 10.1016/j.engappai.2025.113313.

[10] M. A. R. Alif, M. Hussain, G. Tucker, ve S. Iwnicki, "BoltVision: A Comparative Analysis of CNN, CCT, and ViT in Achieving High Accuracy for Missing Bolt Classification in Train Components", *Machines*, c. 12, sy 2, s. 93, Şub. 2024, doi: 10.3390/machines12020093.

[11] F. Guo, J. Liu, Y. Qian, ve Q. Xie, "Rail surface defect detection using a transformer-based network", *Journal of Industrial Information Integration*, c. 38, s. 100584, Mar. 2024, doi: 10.1016/j.jii.2024.100584.

[12] A. Phaphuangwittayakul, N. Harnpornchai, F. Ying, ve J. Zhang, "RailTrack-DaViT: A vision transformer-based approach for automated railway track defect detection", *Journal of Imaging*, c. 10, sy 8, s. 192, Ağu. 2024, doi: 10.3390/jimaging10080192.

[13] F. J. Valverde-Albacete ve C. Peláez-Moreno, "100% Classification accuracy considered harmful: The normalized ınformation transfer factor explains the accuracy paradox", *PLOS ONE*, c. 9, sy 1, s. e84217, Oca. 2014, doi: 10.1371/journal.pone.0084217.

[14] J. A. Scaringi vd., "Implementing an AI algorithm in the clinical setting: a case study for the accuracy paradox*", European Radiology*, c. 35, sy 7, ss. 4347-4353, Tem. 2025, doi: 10.1007/s00330-024-11332-z.

[15] Y. Chen, D. Zhu, Y. Sun, X. Chen, W. Zhang, ve X. Shen, "The accuracy paradox in RLHF: When better reward models don't yield better language Models", içinde *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, Y. Al-Onaizan, M. Bansal, ve Y.-N. Chen, Ed., Miami, Florida, USA: Association for Computational Linguistics, Kas. 2024, ss. 2980-2989. doi: 10.18653/v1/2024.emnlp-main.174.

[16] O. Ronneberger, P. Fischer, ve T. Brox, "U-Net: Convolutional networks for biomedical ımage segmentation", içinde *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, N. Navab, J. Hornegger, W. M. Wells, ve A. F. Frangi, Ed., Cham: Springer International Publishing, 2015, ss. 234-241. doi: 10.1007/978-3-319-24574-4_28.

[17] T. Tang, G. T. Jayaputera, ve R. O. Sinnott, "A Performance comparison of convolutional neural networks and transformer-based models for classification of the spread of bushfires", içinde *2024 IEEE 20th International Conference on e-Science (e-Science)*, Eyl. 2024, ss. 1-9. doi: 10.1109/e-Science62913.2024.10678733.

[18] A. G. R. Salgado, M. Shen, P. Harzig, P. Mayer, ve J. M. Alvarez, "Global average feature augmentation for robust semantic segmentation with transformers", 14 Aralık 2024, arXiv: arXiv:2412.01941. doi: 10.48550/arXiv.2412.01941.

[19] Y. Xu, C. Liu, J. Zhong, W. Mei, ve Y. Zhang, "MSPFNet: Multi-scale perceptual focusing network for scrap steel segmentation and classification", *Engineering Applications of Artificial Intelligence*, c. 144, s. 110084, Mar. 2025, doi: 10.1016/j.engappai.2025.110084.

[20] B. Liu vd., "Identification and mapping of gully using machine learning and deep learning algorithms in the loess hilly and gully region in China", *International Soil and Water Conservation Research*, s. 100587, Eki. 2025, doi: 10.1016/j.iswcr.2025.10.003.

[21] X. Shi. A data set for few-shot segmentation on industrial surface defect detation[DS/OL]. V1. *Science Data Bank*, 2022[2026-03-14]. https://cstr.cn/31253.11.sciencedb.06908.

[22] P. Jaccard, "The distribution of the Flora in the alpine zone.", *New Phytologist Foundation*, c. 11, sy 2, ss. 37-50, 1912, doi: 10.1111/j.1469-8137.1912.tb05611.x.

[23] L. R. Dice, "Measures of the amount of ecologic association between species", *Ecology*, c. 26, sy 3, ss. 297-302, 1945, doi: 10.2307/1932409.

[24] D. M. W. Powers, "Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation", 11 Ekim 2020, arXiv: arXiv:2010.16061. doi: 10.48550/arXiv.2010.16061.

[25] M. Sokolova ve G. Lapalme, "A systematic analysis of performance measures for classification tasks, *Information Processing & Management*, c. 45, sy 4, ss. 427-437, Tem. 2009, doi: 10.1016/j.ipm.2009.03.002.

[26] A. A. Taha ve A. Hanbury, "Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool", *BMC Med Imaging*, c. 15, sy 1, s. 29, Ağu. 2015, doi: 10.1186/s12880-015-0068-x.

[27] T. Heimann vd., "Comparison and evaluation of methods for liver segmentation from CT datasets", *IEEE Transactions on Medical Imaging*, c. 28, sy 8, ss. 1251-1265, Ağu. 2009, doi: 10.1109/TMI.2009.2013851.

[28] J. Cuzick, "A wilcoxon-type test for trend", *Statistics in Medicine*, c. 4, sy 1, ss. 87-90, 1985, doi: 10.1002/sim.4780040112.

[29] H. Karakis, A. Karamete, ve A. Okçu, "The Effects of a computer-assisted teaching material, designed according to the ASSURE ınstructional design and the ARCS model of motivation, on students' achievement levels in a mathematics lesson and their resulting attitudes", *European Journal of Contemporary Education*, c. 15, sy 1, ss. 105-113, 2016.

[30] J. Yang, A. PP Abdul Majeed, M. Ateeq, Z. Omar, R. Jailani, R. Muazu Musa ve N. Mat Yahya, "Surface defect classification: leveraging transformer and transfer learning models for enhanced precision in industrial applications", *The International Journal of Advanced Manufacturing Technology*, c. 139, sy. 7, s. 4141-4152, 2025.

[31] S. T. K. Ayon, F. M. Siraj ve J. Uddin, "Steel Surface Defect Detection Using Learnable Memory Vision Transformer", *Computers, Materials & Continua*, c. 82, sy. 1, 2025.

[32] R. Jin, Z. Shen, S. Zeng, C. Liu ve D. Tao, "Rail-SegFormer: An Attention-Enhanced Model with Convolutional Hybridization and Salient Feature Fusion", *2025 IEEE International Conference on Consumer Electronics-Taiwan (ICCE-Taiwan)*, s. 599-600, 2025, doi: 10.1109/ICCE-Taiwan66881.2025.11207990.

Özgeçmiş

Ahmet AKKAYA
1982 yılında Bandırma'da doğdu. Lisans derecesini Fırat Üniversitesi Elektronik-Bilgisayar Öğretmenliği Bölümü ve Balıkesir Üniversitesi Elektrik-Elektronik Mühendisliği Bölümü, Yüksek Lisans derecesini Balıkesir Üniversitesi Bilgisayar ve Öğretim Teknolojileri Eğitimi Bölümü, Doktora derecesini Bandırma Onyedi Eylül Üniversitesi Mekatronik Mühendisliği Bölümünde aldı. Araştırma alanları arasında optimizasyon, görüntü işleme ve derin öğrenme bulunmaktadır. Aynı zamanda Bandırma Onyedi Eylül Üniversitesi Gönen Meslek Yüksekokulu Bilgisayar Teknolojileri Bölümünde Dr. Öğr. Üyesi olarak çalışmaktadır.
E-Posta: aakkaya@bandirma.edu.tr

Beyanlar:
Bu çalışmanın hazırlanması sürecinde, yapay zekâ tabanlı araçlardan yalnızca yazım dili, dilbilgisi ve anlatımın iyileştirilmesi amacıyla yararlanılmıştır. Yapay zekâ araçları, literatür taraması, çalışmanın bilimsel içeriğinin oluşturulması, veri analizi, sonuçların elde edilmesi veya yorumlanması süreçlerinde kullanılmamıştır. Bu makalede bilimsel araştırma ve yayın etiğine uyulmuştur.