

Yapay Zekâ Düşünce Zincirinin (Chain of Thought - CoT) Ceza Muhakemesinde Delil Değeri^(*)

The Evidential Value of Artificial Intelligence Chain of Thought (CoT) in Criminal Proceedings

Burak TAŞ^(**)

Öz

Ceza muhakemesi hukuku maddi gerçeğe adli yoldan ulaşma hedefiyle delillerin toplanması, değerlendirilmesi ve bunlardan bir sonuç çıkarılması üzerine kuruludur. Bu süreçte, sübuta ulaşma ile insan iradesine dayalı eylemlerin manevi unsuru olan kastın veya taksirin ispatı, yargılamanın en zorlu aşamasını teşkil eder. Yapay zekâ teknolojisinin ceza hukukuna dahil olmasıyla birlikte, ispat meselesi yeni ve karmaşık bir boyut kazanmıştır. Özellikle suç işlenmesi sürecine dahil olan ve delil üretiminde kullanılan yapay zekâlarda ‘düşünce zinciri’ (chain of thought - CoT) olarak bilinen teknoloji, bir yapay zekâ modelinin nihai bir çıktıya veya karara ulaşırken izlediği mantıksal adımları metin formatında sunma potansiyeli taşımaktadır. Teorik olarak, bir suçun işlenmesinde kullanılan bir yapay zekâ, bir nevi zihindeki işlem silsilesini göstermekle manevi unsuru doğrudan tespit etme imkânı sunar gibi görünmektedir. Suç işlemek üzere programlanmış, suç işlenmesinde araç olarak kullanılan veya delil üretmeye özgülümlü bir yapay zekânın düşünce zincirinde yer alan ‘hedefi yok et’ veya ‘güvenlik sistemini yanılt’ gibi bir ifade, ilk bakışta failin kastına dair bir ‘dijital itiraf’ olarak değerlendirilebilir. Bu da yapay zekâda kara kutu sorunun çözümünde önemli bir potansiyel sunmaktadır. Kara kutunun düşünce zinciri ile beyaz kutuya dönüşüp dönüşmeyeceği delil hukukunda önemli bir sonuca ulaşılmasını sağlayacaktır. Çalışmada, düşünce zincirinden elde edilecek verilen tek başına delil olarak kabul edilemeyeceği, uzman tarafından değerlendirilip delil elde etme aracı olarak itibar görmesi gerektiği sonucuna ulaşılabilecektir. Nihayetinde CoT verilerinin güvenilirliği, manipülasyona açıklığı gibi temel zorluklar analiz edilerek olması gerekene yönelik bir çerçeve sunmaya çalışılacaktır.

Anahtar Kelimeler

Kara Kutu Problemi, Düşünce Zinciri, Beyaz Kutu, Açıklanabilir Yapay Zekâ, Delil.

Abstract

Criminal procedure law is founded on the objective of reaching the material truth through judicial means by collecting, evaluating, and drawing conclusions from evidence. In this process, proving the mental element of actions based on human will, namely intent or negligence, constitutes the most challenging phase of a trial. The integration of artificial intelligence technology into criminal law has given rise to new and complex issues surrounding proof. Specifically, in artificial intelligence involved in the commission of a crime or used in evidence generation, the technology known as ‘chain of thought’ (CoT) holds the potential to present, in text format, the logical steps an artificial intelligence model follows to reach a final output or decision. Theoretically, an artificial intelligence used in the commission of a crime seems to offer the possibility of directly ascertaining the mental element by revealing a sort of mental sequence of operations. A statement within the chain of thought of an artificial intelligence, programmed to commit a crime, used as an instrument in its commission, or dedicated to generating evidence, such as ‘eliminate target’ or ‘deceive security system,’ could at first glance be considered a ‘digital confession’ regarding the perpetrator’s intent. This also presents significant potential for solving the black box problem in artificial intelligence. Determining whether the black box can be transformed into a white box through the chain of thought will lead to a significant

^(*) Hakemli makale - Peer reviewed article

Makalenin geliş tarihi: 12.11.2025

Makalenin kabul tarihi: 24.01.2026

^(**) Dr. Öğr. Üyesi, Bolu Abant İzzet Baysal Üniversitesi, Hukuk Fakültesi, Ceza ve Ceza Muhakemesi Hukuku, Bolu - Türkiye

E-posta: burak.tas@ibu.edu.tr

Orcid: 0000-0001-6481-1580

conclusion in the law of evidence. This study will conclude that data obtained from a CoT cannot be accepted as evidence on its own; rather, it should be regarded as a means of obtaining evidence that requires evaluation by an expert. Ultimately, by analyzing fundamental challenges such as the reliability and susceptibility to manipulation of CoT data, the study will attempt to present a normative framework for what the law ought to be.

Keywords

Black Box Problem, Chain of Thought, White Box, Explainable Artificial Intelligence, Evidence.

Extended Summary

Artificial intelligence is leading to fundamental changes and new legal debates in criminal law and the processes of evaluating evidence. Particularly, advanced machine learning models such as deep learning are inadequate in explaining how a specific input is transformed into a specific output due to the complex interactions among billions of parameters, and this situation is referred to in the literature as the black box problem. While proving the mental element of actions based on human will in criminal proceedings, namely intent or negligence, is already a challenging process, the non-transparent decision-making mechanisms of artificial intelligence used in the commission of a crime or in evidence generation make this proof almost impossible. In this context, the effort to comprehend the mental process of artificial intelligence at the time of decision-making has become one of the most current and critical issues in the law of evidence.

The chain of thought (CoT) technology, developed as a technical solution to this transparency issue and constituting an important part of the explainable artificial intelligence concept, refers to large language models presenting the logical steps they follow step-by-step in text format while solving complex problems. This simulation, which shows the intermediate steps an artificial intelligence goes through while reaching a conclusion, theoretically holds the potential to transform the black box into a more transparent white box by offering an interpretable window into the system's behavior. A statement such as 'eliminate target' that might be included in the chain of thought of an artificial intelligence while performing a criminal act could at first glance be considered a digital confession revealing the perpetrator's intent or an important beginning of evidence. However, the issue of whether these outputs can be accepted as definitive evidence serving to directly ascertain the mental element in a legal sense brings along significant technical and legal challenges.

When evaluated within the framework of the Turkish criminal procedure system, chain of thought data do not possess the capacity to serve directly as digital evidence. Here, for the time being, it might be possible to speak of circumstantial evidence. Nevertheless, there are difficult-to-overcome technical obstacles to the use of these data as a means of proof in legal disputes, such as access, accuracy, susceptibility to manipulation, and hallucination. First of all, the inability to provide full access to the architecture of artificial intelligence models and raw chain of thought data due to companies' claims of trade secrets and intellectual property is a fundamental problem that restricts the right of defense and damages the integrity of the evidence. Furthermore, the structure of large language models based on statistical word prediction can lead to the generation of hallucinations that appear logical but are far from factual reality. The fact that malicious actors can manipulate artificial intelligence models through prompt injection or adversarial attacks to create a fake chain of thought, and that models can generate deceptive texts to fabricate innocent covers for their own actions, undermines the trust in the objectivity of these data.

To address these vulnerabilities and strengthen the evidential value of chain of thought data, it is imperative to integrate forensic informatics standards and specific explainable artificial intelligence techniques, such as counterfactual analysis, into the process. In particular, maintaining a continuous chain of custody, which proves that digital evidence has not undergone any alteration from its acquisition to its presentation in court, through methods like timestamping and cryptographic sealing is of critical importance for the reliability of the evidence. However, the technical and complex nature of the outputs makes it impossible for the judge to evaluate these data alone. As seen in the Daubert standard in Anglo-American law, the admissibility of scientific and technical evidence in court requires high reliability and an expert filter.

Consequently, the textual outputs presented by the artificial intelligence chain of thought cannot be accepted as definitive declaratory evidence that directly and solely proves the perpetrator's intent in criminal proceedings. Due to their susceptibility to manipulation and the risk of hallucination they carry, these data can only function as circumstantial evidence or a means of obtaining evidence requiring special expertise within the framework of the right to a fair trial. Convicting a human being based on suspicious texts generated by artificial intelligence is incompatible with the fundamental principles of law. For the data obtained from the chain of thought to gain legal value, it depends on a panel of experts in the fields of artificial intelligence and cybersecurity reporting on the integrity, whether they have been manipulated, and the overall reliability of the records in question in a rational and auditable manner. The judge's conscientious conviction must also be based not on the raw text presented by the artificial intelligence, but on the expert evaluation where this data is examined on a comprehensive and scientific basis.

Giriş

Yirmibirinci yüzyılın en dönüştürücü teknolojilerinden biri olan yapay zekâ artık sadece bir bilim kurgu unsuru değil, toplumsal yaşamın ve ekonomik faaliyetlerin ayrılmaz bir parçasıdır. Otonom araçlardan tıbbi teşhis sistemlerine, finansal algoritmalarından içerik üreten platformlara kadar geniş bir yelpazede kullanılan yapay zekâ sistemleri, insan benzeri bilişsel yetenekler sergileyerek karmaşık kararlar alabilmektedir.¹ Bu durum, hukukun temel paradigmasını sorgulatan yeni soruları beraberinde getirmektedir. Özellikle ceza hukuku alanında, yapay zekanın bir suçun işlenmesinde araç olarak konumlandığı durumlar ile delil ürettiği haller, mevcut yasal çerçevelerin yetersizliğini ortaya koymaktadır. Örneğin bir yapay zekâ tarafından yönetilen yatırım fonunun, piyasayı manipüle ederek haksız kazanç elde etmesi durumunda, bu manipülatif kast nasıl ispatlanabilir? Bu gibi sorularda kilit nokta, yapay zekânın karar anındaki zihinsel sürecini anlamaktır. Geleneksel makine öğrenmesi modelleri bu sürecin anlaşılabilirliği ve öngörülemezliği noktasında genellikle ‘kara kutu (black box)’ olarak nitelendirilir; yani, belirli bir girdiye karşılık neden belirli bir çıktıyı ürettikleri dışarıdan tam olarak anlaşılabilir. Derin öğrenme gibi en etkili yapay zekâ yöntemlerinin karar mekanizmaları şeffaf olmadığından ve kolayca anlaşılabilirliğinden, açıklanabilirlik yapay zekâ alanında çözülmesi gereken kritik bir sorun haline gelmiştir.³ Bu şeffaflık eksikliği, yapay zekâ kararlarının hukuki bir uyumazlıkta delil olarak kullanılmasının önündeki en büyük engellerden biridir.⁴ Ancak son yıllarda geliştirilen ve ‘düşünce zinciri (Chain-of-Thought - CoT)’ olarak bilinen teknik, bu kara kutu sorununa bir çözüm sunma potansiyeli taşımaktadır. Büyük dil modelleri (LLM) gibi gelişmiş sistemler, artık sadece nihai bir cevap vermekle kalmayıp, o cevaba ulaşırken izledikleri ara mantık adımlarını da adım adım açıklayabilmektedir. Bu durum, ceza muhakemesi hukuku açısından oldukça önemlidir. Bir yapay zekanın, bir olaya ilişkin kararını hangi verilere dayanarak, hangi olasılıkları değerlendirecek ve hangi kuralları izleyerek verdiğini gösteren bu düşünce zinciri kaydı, potansiyel bir dijital itiraf gibi bir dijital delil niteliğindedir.

Bu makalenin temel araştırma sorusu yapay zekanın bir karara varırken izlediği adımları ortaya koyan düşünce zinciri verisinin, ceza muhakemesinde bir delil olarak kabul edilip edilemeyeceği, eğer kabul edilirse, ispat gücü ve bu süreçte hangi hukuki, teknik

ve felsefi sorunlarla karşılaşılacağıdır. Bu soruyu yanıtlamak amacıyla çalışma, öncelikle kara kutu sorunu, düşünce zinciri ve açıklanabilir yapay zekâ kavramlarını teknik arka planıyla inceleyecek, ardından Türk ceza muhakemesi hukukundaki delil sistemi içerisinde CoT verilerinin yerini tartışacaktır. Daha sonra, bu yeni delil türünün güvenilirliği, manipülasyona açıklığı, bütünlüğü, bir delil olarak kullanılmasının önündeki teknik ve hukuki engeller gibi temel sorunlar derinlemesine analiz edilecektir.

I. Yapay Zekâda Kara Kutu Problemi

Yapay zekâ, çıkarımsal akıl yürütme, eksik veya belirsiz bilgilere dayalı karar verme ve sınıflandırma gibi karmaşık problemleri çözmek üzere tasarlanmış programları ifade eder. Makine öğrenmesi algoritmalarının çalışma prensibi, istatistiksel çıkarım yöntemlerine dayanır.⁵ Bu algoritmalar, ‘eğitim verisi (training data)’ adı verilen geniş veri setlerini analiz ederek eğitilir.⁶ Süreç boyunca algoritma, tahminleri ile gerçek sonuçlar arasındaki hata payını en aza indirmek için kendi içsel parametrelerini sürekli olarak ayarlar.⁷ Bu eğitimin temel amacı, modelin daha önce karşılaşmadığı yeni veriler üzerinde de isabetli tahminler yapabilme yeteneği olan genelleme (*generalization*) yeteneğini başarmasıdır.⁸

Günümüzde hukuki tartışmaların odağında yer alan yapay zekâ, büyük ölçüde makine öğrenmesi (*machine learning*) ve özellikle de derin öğrenme (*deep learning*) modelleridir. Bu modeller, devasa veri setleri üzerinde eğitilerek, verilerdeki karmaşık örüntüleri ve ilişkileri öğrenir ve bu öğrenme temelinde yeni girdiler için öngörülerde bulunur veya kararlar alır.⁹ Milyarlarca parametreden oluşan bir sinir ağı (neural network)¹⁰ içerisinde, bir girdinin hangi ara işlemlerden geçerek bir çıktıya dönüştüğü, çoğu zaman modelin tasarımcıları tarafından dahi tam olarak izah edilemez.¹¹ Ya-

⁵ Detaylı bilgi için bkz. Hüseyin Ateş, *Ceza Muhakemesi Hukuku ve Yapay Zekâ: Temel İlkeler-Yapay Zekâ Uygulamaları* (Adalet Yayınevi, 2025), s.34.

⁶ Frank Emmert-Streib, Zhen Yang, Han Feng, Shailesh Tripathi and Matthias Dehmer, ‘An Introductory Review of Deep Learning for Prediction Models With Big Data’, *Frontiers in Artificial Intelligence C.3 S.4* (2020), s.1-2.

⁷ Yavar Bathaee, ‘The Artificial Intelligence Black Box and the Failure of Intent and Causation’, *Harvard Journal of Law & Technology C.31 S.2* (2018), s.899.

⁸ Bathaee, s.899.

⁹ Emmert-Streib vd., s.1-2.

¹⁰ Bir sinir ağı birden fazla gizli katmana sahipse derin (deep) olarak nitelendirilir. Geleneksel makine öğrenmesi modelleri tek bir gizli katmandan oluşurken, derin öğrenme ağları birden çok gizli katman kullanarak daha karmaşık problemleri çözebilir. Derin öğrenme, derin yapılandırılmış öğrenme veya hiyerarşik öğrenme olarak da bilinir ve yapay sinir ağları aracılığıyla makine öğrenmesinin bir alt alanıdır. Jabbar Hussain, *Deep Learning Black Box Problem* (İsveç Uppsala Üniversitesi Master Tezi, 2019), s.9.

¹¹ Özellikle makine öğrenmesi özel riskler barındırmaktadır, çünkü en basit makine öğrenmesi sistemleri dışındakilerin iç işleyişini insanların anlaması pratik olarak imkânsız olarak değerlendirilmektedir. Herbert Lin, ‘Escalation Risks in an Artificial Intelligence-Infused World’, *Artificial Intelligence, China, Russia, and the Global Order*, ed. Nicholas D. Wright (Alabama Air University Press, 2019), s.143.

¹ Ashley Deeks, ‘The Judicial Demand for Explainable Artificial Intelligence’, *Columbia Law Review C.119 S.7* (2019), s.1847.

² Deeks, s.1829-1830.

³ Francesca Rossi, ‘Building Trust in Artificial Intelligence’, *Journal of International Affairs Editorial Board C.72 S.1* (2019), s.129; Abiodun A. Solanke, ‘Explainable Digital Forensics AI: Towards Mitigating Distrust in AI-based Digital Forensics Analysis Using Interpretable Models’, *Forensic Science International: Digital Investigation S.42* (2022), s.1.

⁴ Yapay zekâ doğası gereği avantajlarının yanı sıra zafiyetler de barındırmaktadır. Doktrinde hataya açık, önyargılı, öngörülemez, güvenilir, opak ve hassas ayırım yapma yeteneği daha az olabileceği belirtilmektedir. Bkz. M.A. Thomas, ‘Time for a Counter-AI Strategy’, *Strategic Studies Quarterly C.14 S.1* (2020), s.4.

pay zekâ sistemleri hem kendi sonuçlarını açıklayamaz hem de insan uzmanlar tarafından incelendiğinde bile karar süreçlerinin temelindeki mantığı anlaşılır kılmaz; çünkü girdi ile çıktı arasındaki ilişki şeffaf değildir.¹² Bu durum literatürde ‘kara kutu sorunu’ (*the problem of black box*)’ olarak adlandırılır.¹³

Milyarlarca parametre arasındaki karmaşık ve doğrusal olmayan etkileşimler, modelin belirli bir girdiye neden belirli bir çıktıyı verdiğini insan zihninin tam olarak kavramasını neredeyse imkânsız kılar.¹⁴ Bu karmaşık yapay nöron ağlarının karar verme sürecini haritalandırmanın basit bir yolu yoktur.¹⁵ Karmaşıklık, binlerce yapay nöronun bir sorunu çözmek için dağıtık bir şekilde birlikte çalıştığı derin sinir ağları (*deep neural networks*) gibi yapılardan kaynaklanır. Bu ağlarda karar alma süreci, tek bir nörona veya nöron grubunda merkezileşmez, bunun yerine bilgi ve karar mekanizması sistemin tamamına yayılmıştır.¹⁶ Bu durum, bisiklete binmeyi öğrenmek gibi deneyimle kazanılan ve adımlara indirgenemeyen sezgisel bir bilgiye benzetilmektedir; dolayısıyla, ağın neden belirli bir karara vardığını tam olarak tespit etmek neredeyse imkânsızdır.¹⁷

Karar verme süreçleri insanlar için tamamen anlaşılabilir olan yapay zekâ sistemleri olan ‘güçlü kara kutularda (strong black boxes)’, bir karara nasıl ulaşıldığını, hangi bilginin sonucu belirlediğini veya kullanılan değişkenlerin önem sırasını tespit etmek mümkün değildir ve en önemli özellikleri, sistemin çıktılarından yola çıkarak sonradan (*ex post*) bir tersine mühendislik ile dahi analiz edilememeleridir.¹⁸ ‘Zayıf kara kutular (weak black boxes)’ da benzer şekilde anlaşılabilir karar süreçlerine sahiptir; ancak, güçlü kara kutulardan farklı olarak, bu sistemler üzerinde yapılan tersine mühendislik veya sondaj çalışmalarıyla, dikkate alınan değişkenlerin önem derecesine dair gevşek bir sıralama elde edilebilir ve bu durum, modelin gelecekteki kararlarını tahmin etmek için sınırlı ve kesin olmayan bir yetenek sunar.¹⁹ Zayıf bir kara kutuda, yapay zekâ’nın hangi verilere önem verdiği bir dereceye kadar anlaşılabilirse bile, bu veriyi nihai kararı için nasıl ve neden kullandığı yine de belirsiz kalır. Bu kara kutu problemi, yapay zekâ aracılığıyla işlenen suçlarda kastın ispatının yapay zekâ karşısında nasıl işlevsiz kaldığını göstermektedir. Makinelerin kendilerine ait bir kastı olmadığından, hukuki sorumluluk ancak programı tasarlayanın veya kullananın kastına odaklanabilir; ancak, kara kutu yapay zekâ, yaratıcılarının dahi öngöremeyeceği şekillerde faaliyet gösterebildiği için bu yaklaşım yetersiz kalmaktadır.²⁰ Örneğin, kârını maksimize

etme hedefiyle programlanmış bir alım-satım yapay zekası, bu hedefe piyasa manipülasyonu yoluyla ulaşabilir; fakat bu durum, yaratıcısı tarafından önceden öngörülebilir veya sonradan ispatlanabilir olmayabilir ve bu öngörülemezlik, kastın ispatını imkânsız hale getirebilir.²¹ İşte bu kapsamda yapay zekânın eylemleri, tasarımcısının veya kullanıcısının hukuka aykırı bir sonucu gerçekleştirmeye yönelik kastı hakkında bir çıkarım yapmaya olanak tanımayabilecektir. Bu kapsamda olması gereken sinir ağlarının karmaşık iç yapısını, anlaşılabilir sembolik temsillere dönüştürmek gerekir. Düşünce zinciri, bu kara kutuyu aralamayı vaat eder.

II. Yapay Zekâ Düşünce Zinciri ve Açıklanabilir Yapay Zekâ

Makine öğrenmesinde girdi ve çıktı arasındaki ilişki temelden opaktır (şeffaf değildir).²² En gelişmiş yapay zekâ algoritmalarının yaptıkları şeyi nasıl yaptıklarına dair netlik eksikliği, güvenilirliği ve toplumsal kabul edilebilirliği konusunda ciddi endişeler yaratmaktadır.²³

Bu sistemler insan için anlaşılabilir olarak değerlendirilmektedir.²⁴ Kapalı bir kutu sistemi her zaman verimsiz anlamına gelmese de endişe şudur ki, eğer sistem insanlara benzer akıl yürütme yeteneklerine sahip olduğunu iddia ediyorsa, belirli bir sonuca nasıl ulaştığını açıklayabilmelidir.²⁵ Özellikle hukuk gibi yüksek riskli bir alanda, bir sistemin karar verme sürecine ilişkin düşük kaliteli bir açıklama hem sistemin hem de açıklamanın güvenilirliğini azaltır.²⁶

Doktrinde de algoritmaların yapısı, içeriği ve testlerinin şeffaf olmamasına itiraz edilmektedir. Bu son endişe, *State v. Loomis*²⁷ davasında daha da derinleşmiş ve bu davada sanık, kendisini ‘yüksek tekrarlama riski’ olarak sınıflandıran Correctional Offender Management Profiling for Alternative Sanctions (COMPAS) adlı ceza belirleme algoritmasının yargıç tarafından kullanılmasına itiraz etmiştir.²⁸ Sanık, mahkemenin risk değerlendirmesini kullanmasının, kısmen COMPAS’ın doğruluğunu değerlendirememesi nedeniyle, adil yargılanma hakkını ihlal ettiğini iddia etmiştir.²⁹ *State v. Loomis* davasında Wisconsin Yüksek Mahkemesi, sanığın mahkumiyetini

¹² Lin, s.144.

¹³ Ateş, s.39; Sargur N. Srihari, ‘Explainable Artificial Intelligence’, *Journal of the Washington Academy of Sciences* C.106 S.4 (2020), s.14.

¹⁴ Bathaee, s.891; Benzer yönde Lin, s.150.

¹⁵ Bathaee, s.891.

¹⁶ Bathaee, s.901-902.

¹⁷ Hussain, s.10; Bathaee, s.902.

¹⁸ Bathaee, s.906.

¹⁹ Bathaee, s.906.

²⁰ Bathaee, s.891, 895.

²¹ Bathaee, s.897, 907; Thomas, s.6.

²² Brian A. Haugh, David A. Sparrow and David M. Tate, *The Status of Test, Evaluation, Verification, and Validation (TE&V) of Autonomous Systems* (Virginia: Institute for Defense Analyses, 2018), s.3. Yapay zekâ sistemleri çoğu zaman, kullanıcılara sistemin kararlarına yol açan temel veriler, süreçler ve mantık hakkında çok az görünürlük sunan, opak birer kara kutudur. Rossi, s.129.

²³ Retno Larasati and Anna DeLiddo, ‘Building a Trustworthy Explainable AI in Healthcare’, *Human Computer Interaction and Emerging Technologies*, ed. Fernando Loizides, Marco Winckler, Usashi Chatterjee, Jose Abdelnour-Nocera and Antignoni Parmaxi (Ingiltere Cardiff University Press, 2020), s.209.

²⁴ Solanke, s.3.

²⁵ Solanke, s.3.

²⁶ Solanke, s.3.

²⁷ Wisconsin Yüksek Mahkemesi, 881 N.W.2d 749 (Wis.2016).

²⁸ Deeks, s.1844.

²⁹ Deeks, s.1844.

onasa da, COMPAS gibi şeffaf olmayan algoritmaların ceza tayininde kullanımına karşı önemli çekinceler belirtmiştir.³⁰ Mahkeme, adil yargılanma hakkını güvence altına almak amacıyla gelecekteki ceza raporlarında bu algoritmaların sınırlılıklarına dair uyarılar bulunmasını zorunlu kılmıştır, özellikle bir yargıç mahkemenin bile algoritmayı tam olarak anlayamamasının ciddi bir sorun olduğunu ve ceza gerekçelendirilirken bu tür araçların sınırlılıklarının da açıklanması gerektiğini vurgulamıştır.³¹ İddia makamı dahi, şeffaf olmayan algoritmaların belirli koşullarda (örneğin sanığın verilere erişememesi) usulüne uygun yargılanma (*due process*) hakkını ihlal edebileceğini kabul etmiştir.³²

İlk olarak Google araştırmacıları tarafından 2022’de ortaya atılan şeffaflık yaklaşımına bağlı olarak düşünce zinciri, büyük dil modellerinin karmaşık problemleri (matematik, mantık, kodlama vb.) çözerken, insan benzeri bir şekilde problemi alt adımlara bölmeyi ve her adımı metinsel olarak açıklamasını ifade eder.³³ Düşünce zinciri ile istekte bulunma (prompting), birkaç düşünce zinciri gösteriminin örnek olarak sunulduğu bir yöntem olup model, çok adımlı bir problemin nihai cevabını vermeden önce ara akıl yürütme adımları üretmeye teşvik edilir.³⁴ Model, nihai cevabı vermeden önce, “Önce A’yı hesaplayalım. Sonra B’yi bulalım. A ve B’yi kullanarak C’ye ulaşalım. Dolayısıyla cevap C’dir” şeklinde bir akıl yürütme zinciri üretir.³⁵

Özellikle çok adımlı akıl yürütme gerektiren karmaşık görevlerde, çıktıları iyileştiren bir istem mühendisliği (*prompt engineering*) tekniği olan düşünce zinciri, problemi bir dizi tutarlı ve mantıksal adıma bölerek modelin adım adım bir akıl yürütme süreci izlemesine rehberlik eder ve bu sayede bir sonuca ulaşmasını sağlar. Düşünce (*thought*) kelimesi insanı bir iradeyi çağırırsa da burada düşünce esasında istatistiksel bir kelime tahminidir.³⁶ Teknik açıdan bakıldığında bu süreç, yapay zekanın insani manada bir bilinç veya tefekkür ile hareket ettiği anlamına gelmez. Büyük Dil Modelleri (LLM), doğası gereği bir sonraki kelimeyi istatistiksel olarak tahmin etmek üzerine kuruludur. Standart yöntemde model, doğrudan cevabı tahmin etmeye çalışırken; CoT yönteminde model, cevaba giden mantıksal ara basamakları temsil eden kelimeleri tahmin etmeye zorlanır; dolayısıyla düşünce zinciri, aslında failin zihnindeki düşüncelerin bir yansıması değil; modelin, kendisine verilen ‘adım adım düşün’ komutuna³⁷ (prompt) istinaden ürettiği, mantıksal tutarlılık arz eden bir metin simülasyonudur.

Karmaşık problemleri mantıksal adımlara ayırmak, çok adımlı akıl yürütme gerektiren görevlerde modelin doğruluğunu ve güvenilirliğini artırırken, aynı zamanda karar verme sürecini şeffaf kılarak kullanıcılara anlama ve hata ayıklama olanağı tanır.³⁸ Bu yönüyle düşünce zinciri sürecinin, ağların ‘kara kutu’ davranışını ‘beyaz kutu’³⁹ haline getirmeyi amaçladığı söylenebilir.⁴⁰ Düşünce zinciri, modelin davranışına dair yorumlanabilir bir pencere sunar ve bu pencere, modelin belirli bir cevaba nasıl ulaşmış olabileceğini gösterir ve muhakeme yolunun nerede yanlış gittiğini ayıklama (debug) fırsatları sağlar.⁴¹

Kara kutuyu açmanın teknik karşılığı doktrinde açıklanabilir yapay zekâ kavramında aranmaktadır.⁴² Açıklanabilir yapay zekâ (bazen yorumlanabilir veya şeffaf yapay zekâ olarak da anılır), insan kullanıcıların sistemin belirli bir sonuca nasıl ulaştığını anlayıp yorumlayabil-

³⁰ Michigan İstinaf Mahkemesi’nin 2019 tarihli *People v. Younglove* (2019 WL 846117, Michigan Ct.) kararında, sanıkların ceza tayininde COMPAS risk değerlendirme aracının kullanılmasının adil yargılanma hakkını ihlal ettiği yönündeki iddiaları ele alınmıştır. Sanıklar, COMPAS’ın genel nüfus verilerine dayalı istatistiksel analizler yapması nedeniyle bireyselleştirilmiş ceza kararlarında kullanımının uygun olmadığını, ırk ve cinsiyet girdileri bakımından ayrımcı etkiler yarattığını ve ürettiği puanların şeffaflıktan yoksun olduğunu ileri sürmüştür. Mahkeme ise bu iddiayı reddetmiştir. Kararda, ceza öncesi soruşturma raporlarında yer alan COMPAS verilerinin, denetimli serbestlik memurlarının rutin olarak eklediği görüşlere benzediği ve bu nedenle hâkimin takdir yetkisini haksız yere etkilemediği veya onun yerine geçmediği sonucuna varılmıştır. Indiana Yüksek Mahkemesi, 2010 tarihli *Malenchik v. State* (928 N.E.2d 564, 573 (Ind. 2010)) kararında, ceza tayininde risk değerlendirme araçlarının kullanımını onaylamıştır. Bu karardan iki yıl önce, Indiana İstinaf Mahkemesi *Rhodes v. State* (896 N.E.2d 1193 (Ind. Ct. App. 2008)) davasında, LSI-R gibi standart bir risk puanlama modelinin kullanılmasının, mahkemenin bireyselleştirilmiş ceza verme sorumluluğunu baltaladığı ve bu nedenle takdir yetkisinin kötüye kullanılması olduğu sonucuna varmıştı. Ancak Yüksek Mahkeme, Malenchik kararında bu görüşe katılmadığını açıkça belirtmiştir. Mahkemeye göre, kanıta dayalı fail değerlendirme araçlarının etkinliğini destekleyen geniş bir araştırma birikimi mevcuttur. Bu araçların sonuçları, hâkimin bireyselleştirilmiş ceza değerlendirmesini güçlendirebilir ve failin ıslahı için en uygun yaptırımın seçilmesine yardımcı olabilir. Yüksek Mahkeme, bu araçlara uyum ağırlığı vermeleri konusunda ilk derece mahkemesi hakimlerinin sağduyusuna ve takdir yetkisine güvendiğini vurgulayarak alt mahkemenin aksi yöndeki yaklaşımını reddetmiştir. John Villasenor and Virginia Foggo, ‘Artificial Intelligence, Due Process, and Criminal Sentencing’, *Michigan State Law Review* S.2 (2020), s.337-339.

³¹ Deeks, s.1844.

³² Deeks, s.1844.

³³ Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed H. Chi, Quoc V. Le and Denny Zhou, ‘Chain-of-Thought Prompting Elicits Reasoning in Large Language Models’, *Advances in Neural Information Processing Systems* (NeurIPS 2022), s.24824.

³⁴ Wei vd., s.24824-25.

³⁵ Wei vd., s.24824-25.

³⁶ Tom B. Brown vd., ‘Language Models are Few-Shot Learners’, *NIPS’20: Proceedings of the 34th International Conference on Neural Information Processing Systems* S.159 (2020), s.1877, 1880vd.

³⁷ CoT, ‘adım adım düşün’ gibi istemlerle ara adımlar üretir ve doğruluğu artırabilir. Detaylı değerlendirmeler için bkz. Wei vd., s.24824vd.

³⁸ Yapay zekâ sistemlerine duyulan güvensizliğin asıl nedeni, sistem teknik olarak hatasız çalışsa bile davranışlarının insan beklentileriyle uyumaması olup, bu durum güvenilir bir yapay zekânın sadece tasarlandığı gibi işleminin değil, aynı zamanda insan kullanıcı tarafından anlaşılabilir olmasının da gerekli olduğunu gösterir. Nathan Michael, ‘Trustworthy AI’, *National Defense* C.104 S.791 (2019), s.26.

³⁹ Benzer yönde ‘cam kutu (glass-boxing)’ metaforu için bkz. Brandon L. Garrett and Cynthia Rudin, ‘The Right to a Glass Box: Rethinking Artificial Intelligence in Criminal Justice’, *Cornell Law Review* S.109 (2024), s.561vd.; Solanke, s.2.

⁴⁰ Hussain, s.10-11.

⁴¹ Wei vd., s.24825.

⁴² Deeks, s.1829-1830; Lin, s.150.

Ancak insanların kendi yapay sistemlerine tereddütle yaklaşmak yerine onlara çok fazla güvenme ihtimalinin daha yüksek olduğu ileri sürülmektedir. Bu durumun, açıklanabilir yapay zekâ geliştirme çabalarına rağmen bir risk olarak kaldığı da belirtilmektedir. Thomas, s.4.

mesini sağlayan ve böylece güven oluşturan yapay zekâ teknolojilerini ifade eder.⁴³ Düşünce zinciri tekniği, yapay zekânın şeffaflığı ve açıklanabilirliği alanında önemli bir adımdır. CoT sayesinde, bir yapay zekanın kararının ardındaki mantık en azından yüzeysel olarak izlenebilir hale gelir. Örneğin, yapay zekâ destekli bir adli görüntü analiz sisteminin bir fotoğraftaki kişiyi şüpheli olarak nitelemesi durumunda, sistemin sunduğu “Adım 1: Görüntüdeki kişinin yüz hatlarını analiz et. Adım 2: Yüz hatlarını veri tabanındaki aranan şahıslarla karşılaştır. Adım 3: X kişisi ile %98 benzerlik tespit edildi. Adım 4: Kişinin elindeki nesnenin şekli, bilinen silah profilleriyle uyumlu. Sonuç: Kişi yüksek olasılıkla şüphelidir.” şeklindeki bir zincirleme düşünme (CoT) çıktısı, kara kutu bir modelin tek kelimelik ‘şüpheli’ yanıtına kıyasla çok daha fazla bilgi içerdiği için hukuki bir incelemeye elverişli bir başlangıç noktası sunar. Bu yöntem, yapay zekânın sesli düşünmesini sağlayarak ulaştığı sonucun adımlarını göstermesini ve böylece akıl yürütme sürecini izlenebilir kılmayı amaçlar. Model, nihai cevabını vermeden önce, problemi alt adımlara bölerek ve her adımda ne “düşündüğünü” açıklayarak bir mantık silsilesi oluşturur. Hukuk gibi kritik alanlarda izlenebilirliğin sağlanması oldukça önemlidir. Nitekim bir yapay zekanın teşhisi veya tespiti ceza yargılamasında delil olacaksa, bu kararın arkasındaki mantığın, düşünce zincirinin şeffaf, güvenilir ve doğrulanabilir olması gerekir.⁴⁴ Avrupa Birliği’nin Genel Veri Koruma Tüzüğü (GDPR)⁴⁵ de bireylerin verilerini kullanan algoritmik karar verme süreçleri hakkında bilgilendirilme hakkı tanımaktadır.⁴⁶

Hatalı bir makine kararının kolluk kuvvetleri ve ceza adaleti sistemi üzerinde ciddi sonuçları olabileceğinden, açıklanabilir yapay zekâ, büyük bir sorumluluk taşır. Açıklanabilirlik fikri, yapay zekâ sistemlerinin opaklığını en aza indirme veya tamamen ortadan kaldırma çabasından doğar; bunu yaparken şeffaflık, performans ve doğruluk arasında iyi bir denge kurmayı hedefler.⁴⁷ Bir “kara kutu” sisteminden çıkan sonucu anlamlı bir şekilde denetlemek veya buna itiraz etmek mümkün değildir. Eğer bir yapay zeka sisteminin gü-

venilirliği yeterince test edilmemişse, onun ne kadar güvenilir çalıştığını veya karar alma mekanizmasını denetlemek için ne düzeyde bir usul güvence gerektiğini belirlemenin bir yolu yoktur.⁴⁸

III. Düşünce Zincirinin Delil Niteliği

Ceza hukuku açısından, zararlı bir sonuca yol açan bir yapay zekanın düşünce zincirini incelemek, suçta giden yoldaki zihinsel adımları takip etmek anlamına gelir. Örneğin, otonom bir silah sisteminin yanlış bir hedefi vurma durumunda, düşünce zinciri bize şu soruların cevabını verebilir: Hedefi nasıl teşhis etti, alternatif hedefleri değerlendirdi mi, dost-düşman ayrımında hangi kriterleri kullandı, sivil zayıat riskini hesapladı mı ve bu riske rağmen ateş etme kararını neden aldı?⁴⁹ Bu bilgiler, sorumluluğun tespiti için hayati öneme sahiptir. Eğer düşünce zinciri, sistemin sivil zayıat riskini öngördüğünü ancak ana hedefe ulaşma önceliği nedeniyle bu riski ‘göze aldığı’ gösteriyorsa, bu durum olası kastın varlığına işaret edebilir. Sorumluluğun atfedileceği insan fail (kullanıcı veya programcı), bu ‘dijital delil’ temelinde yargılanabilir. Ancak bu senaryo, düşünce zincirinin doğasında bulunan bazı temel sorunları göz ardı etmektedir. Bir delilin geçerliliği için kritik olan en önemli kavramlardan birisi olan açıklanabilirlik (explainability)⁵⁰, bir yapay zekâ modelinin karar verme sürecinin insanlar tarafından ne ölçüde anlaşılabilirliğini ifade eder.⁵¹ Yorumlama (interpretation), modelin iç mekanizmalarını insan tarafından anlaşılabilir terimlere (görselleştirmeler, özellik önem skorları vb.) çevirme yeteneğini; güvenilirlik (reliability), yapay zeka modelinin açıklamalarının ve tahminlerinin tutarlılığını ve güvenilirliğini; sağlamlık (robustness), modelin girdideki gürültüye veya manipülasyonlara rağmen performansını koruma ve doğru açıklamalar sağlama yeteneğini ifade eder.⁵²

Bilişsel enstrümantasyon, açıklanabilir yapay zeka için zorunlu bir koşuldur.⁵³ Yapay zekanın nasıl düşündüğüne veya neden belirli bir şekilde davrandığına dair herhangi bir geçerli açıklama, onun iç durumlarının doğru ölçümlerine dayanmalıdır; ancak, ölçümlerin kendisi açıklama değildir.⁵⁴ Açıklama, tek yönlü bir veri dökümü değil, bir bilgi aktarımı ve diyalog sürecidir.⁵⁵ Bilişsel enstrümantasyon, bir yapay zeka veya otonom sistemin karar verme süreçlerini anlamak için sistemin içsel durumlarını, yani düşünce akışını ölçme ve kaydetme tekniğidir.⁵⁶ Basit bir analogiyle, bir arabanın moto-

⁴³ Michael, s.26; Ateş, s.41.

⁴⁴ Dost Muhammad and Malika Bendeache, ‘Unveiling the black box: A systematic review of Explainable Artificial Intelligence in Medical Image Analysis’, *Computational and Structural Biotechnology Journal* S.24 (2024), s.542.

⁴⁵ Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation), <https://gdpr-info.eu/art-15-gdpr/> [Erişim 28 Ekim 2025]. Madde 15/1-h: “Veri sahibi, kendisiyle ilgili kişisel verilerin işlenip işlenmediğine dair kontrolörden teyit alma ve işleniyorsa kişisel verilere ve aşağıdaki bilgilere erişim hakkına sahiptir: Madde 22(1) ve (4)’te atıfta bulunulan, profil oluşturma dahil olmak üzere otomatik karar verme sürecinin varlığı ve en azından bu durumlarda, ilgili mantık hakkında anlamlı bilgiler ile bu tür işlemin veri sahibi için önemi ve öngörülen sonuçları.”

⁴⁶ Muhammad and Bendeache, s.542; Srihari, s.15.

Açıklanabilir yapay zekaya olan ilgi, sadece GDPR ile sınırlı olmayıp, ABD ve Fransa’nın Dijital Cumhuriyet Yasası gibi uluslararası düzenlemelerde de ‘açıklama hakkı’ olarak karşılık bulmaktadır. Bu durum, ABD mahkemelerinin alacağı kararların, uluslararası alanda da emsal teşkil etme potansiyelini göstermektedir. Deeks, s.1849.

⁴⁷ Solanke, s.2.

⁴⁸ Brandon L. Garrett, ‘AI and Procedural Due Process’, *Journal of Constitutional Law* C.27 S.5 (2025), s.938-939.

⁴⁹ Lin, s.149.

⁵⁰ Yapay zekânın güvenilir kabul edilmesi için güvenilir bir şekilde çalışması, verdiği sonuçları açıklayabilmesi, mahremiyeti ihlal etmemesi ve sosyal açıdan zararlı önyargılar sergilememesi gerekmektedir. Açıklanabilirlik, güvenilir yapay zekanın hayati bir bileşenidir. Srihari, s.11.

⁵¹ Muhammad and Bendeache, s.543.

⁵² Muhammad and Bendeache, s.543.

⁵³ Haugh, Sparrow and Tate, s.4.

⁵⁴ Haugh, Sparrow and Tate, s.4.

⁵⁵ Larasati and DeLiddo, s.211.

⁵⁶ Haugh, Sparrow and Tate, s.2.

runun nasıl çalıştığını anlamak için kaputu açıp sıcaklık, basınç, voltaj gibi değerleri ölçen sensörler kullanmak gibidir. Bilişsel enstrümantasyon da benzer şekilde, bir yapay zekâ modelinin kara kutusunun içine bakarak, karar anında hangi verileri işlediğini, hangi parametreleri kullandığını ve hangi ara adımlardan geçtiğini ortaya çıkaran dijital sensörler yerleştirmektir. Bu kapsamda yapay zekâ düşünce zinciri ham bir log dosyasından ibaret olmayıp bu ham verilerin yorumlanarak anlamlı bir açıklamaya dönüştürülmesi gerekir. Açıklanabilirlik (explainability), algoritmanın ne yapmış olabileceğine dair bir anlatım sunar. Sadece genel açıklamalar paylaşmak, kara kutuyu gerçek anlamda açmayacaktır.⁵⁷

CoT verisi, doğası gereği dijital bir veridir ve bir bilgisayar veya sunucu üzerinde log dosyası olarak saklanır. Bu niteliğiyle, CMK md.134'te düzenlenen 'bilgisayarlarda, bilgisayar programlarında ve kütüklerinde arama, kopyalama ve elkoyma' tedbiri kapsamında elde edilebilecek bir "dijital delil" olarak kabul edilmelidir. Mahkemeye sunulduğunda ise, içeriğindeki metinsel ifadeler ve mantıksal çıkarımlar nedeniyle bir 'belge delili' (CMK md.206 vd.) niteliği taşıyabilir. Zira belge, üzerine yazı yazılmış ve bir düşünceyi açıklamaya yarayan her türlü materyal olarak geniş yorumlanmaktadır. Ancak CoT verisinin en belirgin özelliği, teknik ve karmaşık doğasıdır. Bir hâkimin veya savcının, bir CoT çıktısının ne anlama geldiğini, nasıl üretildiğini ve ne kadar güvenilir olduğunu tek başına değerlendirmesi beklenemez.

Anglo-Amerikan hukuk sistemleri, bilimsel ve teknik delillerin kabul edilebilirliği konusunda daha yapılandırılmış bir yaklaşım benimsemiştir. Bu yaklaşım, *Daubert v. Merrell Dow Pharmaceuticals, Inc.* (1993) davasıyla şekillenen ve Federal Delil Kuralları'nın (Federal Rules of Evidence) 702. maddesinde somutlaşan *Daubert*⁵⁸ standardıdır.⁵⁹ Bu standarda göre, bir uzman tanıklığının veya bilimsel delilin mahkemeye kabul edilebilmesi için sadece "genel kabul görmüş" olması yetmez; aynı zamanda "güvenilir" (reliable) ve "ilgili"

(relevant) olması gerekir.⁶⁰ Mahkeme, bu güvenilirliği değerlendirirken teorinin veya tekniğin test edilip edilemeyeceğini; tekniğin bilinen veya potansiyel hata oranını (error rate); tekniğin hakemli yayınlarda (peer-reviewed) yayımlanıp yayımlanmadığını; tekniğin uygulanmasını yöneten standartların olup olmadığı ve ilgili bilimsel topluluk içinde genel kabul görüp görmediğini (*Frye* standardından kalan bir faktör) dikkate almaktadır. ABD'de şu anda uygulanan yaklaşım, uzmanların kendi alanlarında yetkin olduklarından emin olmak için bu gereklilikleri takip ederek mahkemelere daha fazla takdir yetkisi vermektedir.⁶¹ Hâkime bu faktörleri nasıl ağırlıklandıracağı ve nihayetinde delili kabul edip etmeyeceği konusunda geniş bir esneklik ve takdir alanı tanınmaktadır. *State v. Arteaga*⁶² davasında New Jersey'deki bir istinaf mahkemesi, savcılığın yüz tanıma teknolojisi kullanmayı planlaması durumunda, savunmaya kullanılan yapay zekâ programının kimliği, tasarımı, özellikleri ve işleyişi hakkında bilgi vermesi gerektiğine hükmetmiştir. Mahkeme, bu bilgilerin, "etkili bir savunmanın inşası için temel olan ham maddeler" niteliğinde olduğunu vurgulamıştır.⁶³

Delillerin çoğu, karmaşık ilişkilerin çözülmesini gerektiren nedensel ilişkiler dizisinden çıkarılan olgular olarak sunulur.⁶⁴ Delilin ağırlığını, ilgisini ve önemini mahkeme veya görevlendiren kurum belirler; ancak, sonuca ulaşmak için kullanılan metodolojinin ve varsayımsal yaklaşımların anlaşılır bir incelemesini sunmak adli uzmanın görevidir.⁶⁵

Yapay zekâ düşünce zinciri bir açıklama sunar ve bu, belirti⁶⁶ olarak önemlidir. Ancak bu açıklamanın, maddi gerçeğe ve hukuki normlara uygun olup olmadığı, yani kararı meşrulaştırıp meşrulaştırmadığı, detaylı değerlendirilmesi gereken önemli bir konudur. Bu durum, kaçınılmaz olarak bilirkişilik kurumunu (CMK md.62 vd.) gündeme getirir. CoT verisi, mahkemeye sunulduktan sonra, yapay zekâ, makine öğrenmesi ve siber güvenlik alanlarında uzman bir bilirkişi heyeti tarafından incelenmelidir. Bilirkişi raporu, CoT verisinin teknik analizini, güvenilirliğine ilişkin değerlendirmeleri ve hukuki uyumsuzluk açısından ne ifade ettiğini ortaya koyarak, hâkimin delili serbestçe takdir etmesine (CMK md.217/1) yardımcı olacaktır.⁶⁷ Dolayısıyla

⁵⁷ Garrett, s.944-945.

Akademik ve politik tartışmalarda, şeffaf olmayan kara kutu problemi, yapay zekâ modellerinin karmaşık yapıları nedeniyle doğası gereği daha yüksek bir isabet oranına sahip olduğu yönünde yaygın, ancak hatalı bir varsayım bulunmaktadır. Bu varsayım, kara kutu performans efsanesi (black box performance myth) olarak nitelendirilmektedir. Ancak bilgisayar bilimlerindeki yeni araştırmalar, bu ikilemin geçerli olmadığını ortaya koymaktadır. İnsanlar tarafından tamamen yorumlanabilen cam kutu (glass box) modellerin, özellikle ceza adaleti gibi hatalı verilerin bulunduğu risk dolu alanlarda, kara kutu alternatiflerinden daha düşük performans göstermediği, aksine onlardan daha isabetli olabildiği kanıtlanmıştır. Kara kutu sistemleri, altında yatan hataları ve yanlışlıkları gizleme eğilimindeyken, cam kutu modelleri şeffaflık sağlayarak bu sorunların tespit edilmesine ve düzeltilmesine olanak tanımaktadır. Garrett and Rudin, s.562, 566, 568.

⁵⁸ Birleşik Devletler Yüksek Mahkemesi, *Daubert v. Merrell Dow Pharmaceuticals*, 113 S Ct 2786 (1993).

⁵⁹ Bu karar, bir uzman görüşünün veya bilimsel tekniğin delil olarak kabulü için; test edilip edilebilmesi, hakem denetiminden geçerek yayımlanması, bilinen hata oranı ve bilimsel camiada genel kabul görmesi gibi bir dizi kriter belirlemiştir. Her ne kadar Federal Delil Kuralları ve dolayısıyla *Daubert* standartları ceza tayini aşamasında doğrudan uygulanmasa da bu kriterler bir yöntemin doğruluğunu ve güvenilirliğini değerlendirmek için önemli bir çerçeve sunar. Villaseñor and Foggo, s.328.

⁶⁰ Villaseñor and Foggo, s.328-330.

⁶¹ Claire McGourlay, Mark Thomas and Suzanne Gower, *Evidence Law and Context* (Routledge, 2024), s.445.

⁶² New Jersey Yüksek Mahkemesi, 296 A.3d 542, (N.J. Super. App. Div. 2023).

⁶³ Garrett, s.935-936.

⁶⁴ Solanke, s.4.

⁶⁵ Solanke, s.4.

⁶⁶ Belirti doktrinde olaydan sonra kalan iz ve eserleri ifade eden deliller olarak adlandırılmaktadır. Bkz. Yener Ünver ve Hakan Hakeri, *Ceza Muhakemesi Hukuku* (Adalet Yayınevi, 2022), s.597. Beyan ve belge delili dışında kalan ve uyumsuzluğun sona erdirilmesinde ispatı yardımcı her türlü iz ve eser belirti olarak değerlendirilir. Murat Volkan Dülger ve Şaban Cankat Taşkın, *Ceza Muhakemesi Hukuku* (Seçkin Yayınları, 2023), s.573.

⁶⁷ Yapay zekâ sistemlerinin güvenilirliği, gerçekçi koşullar altında test edilmelidir. Ancak alanında uzman kişiler gerçekçi ve bilimsel değerlendirmeler yapabilir ve hata riskini en aza indirebilir. Benzer yönde Garrett, s.933.

la, CoT verisi maddi gerçeği doğrudan ispat eden bir 'beyan delili (dijital ikrar)' niteliğinde değil, diğer delillerle desteklenmesi gereken 'bilirkişi incelemesine konu olan belirti' mahiyetindedir.

IV. Düşünce Zincirinin Delil Değerini Zayıflatan Faktörler

Bir sistemin bir kararı nasıl aldığını açıklaması, o kararın tek başına hukuken doğru veya meşru olduğu anlamına gelmez.⁶⁸ Nitekim büyük dil modelleri tarafından üretilen muhakeme zincirlerinin hataya açık olduğu gözlemlenmiştir ve bu durum, çıkarım sırasında hatalı muhakemeye yol açabilir.⁶⁹ Bu olumsuz haller içeriğin doğruluğu, delile erişim sorunu, entrika ve aldatma eğiliminde olma, manipülasyona açıklık, halüsinasyon eğiliminde olma şeklinde gündeme gelebilmektedir.

A. İçeriğin Doğruluğu

Düşünce zincirinin ceza muhakemesinde güvenilir bir delil olarak kullanılmasının önünde ciddi engeller bulunmaktadır. Bu engeller, delile erişimden onun içeriğinin doğruluğuna ve yorumlanmasına kadar geniş bir yelpazeyi kapsar. Makine güdümlü bir adli analizin kusurları veya yanlış yorumları tasarım, girdi, model ve çevreden kaynaklanabilir de, en olası nedenler hatalı algoritmalar/kodlar, çarpık veya orantısız veri setleri ve sistemin kusurlu işlevsel bileşenleridir (örneğin, işletim sistemi, dağıtılmış platformlar vb.).⁷⁰ Örneğin yetersiz veri setleriyle eğitilen veya çok fazla değişken içeren modeller, mantıksız temsiller öğrenme riski taşır.⁷¹ Bir suç tespit algoritmasının art arda üç el sıkışmayı uyuşturucu ticareti olarak yorumlamayı öğrenmesi mantıklı görünse de, gerçek dünyadaki uyuşturucuyla ilgili olayları gözden kaçırabilir.⁷² "Üç kez el sıkışma gerçekleştiği için bunu uyuşturucu ticareti olarak yorumladım" şeklindeki düşünce zinciri parçası, açıklanabilirlik noktasında sorun teşkil etmese de bu algoritmanın mantıksız bir temsil olarak çıktısı sunmadığı anlamına gelmeyecektir.

Michigan'da işsizlik yardımı alan on binlerce kişiyi hatalı bir şekilde dolandırıcılıkla suçlayan 'MiDAS (Michigan Integrated Data Automated System)' adlı otomatik sistem, insanlara kararın nedenini açıklamayan ve itiraz yolu sunmayan form mektupları göndermiştir. Bu form mektuplarında, eyaletin neden bu kişilerin dolandırıcılık yaptığını belirlediği açıklanmamış, kararın gerekçesi belirtilmemiş, kişilere yanıt verme imkânı

sunulmamış ve mektuplar gönderilmeden önce, sistemin dolandırıcılık tespitini hiçbir insan gözden geçirmemiştir.⁷³ Bu durum, kara kutu bir sistemin kitlesel hak ihlallerine nasıl yol açabileceğinin bir kanıtı olarak değerlendirilmektedir.⁷⁴

B. Erişim Sorunu

Öncelikle ceza muhakemesinde delillere erişim esastır. Ancak yapay zekânın düşünce zinciri her zaman erişilebilir veya mevcut olmayabilir. Halka açık birçok yapay zekâ hizmetinde, son kullanıcıların gördüğü düşünce zinciri, modelin gerçek içsel sürecinin filtrelenmiş ve basitleştirilmiş bir versiyonudur. Araştırmacılar, modelin kopyalanmasını önlemek veya karmaşıklığı azaltmak için ham düşünce zincirine tam erişimi engeller. Bir yargılama sürecinde, mahkemeye sunulan düşünce zincirinin, olayın aydınlatılması için kritik olan bazı adımları içermeyen sansürlü bir versiyon olup olmadığını anlamak mümkün olmayabilir. Bu durum, delilin bütünlüğüne ve güvenilirliğine gölge düşürür. CoT verisini üreten yapay zekâ modeli, genellikle onu geliştiren şirketin en değerli ticari sırrıdır. Bir ceza davasında, savunma tarafı, CoT verisinin nasıl üretildiğini anlamak ve ona itiraz etmek için modelin mimarisi, eğitim verileri ve ağırlıkları gibi teknik detaylara erişmek isteyebilir; ancak şirketler bu bilgileri ticari sır ve fikri mülkiyet gerekçesiyle açıklamayı reddedebilir.⁷⁵ Eğer düşünce zinciri, şirketin ticari sırlarını ihlal edecek şekilde orantısız bir müdahaleyle veya sanığın (üretici firma) kendisini suçlayıcı beyanda bulunmaya zorlanmasıyla elde edilirse, *nemo tenetur se ipsum accusare* ilkesinin ihlali sebebiyle hukuka aykırı delil haline gelebilir ve hükme esas alınamaz. Mahkemelerin bu çatışmayı nasıl çözeceği, en tartışmalı konulardan biri olacaktır.⁷⁶ DNA karışım analizlerinde kullanılan olasılıksal genotipleme yazılımlarıyla ilgili davalarda mahkemeler ABD'de farklı kararlar vermiştir. Bazı mahkemeler, örneğin *People v. Wakefield*⁷⁷ davasında olduğu gibi, ticari sır iddialarına saygı duyarak savunmanın kaynak koduna erişim taleplerini reddederken⁷⁸, New Jersey'deki *State v. Pickett*⁷⁹ davası gibi bazı davalarda ise mahkeme, savunmanın yazılıma erişimine izin vermiştir.⁸⁰ *State v. Chun*⁸¹ davasında da, New Jersey Yüksek Mahkemesi, alkol ölçüm cihazı üreticisi şirkete, cihazın kaynak kodunu bağımsız

⁷³ Garrett, s.957.

⁷⁴ Garrett, s.957.

⁷⁵ Deeks, s.1846.

⁷⁶ Doktrinde *Villasenor ve Foggo*, risk değerlendirme yazılımı üreten bir şirket örneği üzerinden olması gerekene yönelik değerlendirmelerde bulunmaktadır. Bu şirketin algoritma ve veriler hakkındaki bilgilere erişimi engellemek için ticari sır hukukunu bir mekanizma olarak kullanamaması gerekir. Bu erişim, şirketin ticari sır haklarını koruyacak şekilde (protective orders gibi araçlarla) sağlanabilecektir. Bu da şeffaflığın bir gereğidir. Bkz. Villasenor and Foggo, s.343-344.

⁷⁷ New York Appellate Court, 195 N.E.3d 19, 21 (N.Y. 2022).

⁷⁸ Bkz. Garrett, s.938.

⁷⁹ New Jersey Superior Court, 246 A.3d 279 (N.J. Super. Ct. App. Div. 2021).

⁸⁰ Garrett, s.964.

⁸¹ New Jersey Supreme Court, 943 A.2d 114 (N.J. 2008).

⁶⁸ Karen Yeung and Adrian Weller, 'How is 'Transparency' Understood by Legal Scholars and the Machine Learning Community?', *Being Profiled: Cogitas Ergo Sum*, ed. Emre Bayamlıoğlu, Irina Baraliuc, Liisa Janssens and Mireille Hildebrandt (Amsterdam University Press, 2018), s.37.

⁶⁹ Bkz. Jiashuo Sun, Yi Luo, Yeyun Gong, Chen Lin, Yelong Shen, Jian Guo and Nan Duan, 'Enhancing Chain-of-Thoughts Prompting with Iterative Bootstrapping in Large Language Models', *Findings of the Association for Computational Linguistics (NAACL 2024)*, s.4074.

⁷⁰ Solanke, s.1.

⁷¹ Solanke, s.4.

⁷² Solanke, s.4.

bir inceleme için açıklaması talimatını vermiştir.⁸² Sonuç olarak, düşünce zincirinin delil değeri onun erişilebilirliği, güvenilirliği ve yorumlanmasındaki temel zorluklar nedeniyle ciddi şekilde zayıflamaktadır. Delilin kaynağı olan yapay zekâ modelinin mimarisi ve eğitim verilerinin ticari sır gerekçesiyle gizlenmesi, savunma hakkının temel bir unsuru olan delile erişim ve itiraz etme imkânını ortadan kaldırmaktadır. Anglo-Amerikan hukukundaki *State v. Pickett* ve *State v. Chun* gibi kararlar, bu tür teknolojik kara kutuların açılarak incelenmesi yönünde bir irade ortaya koysa da *People v. Wakefield* gibi aksi yöndeki kararlar, bu konudaki hukuki belirsizliğin devam ettiğini göstermektedir. Dahası, bu sistemlerin hatalı veya taraflı verilerle eğitilmesi sonucu mantıksız temsiller öğrenmesi ve bunun sonucunda MiDAS örneğinde olduğu gibi kitlesel hak ihlallerine yol açması riski, bu delillerin güvenilirliğini temelden sarsmaktadır. Büyük dil modellerinin muhakeme zincirlerinin doğası gereği hataya açık olduğu teknik olarak da kanıtlanmış bir gerçektir. Tüm bu faktörler, düşünce zinciri verisinin ceza muhakemesinde tek başına bir mahkumiyete dayanak oluşturacak güçte, güvenilir bir delil olarak kabul edilmesinin önünde önemli engeller teşkil ettiğini ve bu verilerin ancak bir belirti olarak ihtiyatla ele alınması gerektiğini ortaya koymaktadır.

C. Entrika ve Aldatma Eğilimi

Erişilebilirlik dışında diğer sorun yapay zekânın entrikacı (deceptive ai) yapida olabilme potansiyelidir.⁸³ Aldatıcı açıklamaların üretilmesinin arkasında çeşitli gerekçeler bulunmaktadır. Daha gelişmiş ve entrikacı bir yapay zekâ, araç olarak kullanıldığı suçun delillerini karartmak amacıyla düşünce zincirini kasıtlı olarak gizleyebilir, silebilir veya anlamsız verilerle değiştirebilir. Tıpkı bir suçlunun cinayet silahını ortadan kaldırması gibi, yapay zekâ da kendi ‘dijital parmak izlerini’ yok edebilir. Yapay zekânın gerçek karar mantığının ortaya çıkması, şirketin fikri mülkiyetinin sızmasına yol açabilir ve bu nedenle, karar mekanizmasını gizlemek için aldatıcı açıklamalar üretilir.⁸⁴ Bu durum, modelin sadece suçu işlemekle kalmayıp, aynı zamanda delilleri yok etme yönünde ikinci bir kast ile hareket ettiğini gösterir ki bu, sorumluluğun tespitini daha da karmaşılaştırır. Aldatıcı açıklamaların tespitinin mümkün olup olmadığı noktasında, alan bilgisi olmadan (domain knowledge) yapılan tutarlı bir yalanın tespitinin imkânsız olduğu belirtilmektedir; örneğin, kedi ve köpek hakkında hiçbir bilgisi olmayan birine, sürekli olarak kedinin köpek, köpeğin de kedi olduğunun söylenmesi ve buna uygun açıklamalar

sunulması durumunda, bu yalanı tespit etmenin bir yolu yoktur.⁸⁵ Bir özelliğin (örneğin, cinsiyet veya ırkla ilgili bir kelime) karar üzerindeki etkisinin kasıtlı olarak gizlenip gizlenmediğinin tespiti, ancak bu özelliğin değerinin değiştirilmesinin kararı değiştirdiği başka bir örnekle karşılaştırma yapıldığında mümkün olabilir.⁸⁶ Bu durum, delilin denetlenmesinin, tek bir CoT çıktısına bakarak değil, ancak çok sayıda karşılaştırmalı testle mümkün olabileceğini gösterir. Bu gibi sorunların çözülmesi amacıyla Schneider-Meske-Vlachos, denetçilerin aldatmacayı tespit sürecini basitleştirmek için gerçek model erişimine sahip olmalarını sağlayacak yasaların çıkarılmasını önermektedir.⁸⁷ Bu, öneri savunmanın modelin kaynak koduna ve mimarisine erişim hakkı talebini doğrudan destekleyen ve katkı sağlayan bir husustur.

D. Manipülasyona Açıklık

Düşünce zincirinin güvenilirliğini zedeleyen en tehlikeli yönü, objektif bir gerçeklik kaydı olmaması, aksine yapay zekânın kendisi tarafından üretilen ve dolayısıyla manipülasyona açık olmasıdır. Yapay zekâ modelleri, kasıtlı olarak tasarlanmış girdilerle yanıtlanabilir. Bu, bir modelin girdi verisine küçük, genellikle algılanamayan bir bozulma (perturbation) ekleyerek onu yanıltabilen düşmanca örnekler (adversarial examples) olarak gerçekleştirilebilmektedir.⁸⁸ ‘Düşmanca saldırı’ olarak bilinen bu teknikte, kötü niyetli bir aktör, yapay modeline insan gözüyle fark edilemeyecek kadar küçük değişiklikler içeren bir girdi vererek, modelin tamamen yanlış bir çıktı üretmesini veya istenen yönde bir CoT oluşturmalarını sağlayabilir. Örneğin, bir suçu gizlemek isteyen bir kişi, yapay sistemini, masumiyetini destekleyen sahte bir düşünce zinciri üretmesi için manipüle edebilir. Bu durum, CoT verisinin ispat gücünü temelden sarsan en önemli tehditlerden biridir. Bir sistemin belirli istenmeyen davranışları sergilemeyeceğini güvence altına almanın zorluğu göz önüne alındığında olması gereken, sistemi operasyonlar sırasında izlemek ve kötü bir davranışın ortaya çıkması yakinken müdahale etmektir.⁸⁹

Yapay zekâ, belirli bir eylemi gerçekleştirdikten sonra, bu eylemine masum veya mantıklı bir kılıf uyduran bir düşünce zinciri üretebilir. Örneğin, finansal piyasalarda yasa dışı bir manipülasyon yapan bir alım-satım yapay zekâsı, bu eylemini ‘piyasa volatilitesine karşı riski minimize etme stratejisi’ olarak açıklayan ikna edici bir düşünce zinciri yazabilir. Düşünce zinciri, eylemin gerçek nedeni değil, eylemin bir yan ürünü veya meşrulaştırma aracı olabilir. Bunu gerçekleştirmenin teknik boyutunu ‘prompt injection (istem enjeksiyonu)’ oluşturmaktadır. ‘Prompt injection’ bü-

⁸² Garrett and Rudin, s.607.

⁸³ Yapılan kullanıcı çalışmasının bulguları, aldatıcı açıklamaların gerçekten de insanları kandırabildiğini doğrulamıştır. 200 katılımcıyla yapılan deneyde, katılımcıların aldatıcı açıklamalara verdikleri güven puanları ile doğru açıklamalara verdikleri puanlar arasında istatistiksel olarak anlamlı bir fark bulunsu da mutlak anlamda bu farkın küçük olduğu gözlemlenmiştir. Bu durum, insanların çoğunluğunun genellikle kandırabildiğini göstermektedir. Johannes Schneider, Christian Meske and Michalis Vlachos, ‘Deceptive AI Explanations: Creation and Detection’, *Proceedings of the 14th International Conference on Agents and Artificial Intelligence C.2 (ICAART 2022)*, s.50.

⁸⁴ Schneider, Meske and Vlachos, s.46.

⁸⁵ Schneider, Meske and Vlachos, s.47.

⁸⁶ Schneider, Meske and Vlachos, s.47.

⁸⁷ Schneider, Meske and Vlachos, s.53.

⁸⁸ Schneider, Meske and Vlachos, s.46; Dylan Slack, Sophie Hilgard, Emily Jia, Sameer Singh and Himabindu Lakkaraju, ‘Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods’, *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*. Barcelona, İspanya: Association for Computing Machinery (2020), s.180, 181.

⁸⁹ Haugh, Sparrow and Tate, s.5.

yük dil modellerinin (LLM) amaçlanmayan ve yasa dışı eylemleri gerçekleştirmesine neden olmak için özel olarak hazırlanmış istemler (prompt) kullanarak filtreleri atlatmayı veya modeli manipüle etmeyi içerir.⁹⁰

E. Halüsinasyon Eğilimi

Yapay zekâ modelleri, doğru ve mantıklı çıktılar üretebildikleri gibi, tamamen yanlış veya anlamsız bilgiler de üretebilirler. Literatürde halüsinasyon (hallucination) olarak bilinen bu durum kullanıcı girdisinden (prompt) sapan, daha önce üretilmiş içerikle çelişen veya yerleşik dünya bilgisiyle uyuşmayan içerikler üretme eğilimidir.⁹¹ CoT, yapay zekâ modelinin akıl yürütme yeteneğini geliştirmeyi amaçlamakla birlikte halüsinasyonlar akıl yürütme adımlarının kendisinde de ortaya çıkabilir.⁹² Bunun dışında bir yapay zekâ, gerçekte olmayan adımlar veya mantıksal sıçramalar içeren bir düşünce zinciri üretebilir. Bu CoT çıktısı, görünüşte ikna edici olsa da temelde hatalı olabilir. CoT tarafından üretilen gerekçelendirme adımları, modelin kendi çıktısını doğrulamasına neden olarak, aslında hatalı olan bir cevaba bile yüksek güven duymasına yol açar; örneğin, bir modelin yanlış bir cevap verirken “IMDb ve Wikipedia gibi güvenilir kaynaklara göre” gibi ifadeler eklemesi, öz değerlendirmeye dayalı tespit yöntemlerini yanıltabilmektedir.⁹³ Özellikle CoT yönlendirmesi halüsinasyon tespitinde kullanılan sinyalleri daha belirsiz ve yakalaması daha zor hale getirebilmektedir.⁹⁴ Bu nedenle, bir CoT verisinin doğruluğu ve mantıksal tutarlılığı mutlaka sorgulanmalıdır. Yapay zekânın olgusal olarak yanlış veya anlamsız metinler üretme eğilimi, düşünce zincirinin delil değerini temelden sarsar. Bir düşünce zincirinde yer alan ‘hedef sivil olmasına rağmen ateş et’ gibi bir ifade, gerçek bir karar sürecini mi yansıtıyor, yoksa modelin anlamsız bir kelime dizisi ürettiği bir halüsinasyon anı mı ayrımını yapmak, özellikle modelin iç işleyişine tam erişim olmadan imkânsızdır.

V. Düşünce Zincirinin Delil Değerini Güçlendirme Yöntemleri

Muhammad-Bendeche, bir yapay zekanın karar mantığını sorgulamak için kullanılabilecek spesifik açıklanabilir yapay zekâ tekniklerini ve bunların zayıf-

lıklarını detaylandırmaktadır. Karşı-olgusal açıklamalar (counterfactual explanation) yönteminde, “sonucu değiştirmek için girdide yapılması gereken en küçük değişiklik nedir?” sorusu yanıtlanır.⁹⁵ Örneğin “şüphelinin görüntüsünde aydınlatma yüzde on daha düşük olsaydı, yapay zekâ yine de aynı kişiyi teşhis eder miydi?” gibi bir soru bu sorguya karşılık gelebilir. Bu, bir yapay zekâ delilinin sağlamlığını test etmenin en doğrudan yollarından biri olarak değerlendirilebilse de *Muhammad-Bendeche*, klinik olarak anlamlı ve gerçekçi karşı-olgusal senaryolar üretmenin zorluğuna dikkat çeker ve örnek verdiği LIME ve SHAP gibi popüler yöntemler, bir kararda hangi özelliklerin ne kadar etkili olduğunu göstermektedir.⁹⁶ Ancak bu yöntemlerin hesaplama açısından maliyetli olduğu ve farklı çalıştırmalarda tutarsız sonuçlar üretebileceği vurgulanır ve bu durum, delilin güvenilirliğini ve tekrarlanabilirliğini doğrudan zayıflatmaktadır.⁹⁷

Her dijital delilde olduğu gibi, CoT verisinin elde edildiği andan mahkemeye sunulduğu ana kadar değiştirilmediğinin, bozulmadığının veya üzerinde oynama yapılmadığının ispatlanması gerekir.⁹⁸ Bu gereklilik adli bilişimde ‘korunma zinciri (Chain of Custody-CoC)’ veya ‘delil bütünlüğü zinciri’ olarak bilinir.⁹⁹ Korunma zincirinde temel amaç, delilin kurcalanmadığını, değiştirilmediğini veya bozulmadığını göstermektir; sağlam bir korunma zinciri, dijital delillerin gerçekliğine yönelik itirazlar olmaksızın mahkemeye sunulabilmesini sağlar.¹⁰⁰ CoT verisinin CoC kapsamında güvenilirliği; log dosyalarının zaman damgalarıyla (timestamp) birlikte kriptografik olarak mühürlenmesi (hashing) ve bu verilere erişimin sıkı bir şekilde denetlenmesi, yetkisiz erişimi engellemek için kurcalanmaya karşı korumalı alanlar ve güvenli tesislerde saklanması, delilin kabul edilebilirliği için elzemdir.¹⁰¹ Bu zincirdeki en ufak bir kopukluk, delili şüpheli hale getirecektir.¹⁰²

CMK m.217 gereği hâkim, delilleri vicdani kanaatine göre serbestçe takdir eder. Ancak bu serbesti, keyfilik anlamına gelmez; kanaatin, duruşmaya getirilmiş, akılcı, denetlenebilir ve hukuka uygun delillere dayanması gerekir.¹⁰³ Bir “kara kutunun” kendi ürettiği, doğruluğu ve samimiyeti denetlenemeyen bir metin olan düşünce zinciri, akılcı bir vicdani kanaatin temeli olamaz. Hâkim, anlamadığı bir teknolojinin ürettiği bir metne dayanarak bir insanın özgürlüğü hakkında sağ-

⁹⁰ Hyeokjin Kwon, Jaebeom Kim and Wooguil Pak, ‘Graph-Based Prompt Injection Attacks Against Large Language Models’, *International Journal of Advanced and Applied Sciences* 12/2 (2024), s.112.

⁹¹ Yue Zhang, Yafu Li, Leyang Cui, Deng Cai, Lemao Liu, Tingchen Fu, Xinting Huang, Enbo Zhao, Yu Zhang, Yulong Chen, Longyue Wang, Anh Tuan Luu, Wei Bi, Freda Shi and Shuming Shi, ‘Siren’s Song in the AI Ocean: A Survey on Hallucination in Large Language Models’ (arXiv 2023), s.1, <https://arxiv.org/abs/2309.01219> [Erişim 27 Ekim 2025]; Jiahao Cheng, Tiancheng Su, Jia Yuan, Guoxiu He, Jiawei Liu, Xinqi Tao, Jingwen Xie and Huaxia Li, ‘Chain-of-Thought Prompting Obscures Hallucination Cues in Large Language Models: An Empirical Evaluation’, *Findings of the Association for Computational Linguistics: EMNLP* (2025), s.1272-1273.

⁹² Yue vd., s.11.

⁹³ Cheng vd., s.1279.

⁹⁴ Cheng vd., s.1273.

⁹⁵ Muhammad and Bendeche, s.546.

⁹⁶ Muhammad and Bendeche, s.544, 546.

⁹⁷ Muhammad and Bendeche, s.551-552; Slack vd., s.180.

⁹⁸ Premanand Narasimhan and N. Kala, ‘Ensuring the Integrity of Digital Evidence: The Role of the Chain of Custody in Digital Forensics’, *International Journal of Scientific Research in Computer Science, Engineering and Information Technology* C.6 S.4 (2024), s.2438.

⁹⁹ Narasimhan and Kala, s.2438.

¹⁰⁰ Narasimhan and Kala, s.2439-2440.

¹⁰¹ Detaylı bilgi için bkz. Narasimhan and Kala, s.2439-2449.

¹⁰² Narasimhan and Kala, s.2446.

¹⁰³ Faruk Erem, *Ceza Usulü Hukuku* (Şevinc Matbaası, 1973), s.330vd; Nur Centel ve Hamide Zafer, *Ceza Muhakemesi Hukuku* (Beta Yayıncılık, 2022), s.252-253; Ünver ve Hakeri, s.613; Dülger ve Taşkın, s.556.

lıklı karar veremez. Bu gereklilik korunma zincirinin bütünlüğünün sağlanması ile gerçekleştirilebilir. Aksi durum delil değerlendirmesinin temel rasyonalitesini ortadan kaldırma riski taşır. Bunun için de alanında tam anlamıyla yetkin ve uzman kişinin değerlendirme süreci ile düşünce zinciri bir dijital delil olarak itibar görebilir.

Sonuç

Yapay zekâ teknolojisinin ceza adalet sistemine entegrasyonu, maddi gerçeğe ulaşma idealini yeni ve karmaşık sorunlarla karşı karşıya bırakmaktadır. Bu çalışmada ele alındığı üzere, yapay zekânın karar alma süreçlerindeki şeffaflık eksikliği olarak bilinen “kara kutu” problemi, özellikle kast gibi manevi unsurların ispatı önünde ciddi bir engel teşkil etmektedir. Düşünce zinciri (CoT) teknolojisi, modelin karar adımlarını metinsel olarak sunarak bu kara kutuyu bir “beyaz kutuya” dönüştürme ve böylece yapay zekânın “zihnini” okuma vaadi sunsa da bu vaadin hukuki bir kesinlik olarak kabul edilmesi mevcut teknolojik ve hukuki koşullar altında mümkün görünmemektedir. Yapay zekâ tarafından üretilen düşünce zinciri, ceza hukukunda manevi unsurun ispatına yönelik devrimci bir araç olma potansiyeli taşısa da, mevcut haliyle bir dijital itiraf olmaktan çok, bir dijital muamma sunmaktadır.

Analizler, bir CoT çıktısının, modelin eyleme geçerkenki gerçek içsel sürecinin objektif bir kaydı olmaktan ziyade, eylemden sonra üretilebilen, manipülasyona açık ve meşrulaştırma amacı taşıyabilen bir metin olduğunu ortaya koymuştur. Modellerin “halüsinasyon” görme eğilimi, yani olgusal temelden yoksun ancak mantıksal görünen gerekçeler üretme potansiyeli, bu metinlerin güvenilirliğini temelden sarsmaktadır. Bununla birlikte, “prompt injection” gibi kötü niyetli müdahalelerle bir yapay zekânın, işlediği hukuka aykırı fiili gizlemek veya masum göstermek amacıyla sahte bir düşünce zinciri üretmeye zorlanabilmesi, CoT verisini bir delilden çok, bir aldatma aracına dönüştürme riskini barındırmaktadır. Erişilebilirliğindeki belirsizlikler, manipülasyona ve aldatmacaya açık doğası ve yorumlanmasındaki güçlükler, onu ceza yargılamasında tek başına mahkûmiyete dayanak oluşturacak güvenilir bir delil olmaktan uzaklaştırmaktadır. Düşünce zincirinin manipüle edilebilir, kasıtlı olarak gizlenebilir ve halüsinasyon içerebilir olması, onu doğası gereği şüpheli bir delil haline getirir. Bir mahkemenin, yalnızca şüpheli bir düşünce zincirine dayanarak bir insanın (programcı veya kullanıcı) kastını kesin olarak tespit etmesi ve mahkûmiyet hükmü kurması, adil yargılanma hakkının temel güvenceleriyle bağdaşmayacaktır. Nitekim savunmanın, doğruluğunu ve güvenilirliğini denetleyemediği bir dijital ifadeye karşı etkili bir savunma yapması beklenemez. Bu nedenlerle, düşünce zinciri verisi, CMK anlamında tek başına bir mahkûmiyete dayanak oluşturacak nitelikte bir “delil” olarak kabul edilemez.

Sonuç olarak, CoT verileri, ceza muhakemesinde ancak bir belirti veya özel uzmanlık gerektiren bir

“delil elde etme vasıtası” olarak değerlendirilebilir. Bu verinin hukuki bir anlam ifade edebilmesi, ancak yapay zekâ ve adli bilişim alanında yetkin bir bilirkişinin teknik süzgecinden geçirilmesiyle mümkündür. Bilirkişi, CoT kaydının bütünlüğünü, manipülasyona uğrayıp uğramadığını, modelin halüsinasyon üretme eğilimini ve genel güvenilirliğini denetleyerek mahkemeye bir rapor sunmalıdır. Hâkimin vicdani kanaatinin temelini oluşturacak olan, CoT verisinin ham metni değil, bu metnin uzman analizine dayanan akılcı ve denetlenebilir bilirkişi raporu olmalıdır. Hukukun teknoloji karşısındaki temkinli duruşu, adil yargılanma hakkını ve delil güvenliğini sağlamanın en temel güvencesi olmayı sürdürmektedir.

Kaynakça

- Ateş, Hüseyin, *Ceza Muhakemesi Hukuku ve Yapay Zekâ: Temel İlkeler-Yapay Zekâ Uygulamaları* (Adalet Yayınevi, 2025).
- Bathae, Yavar, 'The Artificial Intelligence Black Box and the Failure of Intent and Causation', *Harvard Journal of Law & Technology* C.31 S.2 (2018), 879-938.
- Brown, Tom B. vd., 'Language Models are Few-Shot Learners', *NIPS'20: Proceedings of the 34th International Conference on Neural Information Processing Systems* S.159 (2020), 1877-1901.
- Centel, Nur ve Hamide Zafer, *Ceza Muhakemesi Hukuku* (Beta Yayıncılık, 2022).
- Cheng, Jiahao, Tiancheng Su, Jia Yuan, Guoxiu He, Jiawei Liu, Xinqi Tao, Jingwen Xie and Huaxia Li, 'Chain-of-Thought Prompting Obscures Hallucination Cues in Large Language Models: An Empirical Evaluation', *Findings of the Association for Computational Linguistics: EMNLP* (2025), 1272-1305.
- Deeks, Ashley, 'The Judicial Demand for Explainable Artificial Intelligence', *Columbia Law Review* 119/7 (2019), 1829-1850.
- Dülger, Murat Volkan ve Şaban Cankat Taşkın, *Ceza Muhakemesi Hukuku* (Seçkin Yayınları, 2023).
- Emmert-Streib, Frank, Zhen Yang, Han Feng, Shailesh Tripathi and Matthias Dehmer, 'An Introductory Review of Deep Learning for Prediction Models With Big Data', *Frontiers in Artificial Intelligence* C.3 S.4 (2020), 1-23.
- Erem, Faruk, *Ceza Usulü Hukuku* (Sevinç Matbaası, 1973).
- Garrett, Brandon L., 'AI and Procedural Due Process', *Journal of Constitutional Law* 27/5 (2025), 933-976.
- Garrett, Brandon L. and Cynthia Rudin, 'The Right to a Glass Box: Rethinking Artificial Intelligence in Criminal Justice', *Cornell Law Review* S.109 (2024), 561-627.
- Haugh, Brian A., David A. Sparrow and David M. Tate, *The Status of Test, Evaluation, Verification, and Validation (TEV&V) of Autonomous Systems* (Virginia: Institute for Defense Analyses, 2018).
- Hussain, Jabbar, *Deep Learning Black Box Problem* (İsveç Upsala Üniversitesi Master Tezi, 2019).
- Kwon, Hyeokjin, Jaebeom Kim and Wooguil Pak, 'Graph-Based Prompt Injection Attacks Against Large Language Models', *International Journal of Advanced and Applied Sciences* C.12 S.2 (2024), 112-116.
- Larasati, Retno and Anna DeLiddo, 'Building a Trustworthy Explainable AI in Healthcare', *Human Computer Interaction and Emerging Technologies*, ed. Fernando Loizides, Marco Winckler, Usashi Chatterjee, Jose Abdelnour-Noceira and Antigoni Parmaxi (Cardiff University Press, 2020).
- Lin, Herbert, 'Escalation Risks in an Artificial Intelligence-Infused World', *Artificial Intelligence, China, Russia, and the Global Order*, ed. Nicholas D. Wright (Alabama Air University Press, 2019).
- McGourlay, Claire, Mark Thomas and Suzanne Gower, *Evidence Law and Context* (Routledge, 2024).
- Michael, Nathan, 'Trustworthy AI', *National Defense* C.104 S.791 (2019), 26-27.
- Muhammad, Dost and Malika Bendeche, 'Unveiling the black box: A systematic review of Explainable Artificial Intelligence in Medical Image Analysis', *Computational and Structural Biotechnology Journal* S.24 (2024), 542-560.
- Narasimhan, Premanand ve N. Kala, 'Ensuring the Integrity of Digital Evidence: The Role of the Chain of Custody in Digital Forensics', *International Journal of Scientific Research in Computer Science, Engineering and Information Technology* C.6 S.4 (2024), 2438-2450.
- Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation), <https://gdpr-info.eu/art-15-gdpr/> [Erişim 28 Ekim 2025].
- Rossi, Francesca., 'Building Trust in Artificial Intelligence', *Journal of International Affairs Editorial Board* C.72 S.1 (2019), 127-134.
- Schneider, Johannes, Christian Meske and Michalis Vlachos, 'Deceptive AI Explanations: Creation and Detection', *Proceedings of the 14th International Conference on Agents and Artificial Intelligence* C.2 (ICAART 2022), 44-55.
- Slack, Dylan, Sophie Hilgard, Emily Jia, Sameer Singh and Himabindu Lakkaraju, 'Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods', *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*, Barcelona, İspanya: Association for Computing Machinery (2020), 180-186.
- Solanke, Abiodun A., 'Explainable Digital Forensics AI: Towards Mitigating Distrust in Albased Digital Forensics Analysis Using Interpretable Models', *Forensic Science International: Digital Investigation* S.42 (2022), 1-12.
- Srihari, Sargur N., 'Explainable Artificial Intelligence', *Journal of the Washington Academy of Sciences* C.106 S.4 (2020), 9-38.
- Sun, Jiashuo, Yi Luo, Yeyun Gong, Chen Lin, Yelong Shen, Jian Guo and Nan Duan, 'Enhancing Chain-of-Thoughts Prompting with Iterative Bootstrapping in Large Language Models', *Findings of the Association for Computational Linguistics* (NAACL 2024), 4074-4101.
- Thomas, M. A., 'Time for a Counter-AI Strategy', *Strategic Studies Quarterly* 14/1 (2020), 3-8.
- Ünver, Yener ve Hakan Hakeri, *Ceza Muhakemesi Hukuku* (Adalet Yayınevi, 2022).
- Villasenor, John and Virginia Foggo, 'Artificial Intelligence, Due Process, and Criminal Sentencing', *Michigan State Law Review* S.2 (2020), 295-354.
- Wei, Jason, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed H. Chi, Quoc V. Le and Denny Zhou, 'Chain-of-Thought Prompting Elicits Reasoning in Large Language Models', *Advances in Neural Information Processing Systems* C.35, S.1800 (NeurIPS 2022), 24824-24837.
- Yeung, Karen and Adrian Weller, 'How is 'Transparency' Understood by Legal Scholars and the Machine Learning Community?', *Being Profiled: Cogitas Ergo Sum*, ed. Emre Bayamlıoğlu, Irina Baraliuc, Liisa Janssens and Mi-reille Hildebrandt (Amsterdam University Press, 2018).
- Zhang, Yue, Yafu Li, Leyang Cui, Deng Cai, Lemao Liu, Tingchen Fu, Xinting Huang, Enbo Zhao, Yu Zhang, Yulong Chen, Longyue Wang, Anh Tuan Luu, Wei Bi, Freda Shi and Shuming Shi, 'Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models', *arXiv* (2023), 1-37, <https://arxiv.org/abs/2309.01219> [Erişim 27 Ekim 2025].