Makine Öğrenmesi ve Transfer Öğrenme ile Türkçe Metin Sınıflandırma

Turkish Text Classification with Machine Learning and Transfer Learning

Murat AYDOĞAN
Bingöl Üniversitesi
Genç Meslek Yüksekokulu
Bingöl, Türkiye
maydogan@bingol.edu.tr

Ali KARCI
İnönü Üniversitesi
Bilgisayar Mühendisliği Bölümü
Malatya, Türkiye
ali.karci@inonu.edu.tr

***Özetçe*— Metin sınıflandırma problemi doğal dil işleme alanının en temel çalışma konularından biridir. Ancak bu alanda yapılan çalışmalar incelendiğinde başta İngilizce olmak üzere birçok dünya diline yönelik çeşitli çalışmalar yapılırken, Türkçeye özgü yapılan çalışmaların istenilen sayıda olmadığı görülmüştür. Bunun için iki Türkçe veri seti oluşturulmuştur. Etiketsiz metinlerden oluşan ilk veri seti üzerinde kelime vektörleri oluşturulmuştur. Kelime vektörleri transfer öğrenme ile çeşitli haber sitelerinden toplanan veriler ile oluşturulmuş ikinci veri seti üzerine aktarılmıştır. Bu veri seti üzerinde makine öğrenmesi algoritmalarından Naïve Bayes ve Destek Vektör Makineleri ile metin sınıflandırma işlemi yapılmıştır. Çalışmada kullanılan kelime vektörlerinin transfer öğrenme ile aktarımının doğruluk oranına etkileri ve makine öğrenmesi yöntemlerinin başarımları detaylı olarak analiz edilmiştir. Çalışma sonunda Destek Vektör Makinesi modelinin daha başarılı performans gösterdiği ayrıca kullanılan transfer öğrenme yöntemi ile başarım değerinin geliştirildiği görülmüştür.**

***Anahtar Kelimeler*—Türkçe metin sınıflandırma, makine öğrenmesi, kelime temsili, transfer öğrenme.**

Abstract— The problem of text classification is one of the most fundamental topics of study in the field of natural language processing, but when reviewing the literature, it is seen that there is an inadequate number of studies for the issue of Turkish text classification. Two different Turkish datasets were created for this aim. Word vectors were created on the first dataset of unlabeled texts. These word vectors were transferred to the second dataset created with data collected from various news sites by transfer learning. Text classification was applied with the machine learning algorithms on this dataset. The effects of transfer learning and transferring of word vectors on the accuracy rate and the performance of machine learning methods were analyzed in detail. When studying the experimental results, it was determined that Support Vector Machine model was performed more successful and It was seen that the accuracy rate was improved with transfer learning.

Index Terms—Turkish text classification, machine learning, word embedding, transfer learning.

I. GİRİŞ

Doğal dil işleme çalışmaları, büyük veri kavramına paralel olarak metin verilerinin artmasıyla birlikte son dönemler de daha da önemli hale gelmiş yapılan çalışmalar ile oldukça popüler olmuştur. Metin sınıflandırma, duygu analizi, makine diline çeviri, bilginin çıkarılması, özetleme, soru-cevap sistemlerinin geliştirilmesi gibi çalışma alanlarında doğal dil işleme teknikleri kullanılmaktadır [1].

Metin sınıflandırma problemi en çok üzerinde çalışılan doğal dil işleme problemlerinden biridir. Başta ingilizce olmak üzere birçok dünya dilinde çeşitli metin analizleri yapılırken ne yazık ki Türkçe çalışmalar için bu sayılar yeterli seviyede değildir [2].

Amasyalı ve arkadaşları [3] çalışmalarında Türkçe metin sınıflandırma için 6 Türkçe veri seti üzerinde temsil yöntemlerinin performanslarını karşılaştırmışlardır. Çalışmalarında uyguladıkları kelime temsil metotları arasında en başarılı performansı n-gram yöntemi göstermiştir.

Kılınç ve arkadaşları [4] TTC-3600 isimli çeşitli haber sitelerinden topladıkları veriler ile 6 kategoriden oluşan bir Türkçe veri seti oluşturmuşlardır. Ayrıca veri seti üzerinde farklı makine öğrenmesi algoritmaları ile metin sınıflandırma işlemi yapmışlardır.

Ayata ve arkadaşları [5] ise Türkçe tweetlerinin içeriğine göre duygu analizi yapmışlardır. Kelimeler vektörleştirilerek temsil edilmiş, makine öğrenmesi algoritmaları ile sınıflandırma işlemi yapılmıştır.

Bu çalışmada, veri setinde yer alan kelimeler günümüzde en popüler kelime temsil (word embedding) yöntemlerinden biri olan word2vec metodu ile vektörleştirilmiştir. Daha sonra bu kelimelerin vektör değerleri, transfer öğrenme ile üzerinde sınıflandırma işlemi yapılacak veri setinde yer alan kelimelerin sayısal ağırlıklarına aktarılmıştır. Kelimeden sayısal değerlere dönüşümü yapılan veriler derin sinir ağları ile eğitilerek sınıflandırma işlemi yapılmıştır.

II. YÖNTEM

A. Kelime Temsili (Word Embedding)

1) Bag of Words (BoW)

Bag of Words, "Kelime çantası modeli" olarak Türkçeleştirilmiştir. BoW, makine öğrenimi algoritmaları ile metin modellerken kullanılan bir kelime temsil yöntemidir. BoW metodunun anlaşılması kolay ve uygulanması basittir. Ayrıca dil modelleme ve metin sınıflandırma gibi problemlerde başarı göstermiştir [6]. Örnek 2 cümle üzerinden anlatılmak istenirse;

cümle1: " Yapay zeka çalışıyorum."

cümle2: " Yapay zeka yeni elektriktir."

Derlem içerisinde yer alan kelimeler unique olarak listelenir. Dolayısıyla kelime torbası, "yapay","zeka","çalışıyorum", "yeni", "elektriktir" kelimelerinden oluşmaktadır. Şimdi cümle1 BoW yöntemi ile kelime torbasında yer alan kelimeler "1" ile olmayan kelimeler ise"0" ile temsil edilecektir. Yani cümleler şu şekilde temsil edilecektir.

cümle1: " Yapay zeka çalışıyorum."=> [1 1 1 0 0]

cümle2: " Yapay zeka yeni elektriktir." =>[1 1 0 1 1]

BoW yönteminde, verilen örnekte 5 unique (tekil) kelime olduğu için vektörün boyutu da 5 olmuştur. Ancak 10 bin kelimeden oluşan bir sözlük olsaydı çoğunluğu sıfırlardan oluşan 10 bin boyutlu bir vektör oluşacaktı. Bu durum BoW yönteminin en büyük dezavantajıdır [7]. Bir diğeri ise kelimeler arasında ilişki kurulmasının mümkün olmamasıdır. Bu örnekte "yapay" ve "zeka" kelimeleri arasında herhangi bir benzerlik söz konusu değildir.

2) Word2Vec

Bir derlem içerisindeki metinlerin nasıl temsil edileceği metin işleme çalışmalarının en kritik noktalarından biri ayrıca bir ağın en önemli girdisidir. En basit tanımıyla, metinlerin sayısal verilere dönüştürülmesine kelime temsili (word embedding) denilmektedir [8]. Aynı metin farklı şekilde farklı sayısal değerlere dönüştürülebilmektedir. Kelime temsil yöntemlerinden bir diğeri olan tahmin tabanlı kelime temsil yöntemi ailesinden olan Mikolov ve arkadaşları [9] tarafından 2013 yılında geliştirilmiş olan temelinde yapay sinir ağı ile kelimelerin eğitilmesi ilkesine dayananWord2Vec modelidir. Bu model giriş olarak alınan kelimelere dayanarak hedef kelimeyi tahmin etme prensibine dayalıdır. Word2Vec modeli CBOW(Continous Bag of Words) ve Skip-gram olarak adlandırılan iki farklı modelden oluşmaktadır. Bu çalışmada CBOW modeli tercih edilmiştir.

CBOW modelinde pencere boyutu merkezinde olmayan kelimeler girdi olarak alınıp, merkezinde olan kelimeler çıktı olarak tahmin edilmeye çalışılmaktadır. Bu işlem cümle bitimine kadar devam etmektedir. Bu durum Şekil 1'de gösterilmeye çalışılmıştır. Burada w(t) ile gösterilen değer, cümlenin merkezinde bulunan ve tahmin edilmek istenen çıktı değeriyken, w(t-2)…..w(t+2) ile gösterilen değerler ise tercih edilen pencere boyutuna göre merkezde olmayan çıktı değerleridir [10-11].

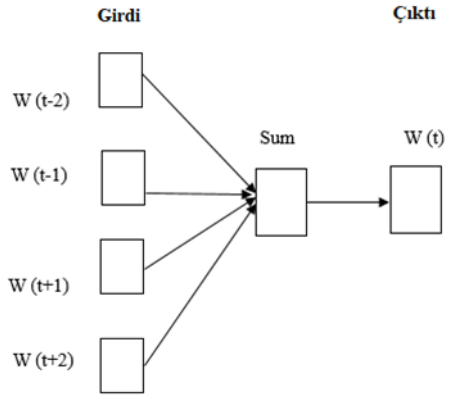

Şekil 1. Word2Vec modelinin yapısı [9]

Word2Vec algoritması sinir ağı temelli bir yaklaşımdır. Eğitim sırasında optimize edilecek hata fonksiyonu ise Eşitlik 1'de gösterilmiştir.

$$J = -\frac{1}{T}\sum_{t=1}^{T}\sum_{-m\leq j\leq m}\log P(w_{t+j} \mid w_t) \quad (1)$$

Eşitlik 1'de gösterilen t=1…..T ile bu işlem derlem içerisindeki tüm kelimeler için yapılarak, her kelimenin çevresindeki kelimeleri yüksek olasılıkla tahmin edebilen vektörler oluşturulmaktadır. Hedef kelimenin pencere boyutu m ile ifade edilirken w_t merkez durumunda ki kelimeyi w_{t+j} ise j uzaklıktaki kelimeyi göstermektedir.

Word2Vec modelinin en büyük avantajı kelimelerin cümle içerisinde ki pozisyonlarına göre şartlı olasılık prensibine göre çalışmasından dolayı kelimeler arasındaki yakınlıkların kaybolmamasıdır. Şekilde görüldüğü gibi kelimeler Word2Vec ile vektörleştirildikten sonra kosinüs benzerliği formülü ile bir kelimeye en yakın kelimeler tespit edilebilmiştir.

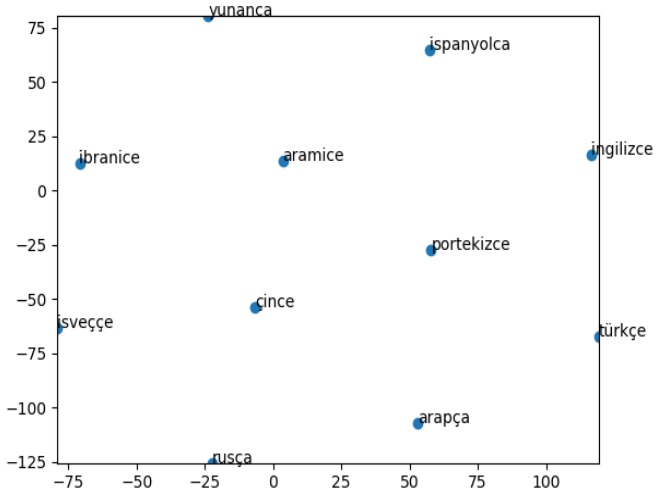

Şekil 2. Kelimelerin 2 boyutlu gösterimi

Vektör (“türkçe”)	
Kelime	**Uzaklık**
ingilizce	0.8736306428909302
çince	0.7922905683517456
ibranice	0.7730669975280762
isveççe	0.7647651433944702
aramice	0.7465971708297730
arapça	0.7360776662826538
portekizce	0.7272559404373169
ispanyolca	0.7208824753761292
rusça	0.7203962802886963
yunanca	0.7147416472434998

.

Şekil 3. Benzer kelimeler listesi

Şekil 3’te “Türkçe” kelimesine en yakın 10 kelime listelenmiştir. Görüldüğü üzere “Türkçe” kelimesinin bir dil olduğu anlaşılmış ve benzer kelimeler olarak diğer diller listelenmiştir. Bu tespit yapılırken derlem içerisindeki kelimelere göre yapılmıştır. Farklı derlemlerde farklı sonuçlar elde etmek mümkündür. Uzaklık ile ifade edilen ise kelime vektörlerinin birbirlerine olan uzaklıklarıdır. Bu değer kosinüs benzerliği ile hesaplanmıştır.

B. Naive Bayes Yöntemi

Naive Bayes (NB) sınıflandırıcısı, Bayes Teoremine dayanan bir istatistiksel denetimli öğrenme algoritmasıdır [12]. Şartlı olasılıklar, metinin hangi sınıfta sınıflandırılması gerektiğini belirlemek için tüm eğitim setleri kullanılarak hesaplanır. Yöntemin kolay uygulanabilir olması ve başarılı performans göstermesi NB sınıflandırıcısının önemli avantajlarıdır. Ayrıca az miktarda eğitim verisi ile çoğu durumda başarılı sonuçlar elde edilmektedir. Metin sınıflandırma problemlerinde sık sık kullanılan bir yöntemdir [13].

$$X = [x_1, x_2, x_3, \dots x_n]$$
$$C = [c_1, c_2, c_3, \dots c_n]$$
$$P(C_i/x) = \frac{p(x\ /\ C_i\ )\ P(C_i)}{P(x)} \qquad (2)$$

Eşitlik 2 durumların olasılık değerlerinin hesaplandığı formüldür.

$$\arg max_{ci}\{\ P\ (x|c_i)\ P\ (c_i)\ \} \qquad (3)$$

Karşılaşılan yeni durum ise 3 numaralı eşitlik kullanılarak hesaplanan en yüksek olasılık değerinin sınıfına atanır.

C. Destek Vektör Makinesi (DVM)

1992 yılında geliştirilen destek vektör makinesi (DVM), istatistiksel bilgi teorisi temelli bir sınıflandırıcıdır. DVM algoritması doğrusal ve doğrusal olmayan DVM olarak iki algoritmaya ayrılmıştır. Doğrusal DVM algoritmasında, verileri ayırmak için sonsuz sayıda hiper düzlem oluşturulur ve tüm bu hiper düzlemlerden maksimum marjlı hiper düzlem seçilir. Doğrusal olmayan DVM, sınıflar doğrusal olarak ayrılmadığında ve veriler daha yüksek boyutlu bir alana aktarıldığında kullanılır. Bu şekilde, veriler doğrusal olarak ayrılabilir hale gelir [14]. DVM’ nin ana avantajları, yüksek doğruluktur. DVM yöntemi günümüzde yüz tanıma sistemlerinden, ses analizine kadar birçok sınıflandırma probleminde kullanılmaktadırlar. Metin işleme de bu alanlardan biridir [15].

III. MATERYAL

Bu çalışma kapsamında iki adet türkçe veriseti oluşturulmuştur. İlk veriseti kelime vektörlerinin eğitilmesi amacıyla etiketsiz Türkçe metinlerden oluşturulmuş büyük bir derlemdir(corpus). Bu derlem çalışmada Dataset1 olarak adlandırılmıştır. Oluşturulan ikinci veriseti ise Dataset 1’den transfer öğrenme ile aktarılan kelime vektörleri makine öğrenmesi algoritmaları ile birlikte kullanılarak sınıflandırma işlemi için oluşturulmuştur. Çalışmada bu veriseti de Dataset2 olarak adlandırılmıştır.

A. Dataset1

Çalışmada kelime vektörlerinin eğitilmesi için oluşturulmuş veri setidir. Bu veri seti oluşturulurken belli bir alanda ki metinleri toplamak yerine daha genel konu başlıklarını içeren metinler tercih edilmiştir. Bu amaçla Wikipedia ortamında yazılmış Türkçe makalelerden oluşan bir derlem oluşturulmuştur.

B. Dataset2

Bu veri seti, eğitilen kelime vektörlerinin makine öğrenmesi algoritmaları ile birlikte sınıflandırma işleminin yapılması için oluşturulmuştur.

Python dili ile bir crawler geliştirilerek internet ortamında çeşitli gazete ve haber siteleri dolaşılmış ve 4 kategoride haber metinleri çekilerek veri seti oluşturulmuştur. Veri setinin yapısı Tablo 1’de verilmiştir.

TABLO I. VERİ SETİNİN (DATASET2) YAPISI

İÇERİK	SINIF
Dün 6,00-6,08 aralığında işlem gören dolar/TL, günü önceki kapanışa göre yüzde 0,44 değer kaybıyla 6,02'den tamamladı.	EKONOMİ
Bakan Mevlüt Çavuşoğlu NATO toplantısında Kıbrıs mesajı verdi.	SİYASET
YouTube' dan yeni uygulama. YouTube abone sayılarını tam olarak göstermeyecek.	TEKNOLOJİ
Sakaryaspor - Fatih Karagümrük arasında oynanacak olan TFF 2. Lig Play-Off Final maçı Bursa Büyükşehir Belediye Stadyumu'nda oynanacak	SPOR

“Siyaset”, “Ekonomi”, “Spor” ve “Teknoloji” başlıklarından her bir kategori için 500 haber çekilmiş toplamda 2000 veriden oluşan bir veri seti üretilmiştir. Veri setinin yapısı tabloda gösterilmiştir.

Veri setinde yer alan veriler kelime vektörü haline getirilmeden önce ön işlem aşamasından geçirilmiştir. Uygulanan ön işlem adımları şöyledir.

- Derlem içerisindeki metinler okunarak, nokta işareti referans alınarak metinler cümlelere bölünmüştür.
- Tüm cümleler küçük harften oluşan kelimelere dönüştürülmüştür.
- Cümlelerden harfler dışındaki tüm karakterler (sayılar, semboller, noktalama işaretleri) temizlenmiştir.
- Cümleler ise, aralarındaki boşluklar referans alınarak kelimelere ayrılmıştır.
- Tokenlara ayrılmış kelimeler, zemberek ortamı [16] kullanılarak köklerine ayrılmıştır.

IV. DENEYSEL ÇALIŞMALAR

Bu çalışmanın amacı Dataset1 ile kelime vektörlerinin üretilmesi daha sonra bu vektörlerin transfer öğrenme ile Dataset2 üzerinde kullanılarak sınıflandırma işleminde başarım oranının geliştirilmesidir. Ayrıca geleneksel kelime temsil yöntemlerinden olan Bag of Words (BoW) ile sinir ağı temelli modern bir yaklaşım olan Word2Vec yöntemi de kıyaslanmıştır.

Çalışmada öncelikle Dataset1 üzerinde ön işlem çalışmaları yapıldıktan sonra unique kelimeler listelenmiş ve bu kelimeler eğitilerek vektörlere dönüşümü yapılmıştır. Bu aşamada kelimeler ve ağırlıklardan oluşan bir tür sözlük oluşturulmuştur.

Dataset2 üzerinde de ön işlem çalışmaları tamamlanmış kelimeler yine unique olarak listelenmiştir. Kelimeler Dataset1'den elde edilen sözlükte yer alıyorsa bu ağırlıklar transfer öğrenme ile aktarılarak vektörler oluşturulmuştur.

Tüm metinler sayısallaştırıldıktan sonra makine öğrenmesi algoritmalarından Naive Bayes (NB) ve Destek Vektör Makinesi (DVM) yöntemleri kullanılarak sınıflandırma işlemleri yapılmıştır. Modelin yapısı şekilde görülmektedir.

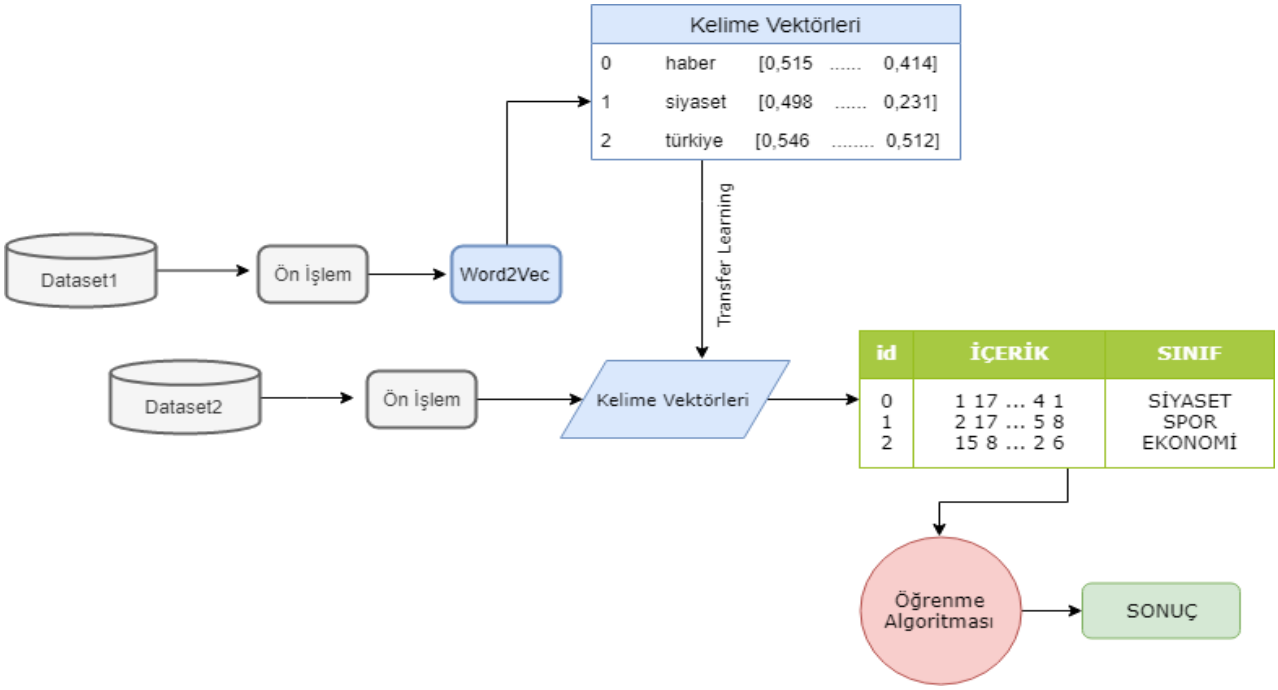

Şekil 4. Modelin Yapısı

Kelimelerin temsil edilmesi konusunda 3 farklı yaklaşım denenmiştir. İlk yaklaşımda (1) geleneksel bir kelime temsil yöntemi olan Bag of Words (BoW) yöntemi kullanılmıştır. İkinci yaklaşımda (2) ise kelime temsili için Word2Vec yöntemi kullanılmış ancak kelimeler vektörlere dönüştürülürken sadece sınıflandırma işleminin yapılacağı Dataset2 içerisindeki veriler kullanılmıştır. Dolayısıyla daha az miktarda veriden ve haber içerikli metinlerden faydalanılmıştır. Son yaklaşımda (3) ise bu çalışmanın da temel amacı olan Dataset1'den Word2Vec yöntemi kullanılarak elde edilmiş kelimelerin vektör biçimindeki ağırlıkları transfer öğrenme ile Dataset2'den listelenmiş unique kelimelerin ağırlıklarına aktarılmıştır. Bu üç yaklaşımdan elde edilmiş doğruluk oranları Tablo 2'de görülmektedir.

TABLO II. DOĞRULUK ORANLARI

TEST KÜMESİ	NB (%)			DVM (%)		
	BoW	W2V	TL	BoW	W2V	TL
SİYASET	66.14	70.03	77.14	65.68	69.74	81.05
EKONOMİ	77.09	81.45	83.59	78.23	81.15	86.65
SPOR	80.52	86.76	90.94	80.33	86.01	91.18
TEKNOLOJİ	71.23	76.85	80.78	71.41	77.10	83.51
TOPLAM	72.45	76.17	80.25	73.12	77.55	83.75

**BoW, Bag of Words 1 numaralı yaklaşım.*
**W2V, Word2Vec 2 numaralı yaklaşım.*
** TL, Word2Vec + Transfer Learning 3 numaralı yaklaşım.*

Veri setinde yer alan kategoriler tek tek daha sonra tüm veri seti toplam olarak ifade edilerek sınıflandırma işlemine tabii tutulmuştur. Sonuçlar kelime temsil yöntemlerinin uygulama yaklaşımlarına göre incelendiğinde geleneksel BoW yaklaşımı en kötü performansı göstermiştir. Tüm kategorilerde, toplam veri setinde ayrıca her iki sınıflandırma modelinde de en az doğruluk oranını 1 numaralı yaklaşım olarak ifade edilen BoW yöntemi göstermiştir. En başarılı yaklaşım ise yine tüm kategorilerde ve toplam veri setinde Word2vec yöntemi ile birlikte transfer öğrenmenin kullanıldığı 3 numara ile gösterilen yaklaşım olmuştur. Sadece Word2Vec yönteminin kullanıldığı 2 numaralı yaklaşım ise BoW metodundan daha iyi sonuç göstermiştir.

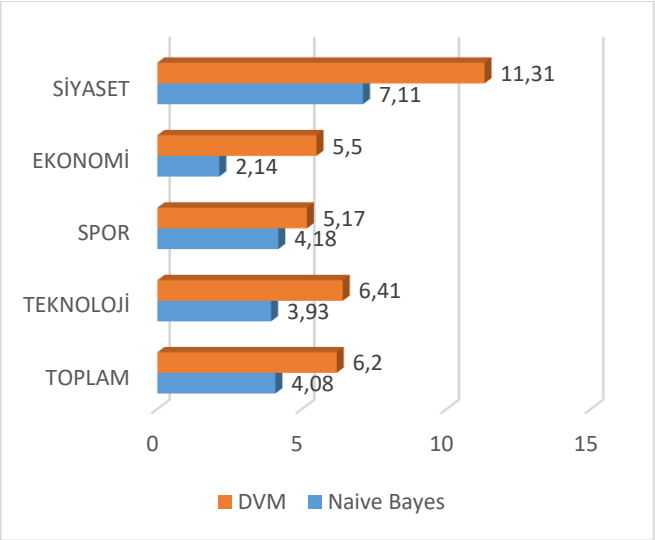

Şekil 5. Doğruluk değerinin geliştirilme oranları (%)

Şekil 5'te Word2Vec yöntemi kullanılarak elde edilen doğruluk değerlerinin, Word2Vec yöntemi ve transfer öğrenme ile ne kadar iyileştirildiğine yer verilmiştir. Öncelikle görülmüştür ki tüm kategorilerde transfer öğrenme ile mevcut doğruluk değerleri geliştirilmiştir. En önemli iyileştirme her iki sınıflandırıcı içinde "siyaset" kategorisinde olmuştur. DVM de % 11,3 oranında önemli bir gelişme meydana gelmişken bu oran NB de 7,11 olmuştur. Tüm veri seti dikkate alındığında ise transfer öğrenme ile DVM de % 6 oranında bir artış olurken, NB de %4 civarında bir iyileşme olmuştur.

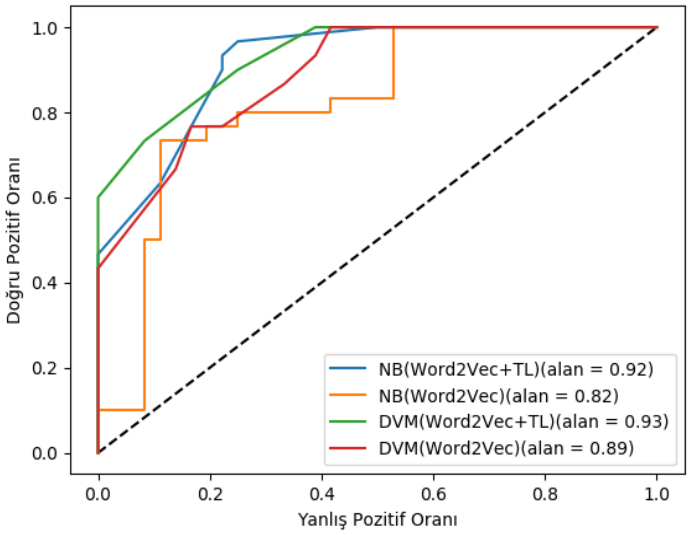

Şekil 6. ROC eğrisi

Şekil 6'da ROC eğrisinin grafiği incelendiğinde DVM sınıflandırıcısı NB sınıflandırıcısından daha iyi sonuç gösterdiği görülmektedir. Her iki sınıflandırıcıda da kelime

temsil yöntemi olarak Word2Vec + Transfer Learning yaklaşımı ile başarım değerleri iyileştirilmiştir.

Deneysel çalışmaların tümü Python 3 programlama dili ve Anaconda ortamı ayrıca Microsoft Windows Server 2012 R2 işletim sistemi ile Intel Xeon E5-2630 2.20 CPU ve 64 GB memory kullanılarak geliştirilmiştir.

V. SONUÇ

Günümüzde üretilen metin verilerindeki artışlara paralel olarak metin işleme çalışmaları popüler hale gelmiştir. Ancak Türkçe metin işleme çalışmalarının sayısı diğer dillerde yapılan çalışmalara oranla istenilen seviyede değildir. Bu nedenle bu çalışmada Türkçe veri setleri oluşturulmuş modern ve popüler kelime temsil yöntemleri yaklaşımları uygulanmıştır.

Çeşitli haber sitelerinden 4 kategoride haber metinleri toplanarak oluşturulan veri setinde her kategori için ve genel veri seti (Dataset2) için sınıflandırma işlemi yapılmıştır. Sınıflandırma işlemi için de metin işleme problemlerinde sık tercih edilen makine öğrenmesi algoritmalarından Naive Bayes (NB) ve Destek Vektör Makinesi (DVM) kullanılmıştır.

Kelimelerin temsil edilme şekli metin işleme çalışmalarının en önemli noktalarından biridir. Bu çalışmada hem daha geleneksel hem de daha modern yaklaşımlar denenmiş ve sonuçlar analiz edilmiştir.

Sinir ağı temelli yaklaşımlar tekrar popüler oluncaya dek en çok tercih edilen yöntem olan BoW yöntemi ve günümüzde en çok tercih edilen kelime temsil yöntemi Word2Vec ile kelime temsilleri yapılmış sonuçlar analiz edildiğinde Word2Vec yönteminin çok daha iyi sonuçlar gösterdiği görülmüştür.

Word2Vec yöntemi ile elde edilen doğruluk değerlerinin geliştirilmesi amacıyla tamamı etiketsiz Türkçe Wikipedia makalelerinden oluşan bir diğer veri seti (Dataset1) ile kelimeler vektörlere dönüştürülmüştür. Bu vektörler daha sonra transfer öğrenme ile sınıflandırma işleminin uygulanacağı veri setinde (Dataset2) yer alan kelimelerin ağırlıklarına aktarılmış ve bu değerler ile sınıflandırma yapılmıştır. Sonuçta tüm veri seti için analiz edildiğinde Naive Bayes sınıflandırıcı da sadece Word2Vec uygulanması ile elde edilen başarım oranı %76 iken bu değerin transfer öğrenme ile %80'e çıkığı görülmüştür. DVM sınıflandırıcı modelinde ise başarım oranı % 77 'den transfer öğrenme ile % 83 değerine ulaşmıştır.

Her iki modelde %4 ile %6 oranında doğruluk oranında bir artış olurken DVM Naive Bayes sınıflandırıcısından daha iyi performans gösterdiği görülmüştür.

KAYNAKLAR

[1] Çoban, Ö., & Özyer, G. T. (2018, September). Word2vec and Clustering based Twitter Sentiment Analysis. In *2018 International Conference on Artificial Intelligence and Data Processing (IDAP)* (pp. 1-5). IEEE.

[2] Adalı, E. (2012). Doğal Dil İşleme. Türkiye Bilişim Vakfı Bilgisayar Bilimleri ve Mühendisliği Dergisi, 5(2).

[3] Amasyalı M. F., Çetin M., Akbulut C., "Metinlerin anlamsal uzaydaki temsil yöntemlerinin sınıflandırma performansına etkileri," Sigma, vol. 5, pp. 8–14, 2013

[4] D. Kılınç, A. Özçift, F. Bozyigit, P. Yıldırım, F. Yücalar, E. Borandag, TTC-3600: A new benchmark dataset for Turkish text categorization. Journal of Information Science, 43(2), 174-185, (2015).

[5] Ayata D., Saraclar M., Ozgur, A. (2017). Turkish tweet sentiment analysis with word embedding and machine learning. 1-4. 10.1109/SIU.2017.7960195.

[6] M. Mittendorfer and W. Winiwarter, "A simple way of improving traditional IR methods by structuring queries," *2001 IEEE International Conference on Systems, Man and Cybernetics. e-Systems and e-Man for Cybernetics in Cyberspace (Cat.No.01CH37236)*, Tucson, AZ, USA, 2001, pp. 951-953 vol.2.

[7] K. Torkkola, "Discriminative features for document classification," Object recognition supported by user interaction for service robots, Quebec City, Quebec, Canada, 2002, pp. 472-475 vol.1.

[8] Amasyalı M. F., Balcı S., Mete E., Varlı E. N., "Türkçe metinlerin sınıflandırılmasında metin temsil yöntemlerinin performans karşılaştırılması" EMO Bilimsel Dergi, vol. 2, no. 4, 2012

[9] T. Mikolov, K. Chen, G. Corrado, J. Dean, Efficient estimation of word representations in vector space. Proceedings of Workshop at ICLR. Scottsdale, (2013).

[10] Q. Le, T. Mikolov, Distributed representations of sentences and documents. 31th International Conference on Machine Learning, China, 2014.

[11] T. Mikolov, I. Sutskever, K. C. 0010, G. Corrado, J. Dean, Distributed Representations of Words and Phrases and their Compositionality, AAAI Spring Symposium AI Technologies for Homeland Security 200591-98, vol. cs.CL, pp. 3111–3119, (2013).

[12] Rish, I. (2001, August). An empirical study of the naive Bayes classifier. In *IJCAI 2001 workshop on empirical methods in artificial intelligence* (Vol. 3, No. 22, pp. 41-46).

[13] D'Agostini, G. (1995). A multidimensional unfolding method based on Bayes' theorem. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, *362*(2-3), 487-498.

[14] Joachims, T. (1998, April). Text categorization with support vector machines: Learning with many relevant features. In *European conference on machine learning* (pp. 137-142). Springer, Berlin, Heidelberg.

[15] Gunn, S. R. (1998). Support vector machines for classification and regression. *ISIS technical report*, *14*(1), 5-16.

[16] Akın, A. A., & Akın, M. D. (2007). Zemberek, an open source nlp framework for turkic languages. *Structure*, *10*, 1-5.