Mobil Robotlarda Navigasyon Problemi için Pekiştirmeli Öğrenme

Nursena BÖLÜK
Bilgisayar Mühendisliği, KOU
Kocaeli, Türkiye
150202049@kocaeli.edu.tr

Özdenur UÇAR
Bilgisayar Mühendisliği, KOU
Kocaeli, Türkiye
150201198@kocaeli.edu.tr

A. Burak İNNER
Bilgisayar Mühendisliği, KOU
Kocaeli, Türkiye
binner@kocaeli.edu.tr

***Özet* — Mevcut mobil robotik araştırmalarındaki en önemli konulardan biri otonom navigasyondur. Bir mobil robotun tamamen otonom bir sisteme sahip olabilmesi için; algılama, haritalama, lokalizasyon, yol planlama, engel tespiti ve engellerden kaçınma gibi birçok sorunu aynı anda çözmesi gerekir. Yıllar içerisinde bu tür sorunlara pek çok çözüm bulunmuş ve geliştirilmiştir. Bu makale bu zamana kadar mobil robotların otonom navigasyon probleminin çözümüne nasıl yaklaşıldığına ve pekiştirmeli öğrenme seçilmesinin sebebine odaklanmaktadır. Aynı zamanda navigasyon problemi için pekiştirmeli öğrenmenin Q-Öğrenme, SARSA, Derin Q-Ağı, İkili Derin Q-Ağı ve A3C algoritmalarını karşılaştırarak incelemektedir. Bu araştırmanın amacı mobil robot navigasyonundaki son gelişmelerin robotikte ek araştırmalara nasıl ilham verebileceğini göstermektir.**

Anahtar Kelimeler— Makine Öğrenmesi, Mobil Robot, Navigasyon, Pekiştirmeli Öğrenme, Yol Planlama

I. GİRİŞ

Mobil robotlar fiziksel bir yere sabitlenmeyen ve tanımlanan bir çevrede hareket ederek yapılması istenilen işlevleri yerine getiren robotlardır [1]. Birçok araştırmacı başta statik (durağan) ortamlarda sonrasında ise gelişen teknoloji ile birlikte dinamik ortamlarda mobil robotlarda yol ve hareket planlama çalışmaları yapmıştır.

Bir mobil robotun yol planlaması mesafeyi, zamanı ve enerjiyi optimize ederek ve başlangıç noktasından hedef noktasına kadar çarpışmasız bir şekilde yol belirlemesidir [2].

Araştırmacılar yol planlama problemini çözmek için kullanılan çeşitli metotları iki faktöre göre ayırmaktadır. Bunlar çevre tipi (statik ve dinamik) [3] ve yol planlama (çevrimiçi ve çevrimdışı) algoritmalarıdır [4]. Yol planlama problemi için çevre tipi olarak statik ortam, dolaşan bir mobil robottan başka hareketli herhangi bir nesne içermeyen ortam olarak tanımlanır; dinamik ortam ise hareketli nesnelere (örneğin; insanlar, hareketli makineler ve hareketli robotlar) sahip ortamdır.

Çevrimdışı yol planlama algoritmaları ortam hakkında tam bir bilgi gerektirir ve tüm ortamın statik olması gerekir. Çevrimiçi yol planlama algoritmaları ise robot hareket halindeyken yol planlamasının yapıldığı algoritmadır ve çevresel değişikliklere cevap olarak yeni bir yol üretme yeteneğine sahiptir [5-6]. Çevrimdışı algoritmalar sezgisel (bilgili) arama ve sezgisel olmayan (bilgisiz) arama olarak iki bölüme ayrılmaktadır. Sezgisel olmayan arama algoritmaları, alana özgü herhangi bir bilgi (sezgisel fonksiyon) kullanmaz. Dijkstra algoritması [7-8] iyi bilinen bir bilgisiz çevrimdışı arama algoritmasıdır. Öte yandan Sezgisel arama alana özgü bilgi (sezgisel fonksiyon) kullanır. A* algoritması [9-10] en iyi bilinen bilgili çevrimdışı arama algoritmasıdır. Örnek olarak Cheng ve arkadaşları tarafından geliştirilmiş hiyerarşik A* algoritmasını büyük otoparkların optimal park yolu planlamasında kullanmışlardır [11]. Soltani ve arkadaşları Dijkstra ve A* algoritmasını şantiyede yol planlaması amacıyla kıyaslamıştır. Bu makalede ortamın şantiye olmasından ötürü güvenlik kriteri de göz önünde bulundurulmuştur. A* algoritmasının yerelde daha uygun çözüm bulabildiğini gözlemlemişlerdir [12].

Yol bulma algoritmalarında sezgisel fonksiyon olarak, genellikle Euklid ya da Manhattan mesafesi kullanılmaktadır [13]. Çevrimdışı algoritmaların, çok fazla hesaplama zamanına ihtiyaç duymalarından dolayı, büyük dinamik çevrelerde kullanımı zordur [14]. Bu duruma bir çözüm olarak, çevrimdışı algoritmaların tekrarlı planlamalar yapması yerine bu algoritmaların artımsal olarak düzenlenmesi önerilmektedir. Artımsal algoritmalar, problemlere daha hızlı çözüm bulmak için, önceki aramalardan elde edilen bilgileri kullanan sürekli planlama tekniklerdir [15]. D* [16], Focused D* [16] ve D* Lite [17] iyi bilinen artımsal sezgisel arama algoritmalarıdır. Örnek olarak Stentz [16] odaklanmış D* (Focused D*) algoritmasını robotun gerçek zamanlı olarak yol planlamasında kullanmıştır. Burada D* algoritmasına sezgisel odaklanma işlevi ekler ve A* algoritmasını dinamik ortama genelleştirir. Böylece odaklanmış D * sürümü, D* algoritmasına göre daha iyi performans gösterir. Artımsal algoritmalar herhangi bir çevresel değişim belirlediğinde, mevcut çözümü kısmi olarak yeniden planlar [13]. Böylece çoğu zaman etkili sonuçlar verebilir fakat bazen ortamda meydana gelen ufak bir değişiklikte tüm yolu yeniden planlamak zorunda kalabilir.

Çevrimiçi algoritmalarda ise, robot sürekli olarak, bir sonraki hareketini sınırlı bir zaman içerisinde planlar ve planı uygular. Algoritma, aynı yol üzerinde, gerçek zamanlı olarak plan ve işlem safhasını birleştirir. Gerçek zamanlı algoritmalardan bazıları; Gerçek Zamanlı Yatay A* (Real-Time Horizontal A*, RTHA*) [13] ve Gerçek Zamanlı A* (Real-Time A*, RTA*) [18], algoritmalarıdır. Gerçek zamanlı algoritmalar, en iyi çözümler için tasarlanmamıştır ve yol uzunluğu konusunda zayıf çözümler bulurlar [13].

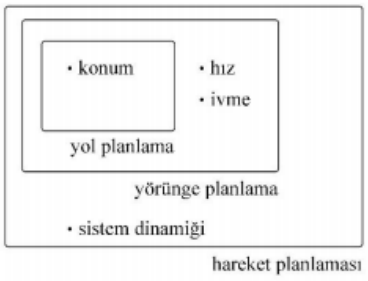

Şekil 1.1: Planlama kavramlarının şematik gösterimi

Şekil 1.1'de planlama kavramlarının birbirleri ile olan ilişkisi şematik olarak gösterilmiştir. Yol planlaması statik ortamlar için daha uygundur. Eğer dinamik ortam kullanılacaksa sistem dinamikliği de işin içine katılacağından hareket planlaması yapılmalıdır.

Mobil robotların hareket planlaması hakkında günümüze kadar pek çok araştırma araştırma yapılmıştır. Yapılan araştırmalarda genetik algoritmalardan, yapay zeka algoritmalarından, optimizasyon tekniklerinden, görüntü işleme tekniklerinden veya en kısa yörünge belirleme algoritmalarından yararlanılmıştır.

Mobil robotlar hareket kontrolünün sağladığı yararla tutarlı hareket edebilir. Bir mobil robot istenen bir yöne gidebilmek için yön bilgisine ve pozisyona ihtiyaç duyar [19].

Şekil 1.2'de gösterildiği gibi mobil robot yol planına göre hedef noktaya doğru harekete başlar ve her hareketinde engellere olan durumunu kontrol eden bir hareket kontrolü (hareket planlayıcı) çalıştırılır. Ardından mobil robot hareket planına göre bir sonraki hareketinde bulunur.

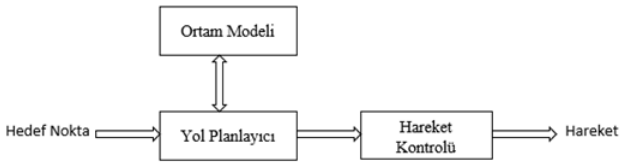

Şekil 1.2: Yol Planlama ve Hareket Kontrolü İlişkisi [20]

Mobil robot navigasyonunda hareket planlamanın temel amacı en iyi seçimle mobil robotu yönlendirmek ve herhangi bir engele çarpmadan mevcut konumdan hedef konuma ulaştırmaktır [21-22].

Yapılan çalışmalara da bakılarak, robotikte hareket planlaması geleneksel ve modern yöntemler olarak iki ayrı dalda incelenebilir.

Geleneksel hareket planlaması genellikle harita temellidir. Mobil robot, harita belli olduğu için çevreyle ilgili tüm durumları kullanarak navigasyon işlemini gerçekleştirir ancak bilinmeyen bir ortamda navigasyonun yapılması zordur [23]. Geleneksel hareket planlamasına örnek olarak Geleneksel Dinamik Programlama (DP); haritalama ve yol bulma problemini ayrı ayrı değerlendirir. Mesela popüler olarak bilinen SLAM algoritması, bir ortamı haritalar ve ardından DP ile yol planlaması için kullanılır. Ancak, bu iki ayrı aşamaları gerçekleştirmek çok zaman alır [24].

Modern yöntem olarak ise makine öğrenme metotları örnek gösterilebilir. Mobil robotlarda navigasyon işlemi için genelde pekiştirmeli öğrenme kullanılmaktadır. Bunun sebebi olarak pekiştirmeli öğrenmenin, denetimli öğrenmeden daha yavaş olmasına rağmen daha iyi öğrenmesi gösterilebilir. Denetim olmadığından ötürü denetimin ön yargılarından etkilenmemektedir. Bu duruma en iyi örnek; Tesaura'nın TD-Gammon programının yaptığı bazı hamlelerin, aynı durum için uzmanların düşündüğü en iyi hamlelerden daha iyi olmasıdır [25].

Pekiştirmeli öğrenme, mobil robotlar bilinmeyen bir ortama yerleştirildiğinde çevre ile deneme yanılma etkileşimi kurarak en uygun davranış politikalarını seçmesine olanak sağlayan bir makine öğrenmesi şeklidir [26]. Pekiştirmeli öğrenme, tasarlanan hedefi (toplam hedefi) en üst düzeye çıkararak en uygun kararı vermeyi amaçlar [27]. Bu çalışmada pekiştirmeli öğrenmenin Q-Öğrenme (Q-Learning) [28-30], SARSA, Derin Q-Ağı (Deep Q-Network, DQN) [31-32], İkili Derin Q-Ağı (Double Deep Q-Network, DDQN) [33-34] ve A3C (Asynchronous Advantage Actor-Critic) [32] [34] algoritmaları üstünde durulmuştur.

Q-Öğrenme algoritması değer temelli bir pekiştirmeli öğrenme algoritmasıdır. Çevrimiçi öğrenme öğrenebilme yeteneği ve sadeliği ile robotikte tercih edilir [30].

SARSA algoritması, politika kullanmayan Q-öğrenmenin politika kullanması ile değiştirilmiş halidir.

Son zamanlarda ise pekiştirmeli öğrenme ve derin sinir ağlarının problemi çözmek için birleştirilmesi yaygındır. Yapay sinir ağları, yüksek boyutlu verilerle başa çıkabilme ve özellikleri daha iyi öğrenebilme yeteneğine sahipken, pekiştirmeli öğrenme bir sistemi yeni görevlerle ve yeni ortamlarla harekete geçirebilmeyi sağlamaktadır [35].

DQN algoritması belirli bir durum için eylem değerlerini veren çok katmanlı bir sinir ağıdır. DQN evrişimsel sinir ağının (CNN) bir çeşididir. Çıktılar sınıf değildir, ajanın ortamdaki durumuna yanıt olarak almayı öğrendiği her bir eyleme karşılık gelen Q değerleridir [36].

DDQN algoritmasında amaç hedefteki maksimum işlemi eylem seçimi ve eylem değerlendirmesine parçalayarak aşırı tahminleri azaltmaktadır. Ayrıca DDQN daha fazla esneklik ve daha yüksek performans sağlar.

Google DeepMind grubu A3C algoritmasını Q-öğrenme ve Policy Gradient metotlarını birleştirerek elde etmiştir. Bu algoritmada birkaç ajan eşzamanlı olarak çalışır ve her ajan kendi çevresinin kopyası olan ortamla etkileşime girer. Bu algoritmanın tek ajana sahip olan algoritmadan daha iyi çalışmasının sebebi her ajanın deneyiminin diğerlerinin deneyiminden bağımsız olmasıdır. Bu şekilde eğitim için mevcut deneyim daha çeşitlenmiş hale gelir [31].

Bu çalışma 2. bölümde navigasyon problemini, 3. bölümde navigasyon problemi için pekiştirmeli öğrenme kullanımını, 4. bölümde navigasyon problemi için pekiştirmeli öğrenmenin avantajlarını ve dezavantajlarını ele almıştır.

II. MOBİL ROBOTLARDA NAVİGASYON

Karmaşık ve yapılandırılmamış ortamlarda otonom bir şekilde gezinme yeteneği mobil robot navigasyonunda önemli bir rol oynar; bu durum mobil robotların teslimat, arama ve kurtarma, inceleme, nakliye, gezegen keşfi ve yaşlı bakımı gibi çeşitli zorlu pratik uygulamalarda güvenli ve verimli bir şekilde çalışmasını sağlar [37]. Nurmaini ve Tutuko [38], mobil robotlarda navigasyon problemini sensör ve kontrol sürecine dayanarak; harita tabanlı, iletişim tabanlı, davranış

tabanlı ve öğrenme tabanlı olmak üzere dört ayrı dalda incelemiştir.

A. Harita Tabanlı Navigasyon

Geleneksel yol planlama yöntemi olarak da bilinen harita tabanlı navigasyon yöntemi; haritalama, lokalizasyon ve yol planlamanın birleşimidir [39]. Harita tabanlı navigasyonda eş zamanlı lokalizasyon ve haritalama (SLAM) algoritmaları öne çıkmaktadır.

SLAM algoritmalarının [] çoğu, ortamın statik olduğu varsayımıyla geliştirilmiştir. Olasılıklı formülasyonlar, Genişletilmiş Kalman Filtreleri (GKF, EKF) ve partikül filtreleri robotun ve haritanın pozuna yaklaşmak için maksimum olasılık tahminine dayanmaktadır ve Durrant-Whtye ve Bailey tarafından iki farklı raporda gözden geçirilmiştir. [41-43]'te sunulan çalışma, robotun iç ortamlarda lokalizasyonu için kablosuz sinyal gücünü kullanır. Ortam hareketli nesnelerden oluştuğunda, konum değişiklikleri mobil robotların lokalizasyonunu ve haritalamasını etkiler.

B. Davranış Tabanlı Navigasyon

Davranış temelli yaklaşıma yerel hareket planlama da denir. Bu, robotun çevre bilgilerini algılayabileceği ve yalnızca sensör kapsamı içinde bir yol belirleyebileceği anlamına gelir. Yerel ortam değiştiğinde (örnek olarak, robot yeni bir konuma hareket ettiğinde), robotun yolu yeniden planlaması gerekir. Bununla birlikte, bu yaklaşım bazı sabit davranış kurallarına dayanmaktadır. Dolayısıyla robot birçok durumla ve karmaşık bir çevreyle başa çıkamaz [29] vardır: engellerden kaçınma, duvar takibi, koridor takibi ve hedef arama. Davranış tabanlı navigasyon, çevre haritalama ve robot davranışları gibi iki süreç birleştirilerek geliştirilebilir [38][44]. Eski bir yöntem olmakla birlikte günümüzde kullanımı çeşitli yöntemleri birleştirerek gerçekleştirilebilmektedir.

C. İletişim Tabanlı Navigasyon

Robotik sistem tabanlı iletişim, mobil robotlarda akıllı navigasyon alanında yeni bir platformdur. İletişim tabanlı navigasyon algoritmaları çoğunlukla sürü robotlarda veya diğer bir ifadeyle çoklu robot ortamlarında kullanılır [38].

[45]'teki çalışmada sürü robotlar için haberleşmeye dayalı bir navigasyon algoritması sunulmaktadır. Sürü içerisinde oluşturulan kablosuz ağ üzerinden navigasyon bilgisi içeren mesajlar robotların birbirlerinin yönlendirilmesini sağlar. Çalışma bu algoritmanın kullanımını iki farklı senaryoda incelemiştir. İlk senaryoda sürü tek bir robotu bir hedefe yönlendirir, ikincisinde ise sürünün tüm robotları iki hedef arasında ileri geri hareket eder. Her iki durumda da, algoritma sürüdeki robotların hatalarına karşı dayanıklı olmakla birlikte etkili navigasyon sağlar. Dahası, ikinci durumda, sistem sürüsünün sağlam bir dinamik yapı içinde kendi kendine organize olmasına izin verdiğini göstermektedir. Bu kendi kendine organizasyon, navigasyon verimliliğini daha da artırır ve karmaşık ortamlardaki en kısa yolları bulabilir.

D. Öğrenme Tabanlı Navigasyon

Robotun birçok durumla ve karmaşık bir çevreyle başa çıkabilmesi için öğrenme tabanlı navigayon yaklaşımı önerilmiştir [29]. Bu yönteminde, mobil robotun otonom bir şekilde gezinme yapabilmesi için öncesinde çevresini iyice öğrenmesi gerekir. Daha önce yayınlanan çalışmalar, öğrenme yeteneğine dayalı yürütülen navigasyon problemini çözmek için yapay zeka içerikli yöntemler önermiştir.[38] Bununla birlikte, mobil robot navigasyonuna yapay zekayı dahil etmek için, olası çevre ile etkileşime girdiğinde tamamlanmamış problemler, yanlış ve belirsizlik durumundaki bazı kaygılar dikkate alınmalıdır. Bu belirli sistem yalnızca tek robot davranışlarıyla değil aynı zamanda çoklu robot davranışlarıyla da uyumludur. Karmaşık ortam gibi belirli bir durum bir robotun tüm görevleri yönetmesini çok zorlaştırır, böylece bir kontrol sürecinde daha fazla hata üretir. Bu nedenle, mobil robot üzerinde öğrenmeye dayalı navigasyonun önemli ölçüde daha fazla araştırılması, mevcut zorlukların üstesinden gelmeye yardımcı olacak yeni yöntemlerin keşfedilmesinde gerekli olacaktır.

III. NAVİGASYON PROBLEMİ İÇİN PEKİŞTİRMELİ ÖĞRENME

Pekiştirmeli öğrenme algoritmasında yer alan bir robotun amacı ödülünü en üst düzeye çıkarmaktır. Örneğin robot bir ortamda gezinirken engellerden kaçındıkça ödülün fazla tutulması ve aynı zamanda da bir engele çarptığında ona ceza verilmesi robotu daha çok ödül toplamaya teşvik eder, böylece tekrarlanan etkileşimlerle robot otonom bir şekilde gerçek zamanlı olarak çevresini öğrenebilir [46]. Şekil 3.1'de navigasyon probleminde pekiştirmeli öğrenme kabaca gösterilmiştir.

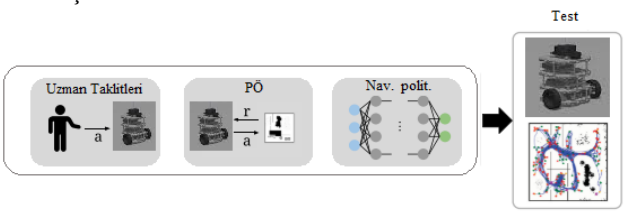

Şekil 3.1: Navigasyon probleminde pekiştirmeli öğrenme

Pekiştirmeli öğrenme, navigasyon problemi için ilk olarak 1986 yılında tanıtılan Q-Öğrenme algoritması ile uygulanmıştır. Robot navigasyonunda Q-öğrenmeyi uygulayan ilk çalışmalardan biri nispeten basit bir ödül işlevi kullanmıştır (Denk. 1). Burada hedef durumuna 1, çarpışma durumuna -1 ve diğer durumlara 0 atanmıştır [47].

$$Q: S \times A \rightarrow R \quad (1)$$

Denklem 1'de verilen Q-Öğrenmenin uygulanmasında sonuçlar her ne kadar umut verici olsa da hesaplama zamanı yüksektir; bu nedenle ilerleyen yıllarda hem Q-Öğrenme üzerine geliştirmeler yapılmıştır hem de diğer yapay zeka yöntemleri ile birlikte kullanılmıştır.

2011 yılında Q-Öğrenme tabanlı robot navigasyonu Jaradat ve ark. [48] yaptığı çalışmada, 100'den fazla eğitim yinelemesi sonucunda Q-değerlerinin Q-matrisinde tutulması gerektiğini öne sürmüştür. Gerçek ortamlarda, bir mobil robotun çalışma alanı birçok farklı engel içerir ve bu durum depolanması gereken Q değerlerinin miktarını arttırır, bu durum da yüksek işlem sürelerine dönüşür.

Pradipta K Das ve diğ. 2012 [49] yılında yaptıkları çalışmada Q-Öğrenmenin yukarıda belirtilen dezavantajlarını (zaman ve bellek) baz alarak Q-Öğrenmeyi geliştirmeyi amaçlamışlardır. Oluşturulan yeni algoritmada her durum, hedef durumuna ulaşmak için en iyi işlemi değil, sadece Q-değerini depolamıştır. Mevcut durum ile hedef arasındaki en iyi yol, şehir-blok mesafesi ile belirlenir; bu nedenle hedefe ulaşmak için birden fazla yol bulunacaktır. Sonuç olarak, robotun ihtiyaç duyduğu enerji minimuma ininceye kadar en iyi hareket seçimi yol planlamasına kadar ertelenir.

Daha sonra 2014 yılında Zuo ve arkadaşları bir robotun bilinmeyen bir labirentte navigasyonuna yardımcı olmak için

Q-öğrenme tabanlı bir yaklaşım önermişlerdir. Bu yaklaşım sadeliği ve iyi bir gerçek zamanlı performansı nedeniyle, Q-Öğrenmenin bir robotun çevreyi hızlı bir şekilde öğrenmesini ve içinde başarılı bir şekilde dolaşmasını sağlamak için oldukça etkili olduğunu göstermiştir [29].

Q-öğrenme algoritmasından sonra SARSA isimli pekiştirmeli öğrenme algoritması da navigasyon problemi için kullanılmaya başlanmıştır. SARSA algoritması ilk defa 1994 yılında [50] tarafından "değiştirilmiş Q-öğrenme" olarak tanıtılmıştır. Politika yaklaşımı kullanan en yaygın algoritma olan SARSA tüm işlemlerin mümkün olmasını sağlamak için ε-greedy yöntemini kullanır [Q-öğrenme ile arasındaki temel fark, bir sonraki durum için maksimum ödülün Q değerlerinin güncellenmesi için gerekli olmadığıdır. Bunun yerine, yeni eylem ve dolayısıyla ödül, orijinal eylemi belirleyen aynı politika kullanılarak seçilir. N. Altuntaş ve arkadaşları 2016 yılında yaptıkları çalışmada [50] mobil robotun navigasyon problemi için Q-öğrenme ve SARSA algoritmalarının performansını kıyaslamıştır. Yapılan kıyaslama sonucunda algoritmaların performansı şekil 3.2'de gösterilmiştir.

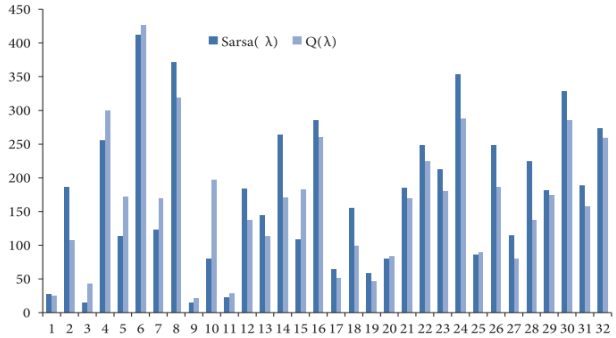

Şekil 3.2: Sarsa (λ) ve Q (λ) yöntemlerinin karşılaştırılması

Q-öğrenme veya Sarsa algoritmasının kullanıldığı durumlarda eğer ortam aşırı derecede büyükse, ödüllerin durum alanı o kadar seyrek olabilir ki, iyice keşfedilmesi de uzun zaman alacaktır. Bu nedenle bazı araştırmalar, performans artımı için bu algoritmaları diğer yapay zeka yöntemleriyle birleştirmeye çalışmıştır [46].

Mirowski ve ark. [51] tarafından 2017 yılında yapılan çalışmada derin pekiştirmeli öğrenme [52] (DRL) uçtan uca navigasyona uygulanmıştır. Robotların sık sık değişen başlangıç ve hedef konumunu içeren geniş ve görsel açıdan zengin ortamlarda gezinmesini sağlamak için, bellek ve yardımcı öğrenme hedefleri ile güçlendirilmiş derin pekiştirmeli öğrenme yöntemini önermiştir. Yapılan çalışmada derin pekiştirmeli öğrenmeyi yardımcı hedeflerle arttırma yaklaşımının [53], daha genel navigasyon stratejilerinin geliştirilmesini teşvik ettiği görülmüştür.

Chen ve diğ. [54], hareketli engeller olarak yayalara sahip bir yolda bileşik problemler için bir çözüm önermiştir. Ödül/ceza işlevinin oluşturulmasına katkıda bulunan yayalarla (hız, pozisyon, yarıçap gibi) ilişkili farklı özellikleri tahmin etmek için LIDAR sensör verilerinin kullanıldığı çalışmada, önerilen algoritmayı göstermek için bir donanım seti kullanılmıştır. Sonrasında 2018 yılında Tegg Taekyong Sung ve arkadaşları [27] pekiştirmeli öğrenmeyi model tabanlı [55-57] ve model bağımsız [58] olarak, navigasyon problemini ise Bilişsel Eşleştirici ve Planlayıcı (CMP) [59] ile Denetimsiz Pekiştirmeli ve Yardımcı Öğrenme (UNREAL) [27] olarak ayırmıştır. Çalışmada öğrenme ajanı olarak Turtlebot3 [60] mobil robotu ve şekil 3.3'te gösterilen ortam kullanılmıştır.

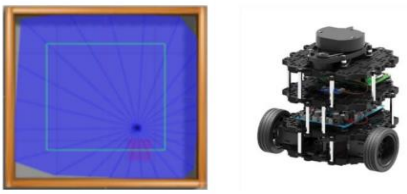

Şekil 3.3: **Solda** 26 basit gözlem alanını içeren basit gezinme ortamı, **Sağda** gerçek robot, Turtlebot3 burger [60] gösterilmektedir.

Çalışmada model bağımsız DQN [61] algoritması farklı boyutlardaki gözlem alanlarıyla denenmiştir. Ayrıca pekiştirmeli öğrenmenin ölçeklenebilirlik özelliğindeki performansını da ölçmek için oluşturulan ortamda birden çok robot kullanılmıştır. Simülasyonlar Gazebo [62] simülatörü kullanılarak yapılmıştır Öğrenme algoritmasını güncellemek için her zaman adımında, ajan güncellemeden daha uzun zaman alan işlemleri beklemelidir. Bir başka fiziksel simülasyon olan OpenAI tarafından geliştirilen Gym [63], zamandan tasarruf sağlayan açma / kapama sahneleme (rendering) işlemini sağlar böylece ajanın beklemek zorunda olduğu süre oldukça kısalır. 2016 yılında Open AI Gym kütüphanesi kullanılarak yapılan çalışmada [64] Robot İşletim Sistemi'ni (ROS) [65] ve Gazebo simülatörünü kullanarak robotlar için OpenAI Gym'in bir uzantısı sunulmaktadır. Çalışmada Q-Learning ve Sarsa algoritmaları kullanılarak elde edilen sonuçlar ele alınmıştır. Sonuç olarak, bu çalışmanın çıktısı, robotik için farklı tekniklerin ve algoritmaların aynı sanal koşullar kullanılarak karşılaştırılmasına olanak sağlayan bir kıyaslama sistemi sunar.

Bahsedilen bu çalışmalara genel olarak bakıldığında ajanın yani robotun bulunduğu ortama göre uygun davranışı öğrenmesi ve buna bağlı olarak da otonom bir şekilde ister statik ister dinamik ortamda gezinmesi beklenir. Bu çalışmalardan farklı olarak 2016 yılında yapılan bir çalışmada [36], robota girdi olarak yalnıza RGB-D sensöründen gelen çevreye dair görüntüler verilmiştir. Derinlik görüntüsünün özellik gösterimi önceden eğitilmiş evrişimsel sinir ağları CNN [66] modeli ile çıkartılmıştır ve DQN algoritmasının yapay zeka konusundaki son başarısına dayanarak, robot kontrolör birkaç farklı benzetilmiş ortamda keşif ve engellerden kaçınma yeteneklerine ulaşmıştır.

Van Hasselt ve arkadaşları 2016 yılında Q-öğrenmede aşırı tahmin probleminin üstesinden gelmek için DDQN [33] algoritmasını önermiştir. Böylece elde edilen sonuçlar daha genellenebilir hale gelir.

Mnih ve arkadaşları da 2016 yılında A3C algoritmasını kullanmışlardır. Bu algoritmada paralel aktörler eğitimi dengelemek için farklı keşif politikaları kullanır, böylece deneyim tekrarı yaşanmaz. Derin Pekiştirmeli Öğrenme (DRL) tekniklerini kullanarak navigasyon hakkında daha ileri çalışmalar; Zhu ve ark. [67], Schaul ve ark. [68], He ve ark. [69], Kolve ve ark. [70], Zhu ve ark. [71], Long ve ark. [72], Gupta ve ark. [73], Khan ve ark. [74] Bruce ve ark. [75], Chaplot ve ark. [76] ve Savinov ve ark. [77].

IV. NAVİGASYON PROBLEMİNDE PEKİŞTİRMELİ ÖĞRENMENİN AVANTAJLARI VE DEZAVANTAJLARI

A. *Avantajları*

Otonom navigasyon, araçların otonom sürüşü için çözülmesi gereken en önemli konulardan biridir. Özellikle son

yıllarda bu konu üzerine çalışmalar yapılmış ve birçok teknik geliştirilmiştir.

Pekiştirmeli öğrenmenin navigasyon problemi için uygulanmasının en temel nedeni; öğretmen olmayan bir öğrenme şekli olmasıdır. Diğer yaklaşımlarla kıyaslandığında aracın ortam hakkında önceden bir bilgi sahibi olmasına veya dışarıdan bir etki olmasına gerek yoktur (denetimli öğrenmenin aksine). Ortamdaki anlık değişimlere gerçek zamanlı çözümler üretebildiği için dinamik ortamlarda da uygulanabilmiştir. Tablo 4.1'te geçmiş yıllardan bu yana navigasyon problemi için kullanılan çeşitli yaklaşımlar gösterilmiştir. Bu yaklaşımlar kullandığı stratejilere, gerçek zamanlılığa ve ön bilgi gereksinimine göre kıyaslanmıştır. Başlarda ortam hakkında tüm durumların bilindiği çevrimdışı planlama algoritmaları yeterliyken problem uzayının genişlemesi ile dinamik yöntemlere ihtiyaç duyulmuştur. Pekiştirmeli öğrenme kullanılarak yapılan yol planlama işlemlerinde, ajan (robot) ortamdaki değişikliklere gerçek zamanlı strateji geliştirebildiği ve bir öğretmene ihtiyaç duymadığı için navigasyon probleminde oldukça iyi performans göstermiştir.

B. Dezavantajları

Pekiştirmeli öğrenme kullanılarak yapılan navigasyon çalışmalarının çoğunda gerçek robot üzerinde eğitim işlemi yapılmadan önce simülasyon ortamında test edilmiştir. Bunun en temel nedeni eğitim işleminin uzun sürmesi ve bu nedenle robotun sahip olduğu fiziksel ekipmanların yeterli olup olmadığından emin olunamamasıdır. Bu sorunu önlemek amacı ile öğrenme algoritmasını paralel bir şekilde çalıştırma [79] veya denetimsiz pekiştirmeli ve yardımcı öğrenme (UNREAL) [27] gibi yaklaşımlar çözüm olarak görülmüştür.

Metodlar	Strateji	Ön Bilgi	Gerçek Zamanlılık	Yorumlar
A*	Arama Tabanlı Yaklaşım	Var	Çevrimdışı Planlama	Maliyetli olan yolları genişletmekten kaçınır.
Dijkstra Algortitması				Olası tüm yolları inceler bu yüzden uzun sürer
Greedy Best First Search				Optimal yolu hızlıca bulur, ancak her zaman işe yaramaz
PRM	Örnekleme tabanlı Planlama	Var	Çevrimdışı Planlama	C uzayından rastgele bir düğüm seçer ve çoklu sorgu gerçekleştirir
RRT				C uzayından rastgele bir düğüm seçer ve artımlı olarak yeni düğüm ekler
PF	Potansiyel Alan Tabanlı Yaklaşım	Yok	Çevrimiçi Planlama	Birkaç dezavantajı var: yerel minima, dar yoldan geçiş yok, dar geçitlerde salınımlar
VFF				Yerel minima sorununun üstesinden gelmekle birlikte diğer iki eksiklik hala var
VFH,VFH'				Dezavantajları aşmak ancak sorunlu senaryolar var
VFH*		Var		Sorunlu senaryoların üstesinden gelir, ancak bir haritadaki bilgilere dayanır.
FLC	Bulanık mantık Tabanlı Yaklaşım	Yok	Çevrimiçi Planlama	Farklı duyusal bilgilere göre çeşitli kararlar verir.
Pekiştirmeli Öğrenme	Derin Pekiştirmeli Öğrenme Tabanlı Yaklaşım	Yok	Çevrimiçi Planlama	İyi eğitimli bir sinir ağından en uygun kararları verir. Robot eğitim sırasında yeterli deneyime sahip olduğu sürece karmaşık senaryoların üstesinden gelinebilir

Tablo 4.1: Yol planlama yaklaşımlarının kıyaslanması [78]

V. SONUÇ

Bu çalışmada, mobil robotlarda navigasyon problemine çözüm olarak önerilen pekiştirmeli öğrenme ile otonom navigasyon konusu incelenmiştir. Son yıllarda bu alanda yapılan çalışmalara bakıldığında SLAM algoritmaları, sezgisel algoritmalar (A*, D* vb.) ve dinamik programlama problem için yeterli gelirken durum uzayı genişledikçe bu yöntemler beklenen performansı gösterememiştir. Özellikle dinamik bir ortam için SLAM algoritmaları ve dinamik programlamanın birlikte kullanılması çözüm olarak görülmüşken, pekiştirmeli öğrenmeye kıyasla ciddi performans farklılıkları görülmektedir. Pekiştirmeli öğrenme, öğrenme hareketlerini yakalama yeteneklerinin yanı sıra optimum algısal işlevleri de kullandığı için daha iyi sonuçlar vermiştir. Bu sonuçlar ele alındığında, gelecekte mobil robotların navigasyon probleminde pekiştirmeli öğrenme kullanımının daha da artması beklenmektedir.

KAYNAKÇA

[1] S. Chitta, I. S¸ucan, and S. Cousins, "Moveit!" IEEE Robotics Automation Magazine, vol. 19, no. 1, pp. 18–19, Mar. 2012

[2] Hu Y., Yang S. X., A Knowledge Based Genetic Algorithm for Path Planning of a Mobile Robot, Proceedings of the 2004 IEEE, International Conference on Robotics & Automation, New Orleans, LA, 2004.

[3] A. Ramirez-Serrano, H. Liu and G. C. Pettinaro. Mobile robot localization in quazi-dynamic environments. Int. J. on Ind. Robot, 2008.

[4] K. H. Sedighi, K. Ashenayi, T. W. Manikas, R. L. Wainwright, and H. M. Tai, Autonomous Local Path Planning for a Mobile Robot Using a Genetic Algorithm, in Congr. Evol. Comput. 2004.

[5] I. Altaharwa, A. Sheta, M. Alweshah, I. Al-Taharwa, and M. Al-Weshah, "A Mobile Robot Path Planning Using Genetic Algorithm in Static Environment Trust Framework for Arabic Online Ecosystem View project Climate Data Modeling-SW App View project A Mobile Robot Path Planning Using Genetic Algorithm in Static Environment," J. Comput. Sci., vol. 4, no. 4, pp. 341–344, 2008.

[6] R. Smierzchalski, Z. Michalewicz, "Path Planning in Dynamic Environments, Innovations in Robot Mobility and Control," 2005.

[7] I. A. S, M. Moll, L. E. Kavraki, and S. Member, The Open Motion Planning Library, Robotics & Automation Magazine, IEEE. 2012.

[8] M. Noto, H. Sato, "A Method for the Shortest Path Search by Extended Dijkstra Algorithm," 2000 IEEE International Conference on Systems, Man, and Cybernetics, Nashville, TN, USA, 8-11 October 2000.

[9] P. E. Hart,N. J. Nilsson, B. Raphael, "A formal basis for the heuristic determination of minimum cost paths," IEEE Trans. Syst. Science and Cybern., 1968, 4(2), 100-107.

[10] H. Myint, "Development of Robot Navigation System with Collision Free Path Planning Algorithm," vol. 3, no. 3, pp. 60–68, 2018.]

[11] L. Cheng, C. Liu, and B. Yan, "Improved hierarchical A-star algorithm for optimal parking path planning of the large parking lot," 2014 IEEE Int. Conf. Inf. Autom. ICIA 2014, no. July, pp. 695–698, 2014.

[12] A. R. Soltani, H. Tawfik, J. Y. Goulermas, and T. Fernando, "Path planning in construction sites : performance evaluation of the Dijkstra , A* , and GA search algorithms," Adv. Eng. Informatics, 2003.

[13] Ç. Ündeğer Ç., Single and Multi Agent Real-Time Path Search in Dynamic and Partially Observable Environments, Doktora Tezi, Orta Doğu Teknik Üniversitesi, Fen Bilimleri Enstitüsü, Ankara, 2007.

[14] Ç. Undeger C., Polat F., RTTES: Real-time search in dynamic environments, Applied Intelligence, 2007, 27(3), 113-129

[15] S. Koenig, Likhachev M., Liu Y., Furcy D., Incremental Heuristic Search in Artificial Intelligence, Artificial Intelligence Magazine, 2004.

[16] A. Stentz A., The focussed D* algorithm for real-time replanning, In Proceedings of the International Joint Conference on Artificial Intelligence, Canada, 20-25 August 1995.

[17] S. Koenig S., Likhachev M., D* Lite, Proceedings of the Eighteenth National Conference on Artificial Intelligence (AAAI), 2002.

[18] V. Bulitko, G. Lee GREGLEE, "Learning in Real-Time Search: A Unifying Framework," 2006.

[19] J. Velagic, B. Lacevic, and N. Osmic, "Nonlinear Motion Control of Mobile Robot Dynamic Model," Motion Plan., no. May 2014, 2012.

[20] I. Muhammad, J. & Bucak, I. O. An improved Q-learning algorithm for an autonomous mobile robot navigation problem. 239–243, 2013.

[21] T. Zeng, "Learning Continuous Control through Proximal Policy Optimization for Mobile Robot Navigation."

[22] T. Hickey, T., & Learning, A. R. (n.d.). Reinforcement Learning Algorithms for Robotic Navigation in Dynamic Environments, 2004.

[23] M. Knopp, "Reinforcement Learning for Robotic Navigation,", 2013.

[24] J. Shabbir and T. Anwer, "A Survey of Deep Learning Techniques for Mobile Robot Applications," vol. 14, no. 8, pp. 1–10, 2018.

[25] G. Tesauro. Temporal difference learning and td-gammon. Communications ofthe ACM, 38(3):58–68, 1995.

[26] F. Cruz, J. Twiefel, S. Magg, C. Weber, and S. Wermter, "Interactive reinforcement learning through speech guidance in a domestic scenario,"

in Neural Networks (IJCNN), 2015 International Joint Conference on. IEEE, 2015, pp. 1–8.
[27] T. T. Sung, C. Kim, K. Lee, and C. Sohn, “Exploring Navigation using Deep Reinforcement Learning,” vol. 13, no. 19, pp. 14447–14450, 2018.
[28] H. Çetin, H. Q-öğrenme algoritması ile mobil robotların yol planlaması Path planning of mobile robots with Q-learning. 2162–2165, 2014
[29] B. Zuo, B., Member, S., Chen, J., Wang, L. & Wang, Y. A Reinforcement Learning Based Robotic Navigation System. 3452–3457, 2014
[30] Li, C., Zhang, J. & Li, Y. Application of artificial neural network based on Q-learning for mobile robot path planning. Proc. IEEE ICIA 2006 - 2006 IEEE Int. Conf. Inf. Acquis. 978–982 (2006).
[31] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg, and D. Hassabis, “Human-level control through deep reinforcement learning,” Nature, vol. 518, no. 7540, pp. 529–533, 2015.
[32] L. Yuxi. “Deep Reinforcement Learning: An Overview,” 2017.
[33] H. v. Hasselt, A. Guez, and D. Silver, “Deep reinforcement learning with double q-learning,” in Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence, ser. AAAI’16. AAAI Press, 2016, pp. 2094– 2100.
[34] V. Mnih, A. P. Badia,M. Mirza, A. Graves, T. Harley, T. P. Lillicrap, D. Silver, K. Kavukcuoglu, “Asynchronous methods for deep reinforcement learning,” In the International Conference on Machine Learning, 2016.
[35] H.-D. Kieu, L. Pham, T.-L. Vuong, D.-V. Nguyen, and T.-H. Le, “Vision Memory for Target Object Navigation Using Deep Reinforcement Learning: An Empirical Study,” 2018 IEEE Int. Conf. Syst. Man, Cybern., pp. 3267–3273, 2019.
[36] L. Tai and M. Liu, “Mobile robots exploration through cnn-based reinforcement learning,” Robot. Biomimetics, vol. 3, p. 24, 2016.
[37] L. Nalpantidis, “Survey of Model-Based Reinforcement Learning: Applications on Robotics Athanasios S. Polydoros” Lazaros Nalpantidis. J Intell Robot Syst, 86(September), 153–173, 2017.
[38] S. Nurmaini ve B. Tutuko, “Intelligent robotics navigation system: Problems, methods, and algorithm,” Int. J. Electr. Comput. Eng. 2017.
[39] J.-A.Meyer, D.Filliat,“Map-based navigation in mobile robots:II.A review of map-learning and path-planning strategies,” Cogn.Syst.Res., 2003.
[40] J. Clemens, T. Reineking, and T. Kluth, “An evidential approach to SLAM, path planning, and active exploration,” Int. J. Approx. Reason., vol. 73, pp. 1–26, 2016.
[41] H. Durrant-Whyte, T. Bailey. "Simultaneous localization and mapping: part I." IEEE robotics & automation magazine 13, no. 2, 99-110, 2006.
[42] T. Bailey, H. Durrant-Whyte. "Simultaneous localization and mapping (SLAM): Part II." IEEE Robotics & Automation Magazine 13, 2006.
[43] S. Shue, “Utilization of Wireless Strength for Mobile Robot Localization in IndoorEnvironments.”PhD diss.,TheUniversity of NorthCarolina, 2017.
[44] S. X. Yang, et al., “An embedded fuzzy controller for a behavior-based mobile robot with guaranteed performance,” IEEE Transactions on Fuzzy Systems, vol/issue: 12(4), pp. 436-446, 2004
[45] F. Ducatelle, G. A. Di Caro, C. Pinciroli, F. Mondada, and L. Gambardella, “Communication assisted navigation in robotic swarms: Self-organization and cooperation,” IEEE Int. Conf. Intell. Robot. Syst., pp. 4981–4988, 2011.
[46] M. Duguleana and G. Mogan, “Neural networks based reinforcement learning for mobile robots obstacle avoidance,” Expert Syst. Appl., 2016.
[47] Smart & Kaelbling, 2002 Smart, W. , & Kaelbling, L. (2002). Effective reinforcement learning for mobile robots. In Proceedings of IEEE international conference on robotics and automation, ICRA’02: vol. 4.
[48] M. A. K. Jaradat, M. Al-Rousan, L. Quadan, “Reinforcement based mobile robot navigation in dynamic environment,” Robotics and Computer-Integrated Manufacturing, 27, 135–149, 2011.
[49] P. KDas, S. C. Mandhata, H. S. Behera, and S. N. Patro, “An Improved Q-learning Algorithm for Path-Planning of a Mobile Robot,” Int. J. Comput. Appl., vol. 51, no. 9, pp. 40–46, 2012.
[50] N. Altuntaş, Nihal; İmal, Erkan; Emanet, Nahit; Öztürk, Ceyda, “Reinforcement learning-based mobile robot navigation,” TÜBİTAK Turkish J. Electr. Eng. Comput. Sci., pp. 1747–1767, 2016.
[51] P. Mirowski, R. Pascanu, F. Viola, H. Soyer, A. J. Ballard, A. Banino, M. Denil, R. Goroshin, L. Sifre, K. Kavukcuoglu, D. Kumaran, R. Hadsell. Learning to navigate in complex environments. 2017.
[52] M. Jaderberg, V. Mnih, W. M. Czarnecki, T. Schaul, J. Z. Leibo, D. Silver, K. Kavukcuoglu, “Reinforcement learning with unsupervised auxiliary tasks,” 2016, arXiv preprint arXiv:1611.05397.
[53] Y Zhang, K Lee, H Lee, “Augmenting supervised neural networks with unsupervised objectives for large-scale image classification,” In Proc. of International Conference on Machine Learning, ICML, 2016
[54] Y. F. Chen, M. Everett, M. Liu, J. P. How, “Socially aware motion planning with deep reinforcement learning,” In Proceedings of the 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Vancouver, BC, Canada, 24–28 September 2017, pp. 1343–1350.
[55] J. Boedecker, J. Springenberg, J. Wulfing, and M. Riedmiller, “Approximate real-time optimal control based on sparse gaussian process models,” in Adaptive Dynamic Programming and Reinforcement Learning (ADPRL), 2014.
[56] M. P. Deisenroth and C. E. Rasmussen, “PILCO: A model-based and data-efficient approach to policy search,” in Proceedings of the 28th International Conference on Machine Learning, L. Getoor and T. Scheffer, Eds. Bellevue, Washington, USA: Omnipress, 2011.
[57] T. Moldovan, S. Levine, M. Jordan, and P. Abbeel, “Optimism-driven exploration for nonlinear systems,” in International Conference on Robotics and Automation (ICRA), 2015.
[58] Q. J. M. Huys, A. Cruickshank, P. Seriès “Reward-Based Learning, Model-Based and Model-Free,” In: Jaeger D., Jung R. (eds) Encyclopedia of Computational Neuroscience. Springer, New York, NY, 2014.
[59] S. Gupta, J. Davidson, S. Levine, R. Sukthankar and J. Malik, "Cognitive Mapping and Planning for Visual Navigation," *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, HI, 2017, pp. 7272-7281.
[60] C. N. Thai, “Exploring Robotics with ROBOTIS Systems,” 2017
[61] V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra, M. Riedmiller, “Playing atari with deep reinforcement learning,” 2013
[62] K. Nathan H. Andrew. “Gazebo-3d multiple robot simulator with dynamics,” 2006.
[63] G. Brockman, C. Vicki, P. Ludwig, S. Jonas, S. John, T. T. Jie, Z. Wojciech, “Openai gym,” 2016
[64] I. Zamora, N. G. Lopez, V. M. Vilches, and A. H. Cordero, “Extending the OpenAI Gym for robotics: a toolkit for reinforcement learning using ROS and Gazebo,” no. August, pp. 1–6, 2016.
[65] M. Quigley, K. Conley, B. P Gerkey, J. Faust, T. Foote, J. Leibs, R. Wheeler, A. Y Ng, “ROS: an open-source Robot Operating System,” ICRA Workshop on Open Source Software, Vol. 3, 3.2. Japan, 2009.
[66] Y. Sun, X. Wang, X. Tang “Deep convolutional network cascade for facial point detection,” In: Proceedings of the IEEE conference on computer vision and pattern recognition; 2013. p. 3476–83.
[67] Y. Zhu, R. Mottaghi, E. Kolve, J. J. Lim, A. Gupta, L. Fei-Fei, A. Farhadi, “Target-driven visual navigation in indoor scenes using deep reinforcement learning,” In Proceedings of the 2017 IEEE International Conference on Robotics and Automation (ICRA), Singapore, 2017.
[68] T. Schaul, D. Horgan, K. Gregor, D. Silver, “Universal value function approximators,” In Proceedings of the International Conference on Machine Learning, Lille, France, 6 July–11 July 2015; pp. 1312–1320.
[69] K. He, X. Zhang, S. Ren, J. Sun, “Deep residual learning for image recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas,” NV, USA, 27–30 June 2016.
[70] E. Kolve, R. Mottaghi, D. Gordon, Y. Zhu, A. Gupta, A. Farhadi, “AI2-THOR: An Interactive 3d Environment for Visual AI,” 2017.
[71] J. Y. Zhu, T. Park, P. Isola, A. A. Efros, “Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks,” arXiv 2017
[72] P. Long, T. Fan, X. Liao, W. Liu, H. Zhang, J. Pan, “Towards Optimally Decentralized Multi-Robot Collision Avoidance via Deep Reinforcement Learning,” 2017.
[73] S. Gupta, J. Davidson, S. Levine, R. Sukthankar, J. Malik, “Cognitive Mapping and Planning for Visual Navigation,” arXiv 2017.
[74] A. Khan, C. Zhang, N. Atanasov, K. Karydis, V. Kumar, D. D. Lee, Memory Augmented Control Networks,” 2017.
[75] J. Bruce, N. Sünderhauf, P. Mirowski, R. Hadsell, “Milford, M. “One-Shot Reinforcement Learning for Robot Navigation with Interactive Replay.” 2017.
[76] D.S. Chaplot, E. Parisotto, R. Salakhutdinov, “Active Neural Localization.,” 2018.
[77] N. Savinov, A. Dosovitskiy, V. Koltun, “Semi-Parametric Topological Memory for Navigation,” 2018.
[78] S. Feng, P. Ben-Tzvi, E. Komendera, and T. Furukawa, “Mobile Robot Obstacle Avoidance based on Deep Reinforcement Learning,” 2018.
[79] S.-H. Chan, P.-T. Wu, L.-C. Fu, K. Xiao, and S.-H. Hsu, “Distributed Deep Reinforcement Learning based Indoor Visual Navigation,” 2019.