HİPERPARAMETRELERİN LSTM TABANLI DOĞAL DİL İŞLEME MODELLERİ ÜZERİNDEKİ ETKİSİNİN İNCELENMESİ

Ramazan KATIRCI
Sivas Cumhuriyet Üniversitesi, Sivas Bilim ve Teknoloji Üniversitesi
ORCID ID: 0000-0003-2448-011X
Metin ZONTUL
Sivas Bilim ve Teknoloji Üniversitesi, Mühendislik ve Doğa Bilimleri Fakültesi, Bilgisayar Mühendisliği Bölümü
Oğuz KAYNAR
Sivas Cumhuriyet Üniversitesi, İktisadi ve İdari Bilimler Fakültesi, Yönetim Bilişim Sistemleri Bölümü(Sorumlu Yazar)

ÖZET

Yapay zekâ (YZ), teknolojik gelişmelerin en önemlilerinden biridir ve birçok alanda insan işlerini daha hızlı ve doğru bir şekilde yapabilmektedir. Bu teknolojinin bir alt kategorisi olan sohbet robotları, doğal dilde iletişim kurabilen bir teknolojidir ve son yıllarda popüler hale gelmiştir. Sohbet robotları, müşteri hizmetleri, sağlık sektörü, eğitim ve eğlence gibi birçok alanda yaygın olarak kullanılmaktadır. Sohbet robotlarının geliştirilmesinde LSTM (Long Short-Term Memory) modelleri yaygın olarak kullanılmaktadır. Bu çalışmanın amacı, çeşitli hiperparametrelerin ve bu hiperparametrelerin birbirleriyle etkileşimlerinin, LSTM tabanlı bir doğal dil işleme (NLP) modelinin performansı üzerindeki etkilerini araştırmaktır. Çalışmada, 140873 satırlık İngilizce-Türkçe çeviri veri seti kullanılmıştır. Eğitim için, karakter tabanlı LSTM modeli tercih edilmiştir. Hiperparametre optimizasyonunda, gizli boyut (latent dimension), öğrenme hızı (learning rate), devir sayısı (epoch), yığın boyutu (batch size) ve düşürme oranı (dorpout rate) kullanılmıştır. Ayrıca veri seti boyutu arttıkça hiperparametrelerin davranışlarındaki değişim araştırılmıştır. Bu kapsamda veri setindeki örnek sayısı 1000 ve 10000 iken hiperparametreler arasındaki etkileşim incelenmiştir.

Sonuç olarak gizli boyut (latent dimension), öğrenme hızı (learning rate) ve devir sayısının arttırılması model doğruluğu üzerinde pozitif etki yaratırken, yığın boyutu (batch size) ve düşürme oranının (dorpout rate) arttırılması model performansını olumsuz yönde etkilemiştir. Özellikle, öğrenme hızının, modelin doğruluk oranı ve kayıp değerleri üzerinde en önemli etkiye sahip olduğu tespit edilmiştir. Diğer bir sonuç, veri setindeki örnek sayısı 1000 iken hiperparametreler arasında etkileşim gözlenmezken, örnek sayısı 10000'e yükseltildiğinde hiperparametreler arasında önemli derecede etkileşim olduğu gözlenmiştir. Bu bulgu, veri setindeki örnek boyutunun değişmesi hiperparametre davranışlarını önemli derecede değiştirdiğini göstermiştir.

Anahtar Kelimeler: Doğal Dil İşleme, LSTM, Hiperparametreler, Makine Öğrenmesi, Metin Verisi

INVESTIGATION OF THE EFFECT OF HYPERPARAMETERS ON LSTM-BASED NATURAL LANGUAGE PROCESSING MODELS

ABSTRACT

Artificial intelligence (AI) is one of the most important technological developments and can do human work more quickly and accurately in many areas. Chatbots, a subcategory of this technology, are a technology that can communicate in natural language and have become popular in recent years. Chatbots are widely used in many areas such as customer service, healthcare, education and entertainment. LSTM (Long Short-Term Memory) models are widely used in the development of chatbots. The aim of this study is to investigate the effects of various hyperparameters and their interactions on the performance of an LSTM-based natural language processing (NLP) model. In the study, an English-Turkish translation data set of 140873 lines was used. For training, the character-based LSTM model was preferred. In hyperparameter optimization, latent dimension, learning rate, epoch, batch size and dorpout rate are used. In addition, the change in the behavior of hyperparameters was investigated as the size of the data set increased. In this context, while the number of samples in the data set was 1000 and 10000, the interaction between hyperparameters was examined.

As a result, while increasing the latent dimension, learning rate and number of revolutions had a positive effect on the model accuracy, increasing the batch size and the dorpout rate negatively affected the model performance. In particular, it has been determined that the learning rate has the most significant effect on the accuracy and loss values of the model. Another result is that when the number of samples in the data set is 1000, there is no interaction between the hyperparameters, but when the number of samples is increased to 10000, there is a significant interaction between the hyperparameters. This result showed that changing the sample size in the data set significantly changed the hyperparameter behaviors.

Keywords: Natural Language Processing, LSTM, Hyperparameters, Machine Learning, Text Data

1. GİRİŞ

Büyük miktarda verinin hızla arttığı çağımızda, bu verilerden yararlanmak ve bilgi çıkarmak için etkili yöntemlere ihtiyaç duyulmaktadır (Halevy, Norvig, ve Pereira, 2009). Doğal dil işleme (NLP), metin ve konuşma verilerini anlamlandırmak ve işlemek için kullanılan bir yapay zekâ (AI) alt dalıdır (Bishop, 2006). NLP'nin birçok uygulaması bulunmaktadır, örneğin duygu analizi (Liu, 2012), metin sınıflandırması (Sebastiani, 2002), otomatik özetleme (Nenkova ve McKeown, 2011) ve makine çevirisi (Koehn, 2009).

NLP'nin performansını etkileyen birçok faktör bulunmaktadır. Özellikle, makine öğrenmesi tabanlı NLP modellerinin hiperparametrelerinin ayarlanması, model performansını büyük ölçüde etkilemektedir (Bergstra ve Bengio, 2012). Bu hiperparametreler arasında gizli boyut (Chung ve diğerleri, 2014), öğrenme oranı (Kingma ve Ba, 2014), devir sayısı (Bottou, 2010), yığın boyutu (Bousquet ve Bottou, 2008) ve düşürme oranı (Srivastava ve diğerleri, 2014) gibi faktörler bulunmaktadır. Bunların her biri, modelin genelleştirme yeteneğini ve nihai performansını etkilemektedir (Arpit ve diğerleri, 2017).

Uzun Kısa Vadeli Hafıza (LSTM) tabanlı bir model, bu hiperparametrelerin ayarlanmasının özellikle zor olduğu bir örnektir (Hochreiter ve Schmidhuber, 1997). LSTM'ler, metin verilerindeki uzun süreli bağımlılıkları modellemek için tasarlanmıştır ve bu nedenle birçok NLP görevinde kullanılmaktadır (Cho ve diğerleri, 2014). Ancak, doğru hiperparametrelerin seçimi, LSTM'lerin performansını iyileştirmede büyük önem arzetmektedir.

Bu çalışma, çeşitli hiperparametreler ve etkileşimlerin, LSTM tabanlı bir NLP modelinin performansını nasıl etkilediğini araştırmaktadır. Ayrıca veriseti boyutunun hiperparametre davranışına ne derece etki ettiği incelenmiştir. Veriseti olarak 140873 satırlık İngilizce-Türkçe sözlük kullanılmıştır. Modelin performansı, doğruluk (accuracy) ve kayıp (loss) metrikleri ile ölçülmüştür.

2. ARAŞTIRMA VE BULGULAR

2.1. Deneysel Çalışmalar

LSTM modeli python kodlama dili ile oluşturulmuştur. Veri seti olarak 140873 satırlık İngilizce-Türkçe sözlük kullanılmıştır. Model eğitimi için 1000 ve 10000 bin satır içeren İngilizce ve Türkçe metinler ana sözlükten rassal olarak seçilmiştir. Oluşturulan LSTM modeli, karakter tabanlı yöntem kullanılarak eğitilmiştir. Model eğitiminde, veri setindeki Türkçe cümlelerin karakterleri ve İngilizce çevirilerinin karakterleri ayrı ayrı toplanarak benzersiz karakter (karakter sözlüğü) listeleri oluşturulmuştur. Daha sonra, bu benzersiz karakterler sıralanmış ve her karaktere bir indeks ataması yapılmıştır. Hiperparametreler iki seviyeli olarak incelenmiştir. İncelenen seviyeler Tablo 1'de gösterilmiştir.

Tablo 1. İncelenen hiperparametreler ve seviyeleri

Hiperparametreler	Seviye 1	Seviye 2
Gizli boyut	64	128
Öğrenme oranı	0.001	0.01
Yığın boyutu	16	32
Düşürme oranı	0.2	0.4
Devir	10	25

2.2. Deneysel Sonuçlar

Bu araştırma, çeşitli hiperparametrelerin ve bu parametrelerin birbiriyle olan etkileşimlerinin model doğruluğu üzerindeki etkilerini detaylı bir şekilde incelemektedir. İncelenen hiperparametreler arasında gizli boyut, öğrenme oranı, yığın boyutu, düşürme oranı ve epoch sayısı bulunmaktadır. Şekil 1(a) ve 1(b), hiperparametrelerin kendi başına ve karşılıklı etkileşimlerinin model doğruluğu üzerindeki etkilerini göstermektedir. Gizli boyut, öğrenme oranı ve epoch sayısının artırılmasının model doğruluğunu olumlu yönde etkilediği, yığın boyutu ve düşürme oranının artırılmasının ise model doğruluğu üzerinde negatif bir etki oluşturduğu gözlemlenmiştir. Öğrenme oranı, model doğruluğu üzerinde en belirgin etkiye sahip olan hiperparametredir. Şekil 1(b) üzerindeki kırmızı ve siyah çizgilerin paralel olması, hiperparametreler arasında anlamlı bir etkileşimin olmadığını gösterir.

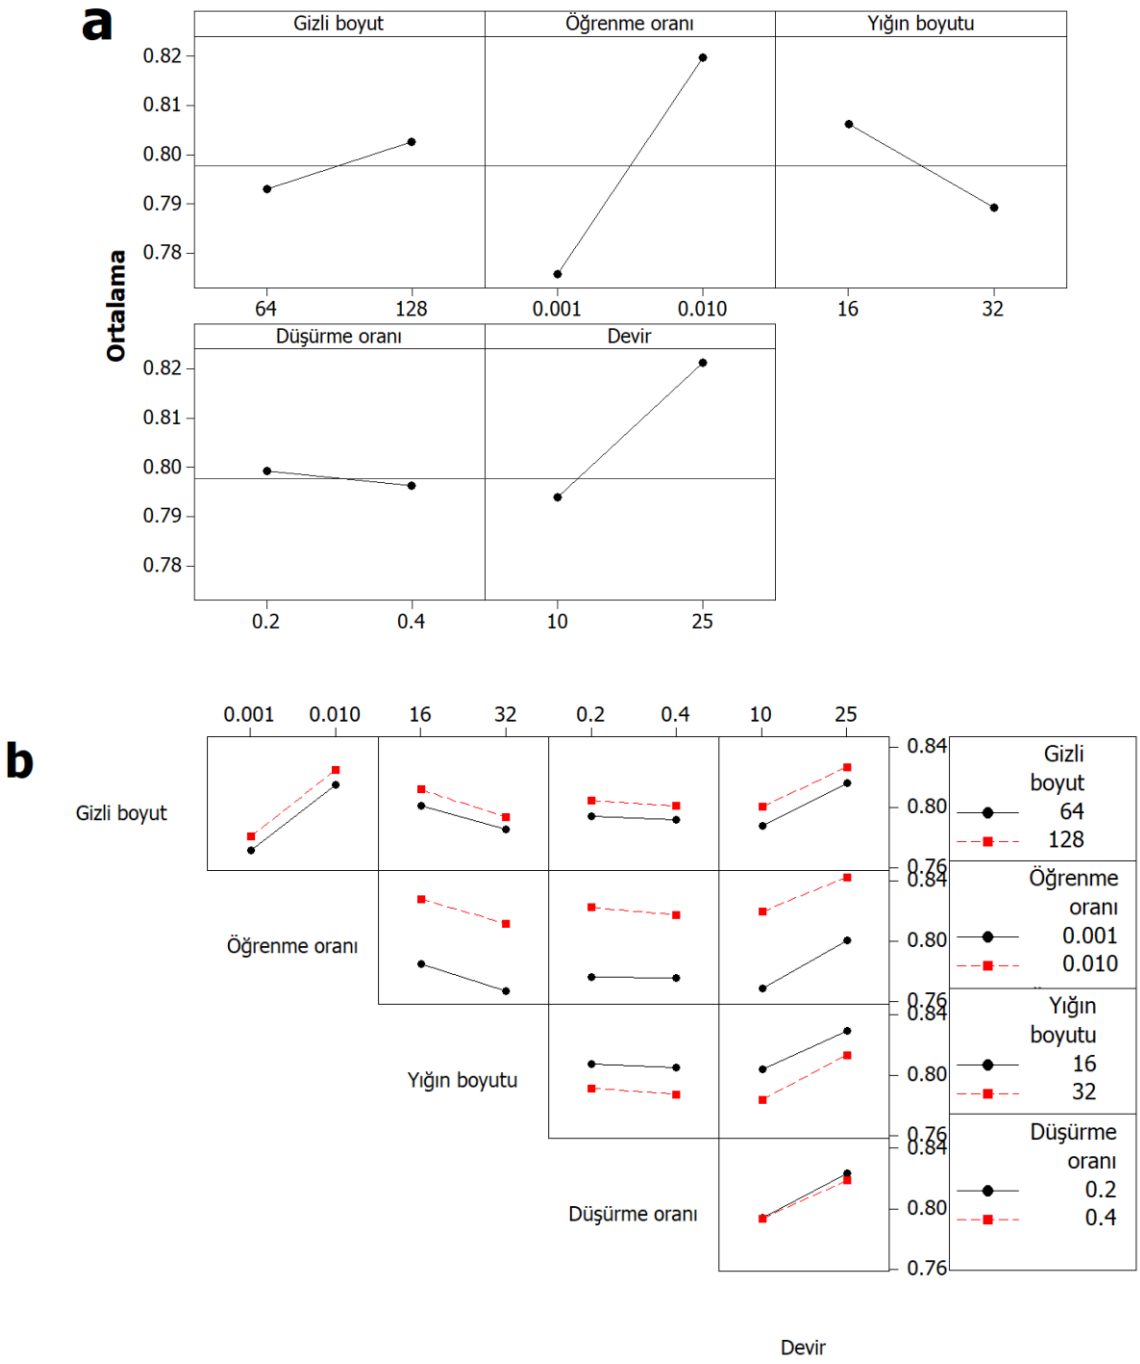

Şekil 1. Doğruluk değerleri için test veri setinde (1000 örnek) a) ana faktörlerin etkisi ve b) ikili etkileşimler.

Şekil 2(a) ve 2(b) hiperparametrelerin modelin kayıp değeri üzerindeki etkilerini incelemektedir. Yüksek öğrenme oranı, kayıp değerini önemli ölçüde düşürmekte, yığın boyutunun 16'dan 32'ye çıkarılması ise kayıp değerini artırmaktadır. Aynı şekilde, düşürme oranının artırılması da kayıp değerini yükseltmektedir. Gizli boyutun 64'ten 128'e çıkarılması ise kayıp değerini düşürmüştür. Gizli boyut, bir modelin katmanlarında bulunan nöron sayısını veya gizli (latent) temsillerin boyutunu temsil eder. Bu, bir modelin öğrenebileceği

özelliklerin karmaşıklığına dair bir göstergedir. Bu hiperparametre, modelin kapasitesini ve öğrenme kabiliyetini etkiler. Daha büyük bir gizli boyut, modelin daha karmaşık özellikler öğrenmesine ve genellikle daha iyi performans göstermesine sebep olabilir.

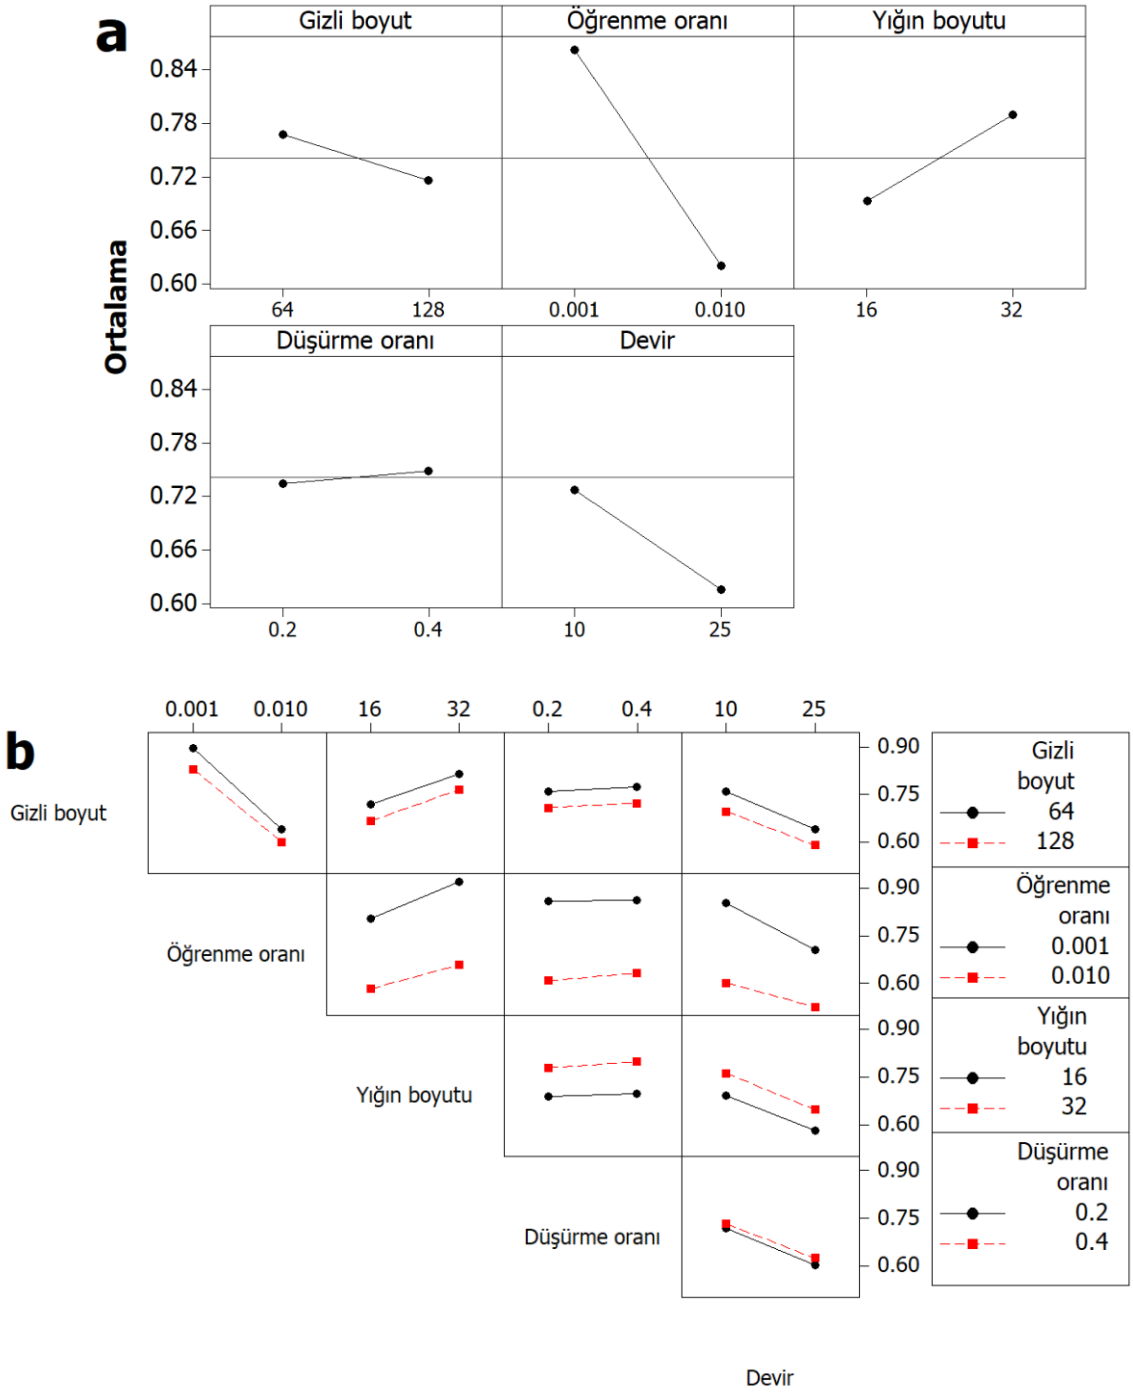

Şekil 2. Kayıp değerleri için test veri setinde (1000 örnek) a) ana faktörlerin etkisi ve b) ikili etkileşimler.

Şekil 3a ve b örnek sayısını 1000'den 10000'e çıkardığımızda hiperparametrelerdeki değişimi göstermektedir. Bu şekilde veri setindeki değişimin hiperparametre üzerindeki etkileri incelenmiş olacaktır. Veri sayısındaki artış, hiperparametreler sabit tutulsa bile modelin doğruluğunu önemli derecede yükseltmiştir. 1000 örnek sayısında hiperparametreler arasında etkileşim gözlenmezken, örnek sayısı 10000'e yükseldiğinde hiperparametreler arasında önemli derecede etkileşim olduğu gözlenmiştir. Buda örnek sayısındaki artışın hiperparametrelerin davranışı üzerinde etkili olduğunu göstermektedir. Örnek olarak, Şekil 3 b'de öğrenme oranı ve gizli boyut arasındaki etkileşimi inceleyelim. Gizli boyut 64 iken, öğrenme oranı 0.001'den 0.01'e yükseltildiğinde doğruluk değerinde ciddi bir yükselme gözlenmezken, gizli boyut 128 iken öğrenme oranını 0.01'den 0.001'e çıkardığımızda doğruluk değerinde çok önemli bir artış gözlenmiştir. Sonuç olarak öğrenme oranı ile gizli boyut arasındaki etkileşim, doğruluk değeri üzerinde sinerjik bir etkiye sebep olmuştur. Benzer etkileşim düşürme oranı ile öğrenme oranı arasında da gözlenmiştir. Öğrenme oranı 0.001 değerinde iken düşürme oranını 0.2'den 0.4'e yükseltmek doğruluk değerini çok fazla düşürmezken, öğrenme oranı 0.01'de tutulduğunda düşürme oranını 0.2'den 0.4'de yükseltmek doğruluk değerini çok önemli derecede düşürmektedir. Bu da bu iki hiperparametrenin doğruluk değeri üzerinde antisinerjik bir etkiye sahip olduğunu göstermektedir.

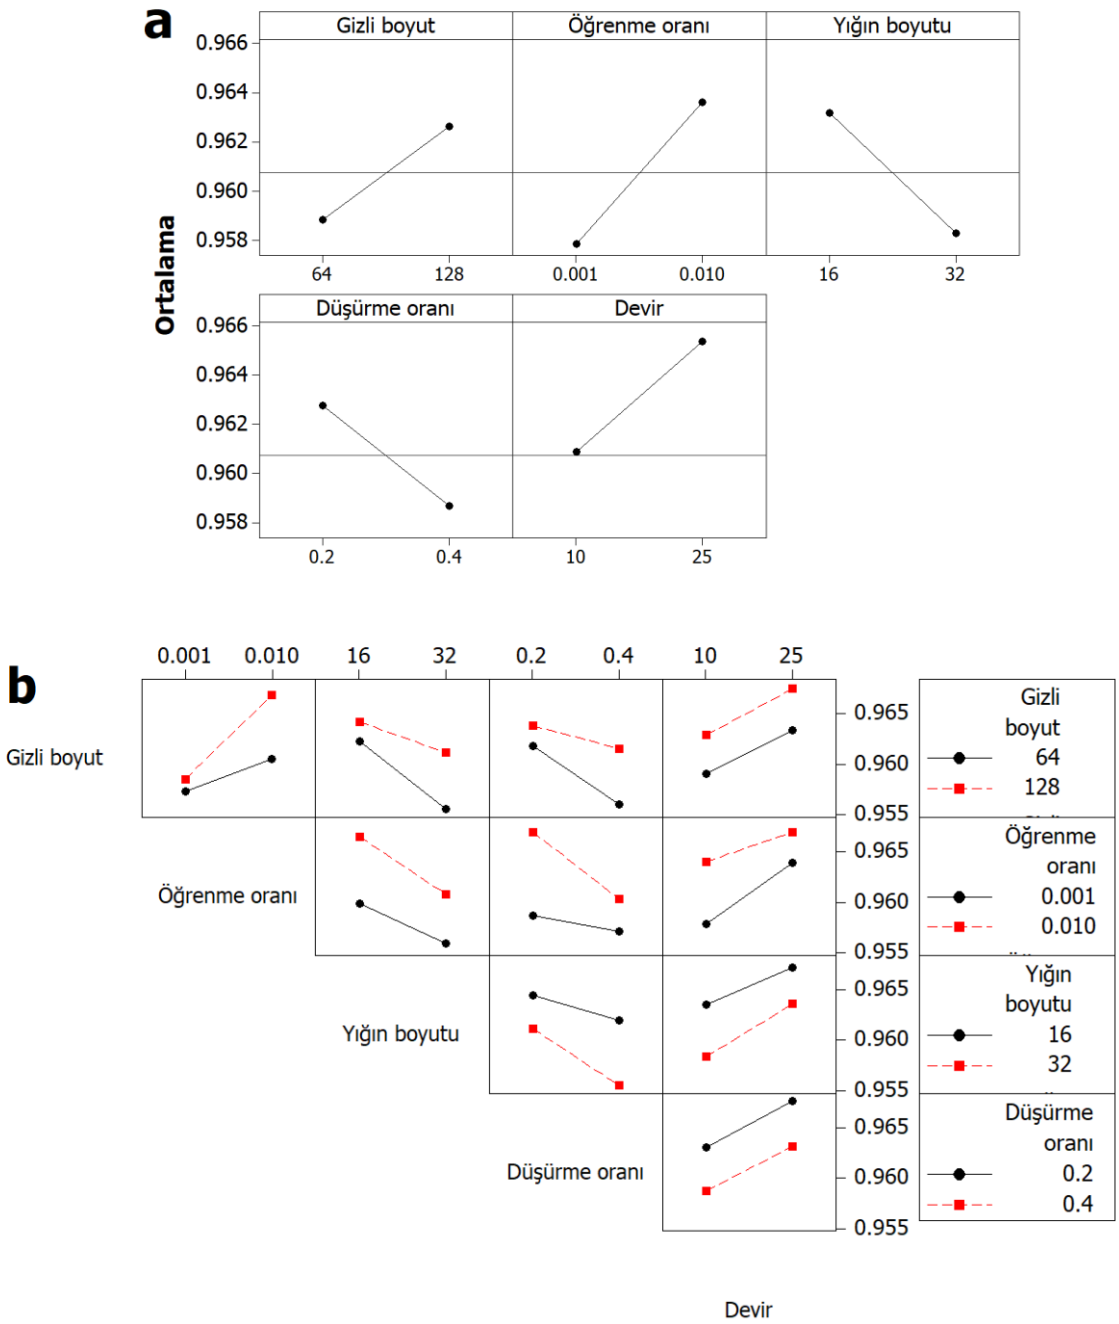

Şekil 0. 10000 örnekli test verisetinde doğruluk değerlerine a) ana faktörlerin etkisi ve b) ikili etkileşimler.

Şekil 4a ve b örnek sayısı 10000'e çıkarıldığında kayıp değerli ile hiperparametre davranışları arasındaki ilişkiyi göstermektedir. Hiperparametrelerin tek başına davranışlarında yön olarak bir değişim gözlenmezken kayıp değerlerin önemli düşüş gözlenmiştir. Ayrıca etkileşim grafiği incelendiğinde doğruluk değerinde olduğu gibi hiperparametrelerin birbiriyle etkileştikleri gözlenmiştir. Gizli boyut 64'den 128'e çıkartıldığında ve öğrenme oranı 0.001'den 0.01'e yükseltildiğinde en düşük kayıp değeri gözlenmiştir.

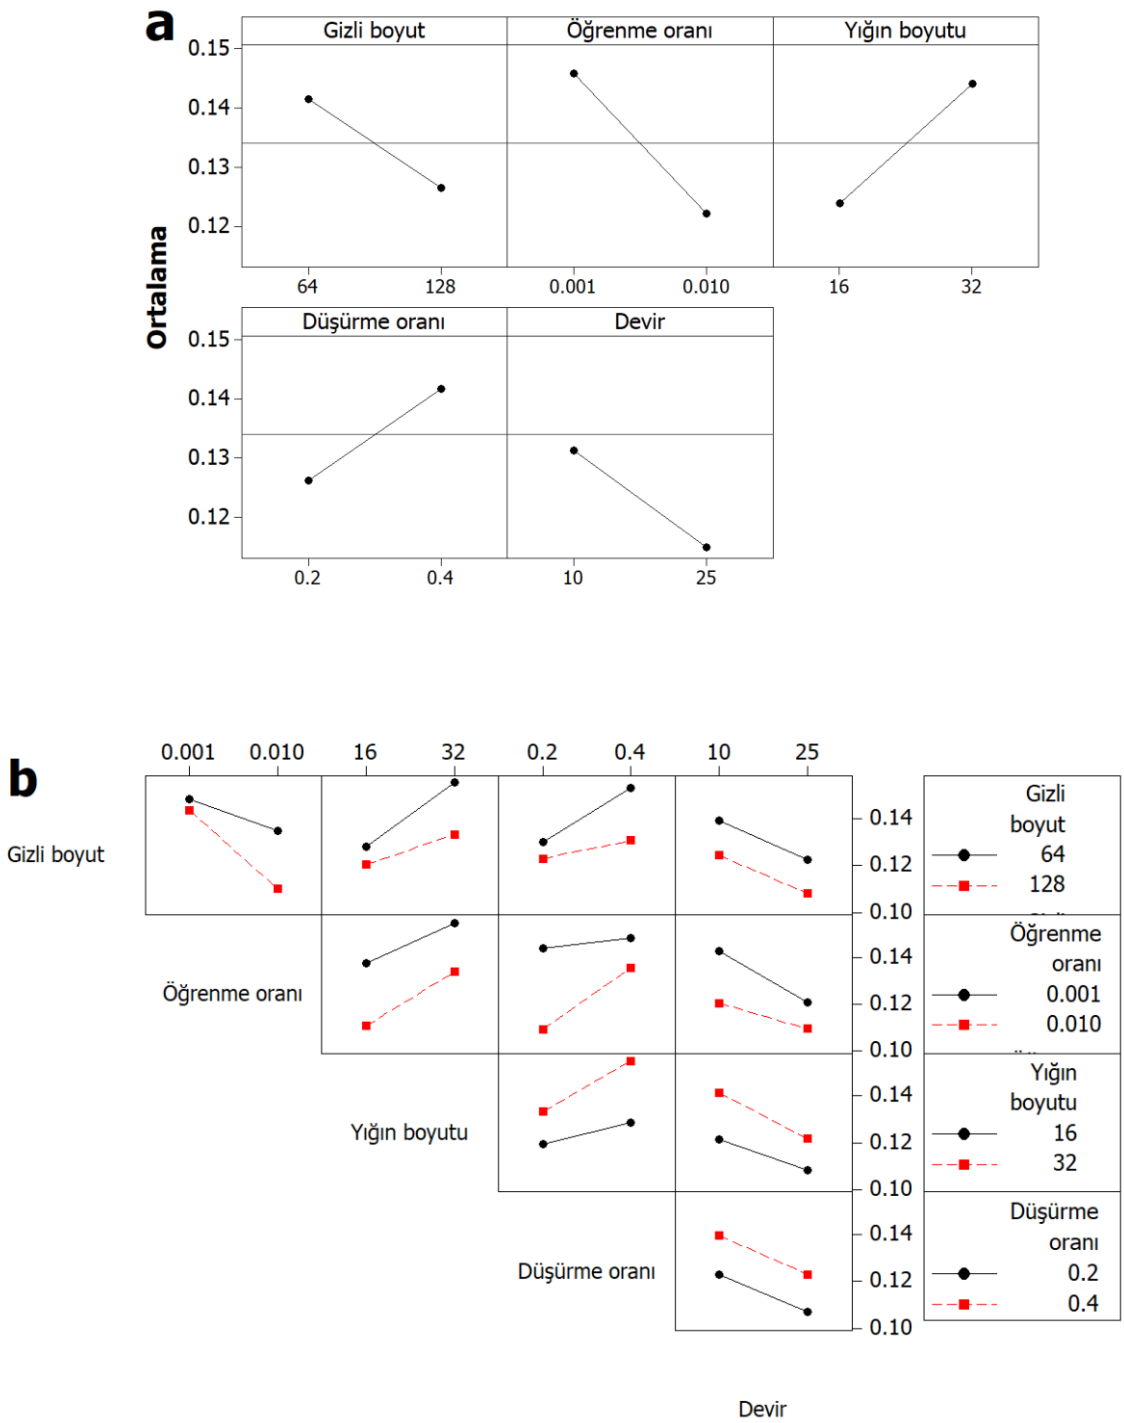

Şekil 4. 10000 örnekli verisetinde kayıp değerlerine () a) ana faktörlerin etkisi ve b) ikili etkileşimler.

3. SONUÇ

Bu çalışma, LSTM modelinin performansını etkileyen çeşitli hiperparametrelerin ve etkileşimlerinin incelenmesi üzerine odaklanmıştır. Bu kapsamda elde edilen sonuçlar aşağıda sıralanmıştır.

- Gizli boyut, öğrenme oranı ve devir sayısının artırılması, modelin doğruluk oranını yükseltmiştir ancak yığın boyutu ve düşürme oranının artırılması, modelin doğruluk oranını düşürmüştür. Yüksek yığın boyutları ve düşürme oranları, modelin genelleme kabiliyetini olumsuz yönde etkileme potansiyeline sahiptir.
- Öğrenme oranı, modelin doğruluk oranı ve kayıp değerleri üzerinde en büyük etkiye sahip hiperparametredir. Yüksek öğrenme oranı, modelin öğrenme hızını artırır ve bu da doğruluk oranı ve kayıp değerleri üzerinde olumlu bir etki meydana getirmektedir.
- Veri setindeki örnek sayısının artması, modelin doğruluk oranı ve kayıp değerlerini önemli ölçüde etkilemiştir. Bu, büyük veri setlerinin modelin genelleme yeteneğini artırabileceğini göstermektedir. Ayrıca, örnek sayısı arttıkça, hiperparametrelerin birbiriyle etkileşimi daha belirgin hale gelmiştir.

Bu çalışmanın bulguları, doğal dil işleme (NLP) uygulamalarında LSTM modellerinin seçim ve uygulama sürecine önemli bilgiler sağlamaktadır. Hiperparametrelerin ve etkileşimlerinin model performansı üzerinde önemli bir etkisi olduğu gösterilmiştir. Bu nedenle, makine öğrenmesi modelinin optimize edilmesinde, hiperparametrelerin uygun şekilde ayarlanması ve etkileşimlerinin göz önünde bulundurulması önemlidir.

Sonuç olarak, bu çalışma, LSTM modellerinin metin sınıflandırma problemleri için performansını değerlendirmiştir. Gelecekteki araştırmalar, metin özetleme, duygu analizi, makine çevirisi gibi diğer NLP problemleri üzerinde odaklanabilir ve böylece modellerin performanslarının bu alanlarda nasıl değiştiğini inceleyebilir. Bu şekilde, NLP uygulamaları için daha geniş ve daha etkili model seçenekleri sunulabilecektir.

KAYNAKÇA

Arpit, D., Jastrzębski, S., Ballas, N., Krueger, D., Bengio, M., Fischer, A., Courville, A., & Bengio, Y. (2017). A closer look at memorization in deep networks. In Proceedings of the 34th International Conference on Machine Learning-Volume 70 (pp. 233-242). JMLR. org.
Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. Journal of Machine Learning Research, 13(Feb), 281-305.
Bishop, C. M. (2006). Pattern recognition and machine learning. springer.
Bottou, L. (2010). Large-scale machine learning with stochastic gradient descent. In Proceedings of COMPSTAT'2010 (pp. 177-186). Springer, Heidelberg.
Bousquet, O., & Bottou, L. (2008). The tradeoffs of large scale learning. In Advances in neural information processing systems (pp. 161-168).
Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. arXiv preprint arXiv:1406.1078.
Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Empirical evaluation of gated recurrent neural networks on sequence modeling. arXiv preprint arXiv:1412.3555.

Halevy, A., Norvig, P., & Pereira, F. (2009). The unreasonable effectiveness of data. IEEE Intelligent Systems, 24(2), 8-12.
Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural computation, 9(8), 1735-1780.
Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980.
Koehn, P. (2009). Statistical machine translation. Cambridge University Press.
Liu, B. (2012). Sentiment analysis and opinion mining. Synthesis lectures on human language technologies, 5(1), 1-167.
Nenkova, A., & McKeown, K. (2011). Automatic summarization. Foundations and Trends® in Information Retrieval, 5(2–3), 103-233.
Sebastiani, F. (2002). Machine learning in automated text categorization. ACM computing surveys (CSUR), 34(1), 1-47.
Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting. The journal of machine learning research, 15(1), 1929-1958.